

Ответы на вопросы Громова: объяснение на пальцах

Второй раунд калибровки (5 октября 2026). Что мы проверяли, что увидели и что из этого следует — подробно, с примерами и без формул там, где без них можно обойтись.

Как читать. Сначала — словарь и общая идея (разделы 0–1). Потом по одному разделу на каждый вопрос Громова. В каждом разделе: *что спрашивали* → *как проверяли* → *что увидели* (с числами) → *что это значит*. Жёлтые блоки — объяснения на пальцах, синие — короткий итог. Полные таблицы — в техническом отчёте «Калибровка, раунд 2».

0. Словарик

слово	что значит здесь
размерность объекта (m, D)	сколько независимых «ручек» нужно, чтобы описать точку на объекте. Линия — 1, поверхность — 2, тор T^2 — 2. У фракталов бывает дробная (салфетка Серпинского — 1,585).
эмбединг, d	способ превратить слово в вектор из d чисел. d — длина вектора, «размер коробки», в которую мы кладём слова.
CBOW, SVD	два способа получить векторы слов. CBOW — нейросетевой (word2vec), учится предсказывать слово по соседям. SVD — линейный, раскладывает таблицу «слово × документ».
эталон	те же «слова», но с их настоящими координатами на объекте (центры ячеек). Это то, что получилось бы при идеальном эмбединге.
оценщик	метод, который по облаку точек выдаёт число — размерность. У нас четыре: Швайнхарт, TwoNN, Hidalgo, FisherS.
плато	оценка перестаёт расти, когда мы увеличиваем d. Признак того, что мы меряем объект, а не размер коробки.
слова / биграммы	облако векторов отдельных слов / облако пар соседних слов (два вектора подряд).
FNN, FNF	ложные соседи двух типов (раздел 5). FNN — от «сплющивания», FNF — от «складок».

1. Общая идея: зачем вообще калибровка

Мы хотим измерить размерность «смыслового пространства» языка. Но у языка мы не знаем правильного ответа, поэтому не можем проверить, врёт метод или нет. Выход — сначала проверить метод там, где ответ известен.

На пальцах. Это как проверка весов гирями. Прежде чем взвешивать неизвестный груз, кладём на весы гири в 1 кг, 2 кг, 5 кг и смотрим, что они показывают. Если на гире в 2 кг весы показывают 3,5 — мы знаем, что они завышают, и можем ввести поправку. Наши «гири» — объекты известной размерности: торы, сферы, аттракторы, фракталы.

Как из объекта делается «текст» (это предложение Громова): по объекту гуляет точка — это траектория. Объект разрезан на 5000 кусочков-ячеек, каждая ячейка — «слово». Пока точка гуляет, мы записываем, в какой ячейке она сейчас, — получается последовательность слов, то есть текст. Дальше с этим текстом делаем всё то же, что с «Войной и миром»: строим векторы слов (CBOW, SVD) и мерим размерность облака векторов. Поскольку истинная размерность объекта известна,

видно, насколько метод прав.

Первый раунд показал: CBOW + TwoNN / Hidalgo / Швайнхарт дают плато, но завышают примерно в 1,5–2 раза; SVD растёт вместе с d ; FisherS неинформативен. Громов задал три новых вопроса — разберём их по очереди.

2. Вопрос 1а. Что будет при ещё больших d ?

Что спрашивали. Раньше мы смотрели d до 30. Не может ли быть так, что «плато» — это просто случайность диапазона, и при $d = 50$ или 100 оценка снова поползёт вверх?

Как проверяли. Те же торы и сферы, плюс более «толстые» объекты — T^{10} , T^{12} , S^{12} — и потоки Лоренца, Рёсслера и Лоренца-96. Векторы CBOW и SVD при $d = 5, 10, 15, 30, 50, 100$.

На пальцах. Представьте, что вы пытаетесь уложить скомканный лист бумаги (двумерный объект) в коробку. В плоскую коробку ($d = 1$) он не влезет без того, чтобы слои легли друг на друга. В объёмную — влезет. Теорема Уитни говорит: объект размерности m гарантированно можно уложить без самопересечений в «коробку» размерности $2m$. То есть тору T^6 нужна коробка хотя бы 12-мерная, T^{12} — 24-мерная. Если коробка меньше, объект «сминается», и метод видит не объект, а размер коробки. Когда коробка становится достаточно большой, объект перестаёт сминаться, и оценка выходит на плато.




Рис. 1. Оценка TwoNN в зависимости от d (ось d — логарифмическая). Сплошные линии — CBOW, пунктир — SVD. Слева — облако слов, справа — облако биграмм. Штриховая диагональ — оценка, равная d .

Что увидели.

- **Для $m \leq 8$ плато настоящее.** CBOW выходит на плато к $d = 15$ –30 и держит его до $d = 100$. Пример — T^8 : 14,5 при $d = 30$, 14,8 при $d = 50$, 14,4 при $d = 100$. Пять разных «коробок» — одна и та же оценка.
- **Для $m = 10$ –12 плато наступает позже,** примерно при $d \approx 50$: T^{10} — 18,7 / 22,2 / 22,8 при $d = 30$ / 50 / 100. Это ровно то, что предсказывает Уитни: коробка должна быть порядка $2m = 20$ –24, и чуть больше с запасом.
- **Уровень плато всё ещё завышен:** на словах примерно в 1,6–2,5 раза больше m (T^8 даёт 14,5 вместо 8). Завышение не исчезает с ростом d — это свойство самого

CBOW, а не нехватки места.

- **SVD растёт всегда:** у T^6 23 при $d = 30$ и 49 при $d = 100$. SVD-векторы «занимают» всю коробку, сколько ни дай.
- **Биграммы при $m \geq 8$ упираются в потолок 12-14** — и у CBOW, и у SVD, и даже у эталона. Это не свойство эмбединга, а нехватка точек (см. ниже).
- **Потоки восстанавливаются гораздо лучше броуновских блужданий.** Лоренц-96 с истинной размерностью 6,55 даёт на биграммах 6,6–6,8 — почти точно. У броуновского тора T^6 на биграммах $\approx 9,8$.

На пальцах. Почему у биграмм потолок 12-14? Чтобы «увидеть», что объект 12-мерный, нужно очень много точек: число точек, необходимое для надёжной оценки, растёт примерно как 10 в степени размерности. 10 000 биграмм хватает, чтобы отличить 4 от 6, но не 10 от 12 — облако выглядит «просто очень многомерным». Это называется «проклятие размерности», и о нём же пишут Малинецкий и Потапов (§ 13.1).

На пальцах. Почему потоки лучше, чем броуновское блуждание? В потоке (Лоренц, Рёсслер) следующая точка однозначно определяется предыдущей — траектория гладкая и «предсказуемая». В броуновском блуждании каждый шаг случаен. CBOW учится по соседним словам: в потоке соседи несут много информации о положении слова, в случайном блуждании — меньше, и векторы получаются «размазанными», с лишними направлениями. Отсюда завышение.

Коротко: плато CBOW — не случайность, оно сохраняется до $d = 100$. Для больших m нужна коробка $d \geq 2m$. SVD для измерения размерности не годится. Абсолютное значение CBOW завышено, и завышение сильнее у случайных блужданий, чем у детерминированных потоков.

3. Вопрос 16. Фракталы и мультифракталы

3.1. Что такое фрактальная размерность

На пальцах. Возьмите отрезок и уменьшите его в 2 раза — нужно 2 копии, чтобы собрать исходный. Квадрат: уменьшили в 2 раза — нужно $4 = 2^2$ копии. Кубик — $8 = 2^3$. Показатель степени и есть размерность. А салфетка Серпинского собирается из 3 копий, уменьшенных в 2 раза: $3 = 2^D$, откуда $D = \log 3 / \log 2 \approx 1,585$. Она «больше линии, но меньше поверхности».




Рис. 2. Салфетка Серпинского, как мы её строили: 19 683 клетки. При увеличении в 8 раз видна та же картинка (самоподобие). При увеличении в 50 раз видны отдельные клетки — и они выстроены в линии.

Мы взяли шесть таких объектов: салфетку (1,585), ковёр Серпинского (1,893), тетраэдр Серпинского (2), его аналоги в 4 и 7 измерениях (2,32 и 3) и губку Менгера (2,727). Текст получался так: точка случайно прыгает по соседним клеткам фрактала.

3.2. Что увидели на «эталоне» — самих координатах клеток

объект	истинная D	Швайнхарт	TwoNN	Hidalgo
салфетка	1,585	1,5	1,0	1,1
ковёр	1,893	1,7	1,3	1,2
тетраэдр	2	1,8	1,0	1,2
губка Менгера	2,727	2,5	2,5	1,9
7-симплекс	3	2,7	1,9	2,0

На пальцах. Почему Швайнхарт прав, а TwoNN занижает? TwoNN смотрит только на двух ближайших соседей каждой точки — то есть на самый мелкий масштаб. А на самом мелком масштабе (правая картинка рис. 2) наш дискретный фрактал состоит из клеток, стоящих в линию, — и TwoNN честно говорит «линия, размерность 1». Швайнхарт строит минимальное остовное дерево на выборках разного размера и смотрит, как меняется его длина, — то есть использует сразу много масштабов, от мелкого до крупного. Поэтому он видит самоподобную структуру и даёт близкое к D число. Мораль: для фракталов надо смотреть на много масштабов сразу.

3.3. Что увидели с CBOW


На всех фракталах с D от 1,6 до 3 CBOW даёт почти одно и то же: 3,2–4,1. Например, салфетка — 3,2, губка — 4,1. Плато есть, но его уровень почти не зависит от D .

На пальцах. У CBOW есть «пол»: он не умеет показать размерность ниже 3–4. Мы видели это уже в первом раунде на двумерных объектах (T^2 , S^2 , Лоренц давали 3,5–5). Похоже на весы, у которых стрелка не опускается ниже 3 кг: гирю в 1,5 кг и гирю в 2,5 кг они покажут одинаково. Значит, если у языка размерность маленькая (меньше 3), CBOW её не измерит. Хорошая новость: все наши оценки языка — 8–15, это далеко от «пола».

3.4. Мультифракталы

На пальцах. У обычного фрактала все кусочки «одинаково важны». У мультифрактала — нет. Представьте карту страны, где население распределено неравномерно: в одних городах живёт 60 % людей, в других 25 %, в третьих 15 %, и внутри каждого города то же самое повторяется на районах, кварталах и т. д. Территория (носитель) — одна и та же, а «где люди» — по-разному. Тогда размерностей несколько: D_0 — размерность территории (сколько места занято вообще), D_1 — «информационная», D_2 — «корреляционная» (насколько часто две случайно выбранные точки оказываются рядом). Чем неравномернее население, тем сильнее D_2 меньше D_0 .

равномерная мера: все клетки одинаково «населены»



мультифрактал: вес 0,6 / 0,25 / 0,15




Рис. 3. Одна и та же салфетка: слева точки разбросаны равномерно, справа — с весами 0,6 / 0,25 / 0,15. Носитель одинаковый ($D_0 = 1,585$), но справа точки сгущаются в «столицах»: $D_1 = 1,35$, $D_2 = 1,17$.

Что увидели. На эталоне мультифрактала TwoNN даёт 1,0, Швайнхарт 1,1 — это ближе к $D_2 = 1,17$, чем к $D_0 = 1,585$. CBOW даёт 2,7 — меньше, чем на равномерной салфетке (3,2).

На пальцах. Когда мы мерим размерность по выборке точек, мы мерим не «территорию», а «где живут люди». Для языка это важно: частые слова встречаются в тексте во много раз чаще редких, то есть «население» слов распределено очень неравномерно (закон Ципфа). Значит, наши оценки по словам — это скорее D_1 – D_2 «языка с его частотами», а не размерность «всех возможных смыслов».

Коротко: для фракталов надёжнее Швайнхарт (много масштабов), TwoNN/Hidalgo занижают из-за дискретности. CBOW не различает размерности

меньше 3–4. Для неравномерно «заселённых» объектов оценки ближе к D_2 , чем к D_0 , — для языка с законом Ципфа это надо помнить.

4. Вопрос 2. Как влияет число точек и число траекторий

Что спрашивали. Насколько результат зависит от того, сколько у нас данных — сколько «слов» (V , на сколько ячеек порезан объект) и сколько «документов» (траекторий).

Как проверяли. T^4 , T^6 , S^4 и Лоренц. Словарь $V = 1000, 2000, 5000, 10\,000, 20\,000$ при 500 траекториях; и 100, 250, 500, 1000, 2000 траекторий при $V = 5000$.

T^4 ($m = 4$)	$V = 1000$	2000	5000	10 000	20 000
CBOW $d=15$, слова, TwoNN	9,2	8,3	8,1	7,7	6,6
CBOW $d=30$, биграммы	6,7	6,6	6,9	7,2	7,2
эталон	4,6	4,0	4,1	4,1	4,0

T^4 ($m = 4$)	100 траекторий	250	500	1000	2000
CBOW $d=15$, слова, TwoNN	7,4	7,9	8,1	8,1	8,7
CBOW $d=30$, биграммы	6,2	6,5	6,9	7,1	7,3

Что увидели. Размер словаря влияет сильнее всего: чем больше словарь, тем меньше завышение CBOW на словах (T^4 : $9,2 \rightarrow 6,6$; T^6 : $12,7 \rightarrow 9,5$). Число траекторий влияет слабо и в обратную сторону (T^4 : $7,4 \rightarrow 8,7$). Эталон от объёма данных почти не зависит. У Лоренца, наоборот, слова растут с V ($3,7 \rightarrow 4,2$).

На пальцах. Почему словарь важнее длины корпуса? Чем мельче нарезан объект (больше слов), тем ближе соседние слова в тексте друг к другу на самом объекте — и тем точнее CBOW восстанавливает, «кто с кем рядом». Длина корпуса — это сколько раз мы видели каждое слово; после некоторого порога лишние повторы мало что добавляют. Аналогия: чтобы нарисовать карту города, важнее, насколько подробно вы разделили его на кварталы, чем сколько раз прошли по одним и тем же улицам.

Коротко: сравнивать корпуса (фреймы, модели, языки) надо при одинаковом размере словаря — разница в V может дать разницу в оценке больше, чем реальный эффект. Длина корпуса менее критична.

5. Вопрос 3. Реальная ситуация: истинная размерность неизвестна

Это главный вопрос: в языке «гири» нет. Можно ли по самим данным, без знания ответа, понять, какая размерность? Громов подсказал смотреть на теорему Уитни косвенно — через ложных соседей (FNN и FNF), как в книге Малинецкого и Потапова.

5.1. Теорема Такенса: восстановление объекта по одному сигналу

На пальцах. Представьте, что вы не видите сам маятник, а видите только его тень на стене — одну координату $x(t)$. Кажется, что информации мало. Но Такенс доказал: если взять несколько значений тени подряд — $x(t)$, $x(t + \tau)$, $x(t + 2\tau)$, ... — и считать их координатами точки, то при достаточном их числе k получится копия исходного объекта (без самопересечений). Достаточно $k \geq 2D + 1$ — это та же граница, что в теореме Уитни.




Рис. 4. Аттрактор Лоренца, восстановленный по одной координате $x(t)$. $k = 1$: только значения x — всё сжато в отрезок. $k = 2$: появляется форма аттрактора, но траектории пересекаются. $k = 3$: пересечения исчезают — объект восстановлен.

Как понять, что k уже достаточно? Тут и появляются ложные соседи.

5.2. Два типа ложных соседей




Рис. 5. Слева и в центре — FNN: две далёкие точки окружности после проекции на прямую слипаются. Справа — FNF: кривая, уложенная «гармошкой», где далёкие по кривой участки оказываются рядом.

На пальцах. FNN (ложные ближайшие соседи). Если смотреть на окружность сбоку, две противоположные точки сольются в одну — они «соседи» в проекции, но не на самом деле. Так бывает, когда k слишком мало: объект сплюснен. Если добавить ещё одну координату ($k + 1$), ложные соседи разъезжаются, а настоящие — остаются рядом. Алгоритм Кеннела так и работает: увеличиваем k , считаем, сколько соседей «разъехалось»; когда их доля упала до нуля — k достаточно.

На пальцах. FNF (ложные соседи на складках). Это обратная беда — когда k (точнее, окно $(k - 1) \cdot \tau$) слишком велико. За длинное окно соседние траектории успевают разойтись, реконструкция начинает «складываться гармошкой», и далёкие участки снова оказываются рядом — но уже на крупных масштабах. По Малинецкому и Потапову (§ 13.3), для простых объектов есть «окно» хороших k , где FNN уже нет, а FNF ещё нет. Для сложных (многомерных) объектов это окно может исчезнуть — оба типа ложных соседей есть одновременно, и реконструкция не работает. Слепой признак FNF: с ростом k растёт наклон корреляционного интеграла на крупных масштабах.

5.3. Что мы посчитали

- Для каждого объекта — классическое вложение с задержкой по одной координате (как на рис. 4), $k = 1 \dots 20$.
- Для текста — то же самое, но вместо значений сигнала берём векторы слов: «точка» — это k слов подряд (k -грамма). Векторы слов — либо истинные координаты клеток (эталон), либо CBOW.
- Для каждого k : доля FNN по Кеннелу; критерии Цао E1 и E2; наклон корреляционного интеграла на трёх масштабах; и — раз у нас калибровка и ответ известен — прямую долю ложных соседей: сосед по реконструкции, который в исходном пространстве далеко.




Рис. 6. Вложение с задержкой. Слева — доля FNN по Кеннелу; в центре — настоящая доля ложных соседей (FNN + FNF); справа — наклон корреляционного интеграла на малом масштабе.

Что увидели (рис. 6).

- **Кеннел обманывается.** Доля FNN падает до нуля у всех, в том числе у случайного блуждания по тору (серая линия). Значит, одного FNN мало: он не отличает «восстановили объект» от «это просто шум».

- **Настоящая доля ложных соседей всё показывает.** У Лоренца она минимальна при $k = 3-4$ (14 %), а дальше растёт до 43 % при $k = 12$ — это FNF, ровно как в книге. У Рёсслера ложных почти нет (1-2 %) при любом $k \geq 3$. У Лоренца-96 с $N = 10$ минимум 60 %: FNN и FNF одновременно, как Малинецкий и Потапов и предсказывают для многомерных аттракторов. У случайного блуждания ≈ 90 % при любом k — восстановить нечего.
- **Наклон корреляционного интеграла** (правая панель) у Лоренца и Рёсслера выходит на плато 2,0 и 1,8 — это и есть их размерность. У Лоренца-96 и тора он растёт линейно с k — объект не восстановился.

Но настоящую долю ложных соседей мы можем посчитать только в калибровке — для языка исходного пространства нет. Поэтому нужны признаки, которые работают вслепую.

На пальцах. Критерий Цао E2 — вслепую отличает «динамику» от «шума».

Идея: если два момента похожи по прошлому, то в детерминированной системе у них похоже и будущее, а в случайной — нет. E2 сравнивает, насколько похожи «следующие шаги» у соседей. Для случайного процесса $E2 \approx 1$ при любом k , для детерминированного — заметно меньше 1 при малых k . У нас: потоки 0,02-0,25, броуновские блуждания ≈ 1 .

5.4. То же для текста: облако из k слов подряд




Рис. 7. Наклон корреляционного интеграла для облака из k подряд идущих слов. Слева — слова как истинные координаты клеток, справа — как векторы CBOW $d = 30$.

На пальцах. Это прямой аналог теоремы Такенса для текста. Если текст порождён детерминированной динамикой, то одно слово «почти определяет» следующее, и облако из k слов подряд не становится многомернее с ростом k — оно насыщается на размерности объекта (левая панель: Лоренц 2,1, Рёсслер 1,7 при любом k). Если текст — случайное блуждание, каждое следующее слово добавляет новую случайность, и облако k -грамм растёт с k (тор T^6 : 7,6 → 25). С векторами CBOW картина та же, только всё сдвинуто вверх (у потоков 6-7 при всех k , у T^6 — от 8,6 до 26).

Это и есть ответ на вопрос «как понять, что за текст перед нами»: смотрим, растёт ли размерность k -грамм с k .

5.5. Обратная модель: из оценок — в истинную размерность

На пальцах. Если весы систематически врут, по гилям можно построить таблицу поправок: «показали 8 — значит, на самом деле 4». То же мы делаем для размерности. По калибровочным объектам строим кривую «оценка CBOW → истинная m ». Чтобы проверить её честно, используем принцип экзамена без подсказки (leave-one-out): строим кривую по всем объектам, кроме одного, и предсказываем этот один — как будто его ответ неизвестен. Так по очереди для каждого объекта. Объекты при этом делим на две группы по слепому признаку E2: у «броуновских» и «динамических» кривые разные.




Рис. 8. Восстановленная вслепую размерность против истинной. Точки на диагонали — идеальное попадание.

что используем	типичная ошибка	худший случай
TwoNN по словам, CBOW $d = 30$	13 %	39 %
TwoNN по биграммам, CBOW $d = 30$	14 %	39 %
Hidalgo по биграммам, CBOW $d = 30$	16 %	37 %
то же без деления на группы	15 %	51 %

Что это значит. Хотя CBOW завышает, завышение систематическое, и по калибровочной кривой размерность восстанавливается с типичной ошибкой 13–16 %. Хуже всего — маленькие фракталы (тут мешает «пол» CBOW) и T^{12} (биграммы упираются в потолок). Важно: кривая годится для текстов, похожих на калибровочные — с тем же размером словаря и тем же обучением CBOW.

Коротко: в реальной ситуации порядок действий такой: (1) по E2 и поведению k -грамм понять, «динамический» текст или «случайное блуждание»; (2) убедиться, что есть плато по d (и $d \geq 2m$ с запасом); (3) пересчитать оценку CBOW в размерность по калибровочной кривой своей группы. Один FNN по Кеннелу для этого не годится — он не отличает шум от динамики.

6. Что это даёт для наших диалогов

В отчёте по фреймам (4 октября) у коротких диалогов было: CBOW-биграммы TwoNN при $d = 30 \approx 8,7$ – $9,5$ (плато есть), слова ≈ 14 – 16 (плато нет, рост с d).

- Если язык диалогов ведёт себя как «броуновская» группа, калибровка переводит это в **$m \approx 6$ – 7 по биграммам** и ≈ 8 – 9 по словам.
- Если как «динамическая», кривая выходит за пределы того, что мы откалибровали ($m > 7$), — пока сказать нельзя.
- Чтобы выбрать группу, нужно посчитать для диалогов E2 и поведение k -грамм. Это следующий шаг, я его поставлю на HSE.
- Оговорки: у диалогов другой словарь (≈ 6000 лемм) и сильно неравномерные частоты слов (раздел 3.4), поэтому это ориентир, а не измерение.

7. Итог в шести пунктах

- **Плато CBOW — настоящее:** держится до $d = 100$ для $m \leq 8$. Для больших m нужна «коробка» $d \geq 2m$ (Уитни).
- **SVD и FisherS — не использовать:** SVD растёт с d , FisherS ошибается уже на эталоне.
- **Фракталы:** Швайнхарт близок к D_0 , TwoNN/Hidalgo занижают. CBOW не различает $D < 3$ – 4 .
- **Мультифракталы:** оценки по выборке ближе к D_2 — для языка с законом Ципфа это важно при интерпретации.
- **Объём данных:** размер словаря влияет сильнее длины корпуса — сравнивать при одинаковом V .
- **Вслепую:** E2 и k -граммы показывают тип текста; калибровочная кривая даёт размерность с ошибкой $\approx 15\%$.

Что ещё досчитывается: мультифрактал на тетраэдре и две самые большие конфигурации по числу траекторий. Они не меняют выводов, но я добавлю их в технический отчёт.