

Калибровка на псевдоязыке: можно ли узнать истинную размерность

Тексты, порождённые блужданием по фигуре известной размерности m , превращаются в эмбединги (SVD, CBOW), и к ним применяются те же четыре метода, что и к «Войне и миру». Вопрос: какой из получающихся цифр можно верить. Расчёт — суперкомпьютер НИУ ВШЭ CHARISMa, 2 октября 2026.

Главное

1. **CBOW по «локальному» тексту восстанавливает размерность:** оценка растёт вместе с m и при $d = 10-15$ лежит на 0,2-0,9 выше истины (Швайнхарт при $d = 15$: 2,6 / 3,5 / 4,3 / 6,2 для $m = 2 / 3 / 4 / 6$). Между $d = 10$ и $d = 15$ она почти не меняется — выходит на плато.
2. **Признак надёжной оценки — плато по d .** Если оценка продолжает расти с d , её нельзя читать как размерность.
3. Нужен запас по d : при $d = 5$ CBOW не может показать больше ≈ 4 ($m = 6 \rightarrow 4,0$). Это согласуется с теоремой Уитни ($d \geq 2m$).
4. **SVD завышает и не выходит на плато** ($m = 4 \rightarrow 7-8$, $m = 6 \rightarrow 8-10$). **FisherS на CBOW неинформативен** ($\approx 6-7$ при любом m).
5. Блуждание из тетрадки ($p \propto 1/d^2$) при $m \geq 3$ почти не локально: текст перестаёт нести геометрию, и все оценки растут с d . Профиль CBOW «Войны и мира» по d ($4,7 \rightarrow 8,9 \rightarrow 10,0$) похож именно на этот режим, а не на плато.

1. Постановка

- **Объект.** Куб $[0,1]^m$, $m = 2, 3, 4, 6$, из которого вырезаны 4 шара («дырки»; для $m = 2$ — круги из тетрадки). 5 000 случайных точек до вырезания, после — 4 581-4 999. Каждая точка — «слово».
- **Тексты.** 1 000 текстов; длины взяты из корпуса русских текстов (russian_Prussner_wolframe100.csv), делённых на $k = 60\,000 // V$, как в тетрадке; $\approx 0,84-0,94$ млн словоупотреблений.
- **Два способа блуждания.** *dist* — как в тетрадке: следующее слово выбирается с вероятностью $\propto 1/(\text{расстояние})^2$. *eps* — равновероятно среди соседей ближе $\epsilon = 1,5 \cdot V^{-1/m}$ (несколько ближайших соседей).
- **Эмбединги.** SVD по методике статьи «A Language and Its Dimensions» (слово $\times$ текст, энтропийные веса); CBOW с настройками тетрадки (5 эпох, min_count 3) и с настройками «Войны и мира» (30 эпох, min_count 1, window 5, negative 5); $d = 2, 5, 10, 15$. Эталон — сами точки (истинная геометрия).
- **Методы.** Швайнхарт (две лестницы, min-max по допустимым α), TwoNN, FisherS, Hidalgo — те же реализации, что в отчёте по «Войне и миру». Слова и биграммы (конкатенация векторов соседних слов, до 10 000 случайных биграмм).

2. Насколько локальны тексты

m	медиана шага, dist	медиана шага, eps	расстояние до ближайшего соседа	шаг dist / сосед
2	0,005	0,016	0,007	0,7
3	0,27	0,070	0,032	8,4
4	0,51	0,15	0,075	6,8
6	0,80	0,32	0,18	4,4

При $m \geq 3$ блуждание dist делает шаги порядка размера самого куба: вероятность $\propto 1/r^2$ падает медленнее, чем растёт число точек на расстоянии r ($\propto r^{m-1}$), и дальние прыжки доминируют. Соседние слова такого текста почти не связаны геометрически. Блуждание eps локально при любом m .

3. Истинная размерность против оценки




Рис. 1. Оценка TwoNN по словам при $d = 15$. Слева — локальное блуждание: CBOW идёт параллельно диагонали чуть выше неё, SVD сильно завышает. Справа — блуждание тетрадки: все эмбединги далеко от истины.

Таблица 1. Слова, блуждание eps. Крупно — TwoNN, мелко — диапазон Швайнхарта.

m	точки	CBOW d=5	CBOW d=10	CBOW d=15	CBOW-те тр. d=15	SVD d=5	SVD d=10	SVD d=15
2	2,04 1,91-2,04	2,88 2,92-3,33	2,81 2,61-2,81	2,91 2,59-2,66	2,93 2,55-2,60	2,18 нет доп. α	2,59 1,49-2,13	2,83 1,56-2,27
3	2,88 2,76-2,97	3,41 3,30-3,52	3,65 3,22-3,44	3,88 3,44-3,61	3,74 3,18-3,30	4,10 2,88-3,84	5,26 4,10-4,69	5,95 4,04-5,16
4	3,89 3,74-3,93	3,73 3,65-3,87	4,45 4,00-4,32	4,78 4,16-4,42	4,51 4,09-4,22	4,71 4,33-4,75	7,22 5,90-6,82	8,29 6,66-7,68
6	5,56 5,15-5,92	4,01 3,97-4,32	5,99 5,50-5,98	6,35 5,66-6,78	5,91 5,39-6,55	4,93 4,92-5,06	8,42 7,93-8,41	9,76 нет доп. α

Таблица 2. Слова, блуждание dist (тетрадка).

m	точки	CBOW d=5	CBOW d=10	CBOW d=15	CBOW-те тр. d=15	SVD d=5	SVD d=10	SVD d=15
2	2,04 1,89–1,99	3,54 3,56–3,75	4,94 4,52–4,96	5,46 5,25–5,82	3,64 4,39–4,80	4,37 3,95–4,69	6,25 5,00–5,56	6,95 5,71–6,26
3	2,88 2,76–2,97	3,78 3,32–3,95	6,48 5,33–5,95	8,03 6,53–7,59	7,53 нет доп. α	4,84 4,09–4,82	8,32 7,67–7,67	10,76 нет доп. α
4	3,89 3,72–3,94	3,91 3,93–4,16	7,41 6,56–7,52	10,38 8,94–9,92	12,28 9,74–12,04	4,87 4,71–4,87	8,81 7,42–8,03	10,62 8,23–8,82
6	5,56 5,15–5,92	3,99 3,89–4,34	8,62 7,64–8,60	12,36 11,81–13,4 8	12,25 12,26–13,4 5	4,74 4,30–4,62	8,59 6,75–7,19	10,66 7,90–8,43

«нет доп. α» — ни одно α не прошло критерий ширины доверительного интервала (10%).

4. Плато по d — главный признак надёжной оценки




Рис. 2. Швайхарт (середина диапазона) по словам в зависимости от d ; пунктир — истинная m . CBOW на локальном тексте выходит на плато около m ; SVD и CBOW на нелокальном тексте растут с d . Красный пунктир — CBOW «Войны и мира» из полного отчёта.

Если оценка устойчива при росте d ($d = 10 \rightarrow 15$ меняет её меньше чем на $\approx 0,5$), это размерность облака, а не артефакт эмбединга. Для «Войны и мира» CBOW даёт $4,7 \rightarrow 8,9 \rightarrow 10,0$ — рост без плато, как у нелокального блуждания. Это не значит, что размерность романа ≈ 10 : по этому критерию цифра пока не надёжна, и её нужно проверить при $d = 20-30$.

5. Сравнение методов




Рис. 3. Четыре метода на одном облаке (CBOW, $d = 15$, eps). Швайнхарт, TwoNN и Hidalgo согласованы и близки к истине; FisherS — нет.

Таблица 3. Все методы, CBOW (настройки ВиМ), $d = 15$, блуждание eps, слова / биграммы.

m	Швайнхарт	TwoNN	FisherS	Hidalgo d_1 / d_2
2	2,59–2,66 / 2,97–3,12	2,91 / 2,96	6,98 / 6,54	2,86, 3,11 / 3,20, 3,24
3	3,44–3,61 / 4,23–4,38	3,88 / 4,03	6,78 / 6,47	3,69, 4,14 / 4,06, 4,58
4	4,16–4,42 / 5,35–5,72	4,78 / 4,99	6,98 / 6,63	4,78, 4,81 / 5,29, 5,48
6	5,66–6,78 / 7,03–8,18	6,35 / 6,14	7,63 / 7,86	6,36, 6,42 / 6,32, 6,45

Для биграмм локального текста истинная размерность — около $m + 1$ (вторая точка лежит в ϵ -окрестности первой; у самих точек TwoNN 2,4 / 3,4 / 4,5 / 5,9). CBOW даёт около $m + 1$ (Швайнхарт до $m + 2$ при $m = 6$) и тоже выходит на плато.

6. Что это значит для оценок языка

- **Можно верить:** Швайнхарту, TwoNN и Hidalgo на CBOW при $d \geq 10$, **если** оценка стабильна между $d = 10$ и $d = 15$ (и дальше). Ожидаемое смещение — завышение на 0,2–0,9.
- **Нельзя читать как размерность:** SVD-оценки (растут с d , на $m = 4$ дают 7–8), FisherS на CBOW, любые оценки при $d < 2m$.
- **Оговорка.** Калибровка верна для текстов, где соседние слова близки в «пространстве смыслов». Реальный язык может быть устроен иначе; отсутствие плато у «Войны и мира» — главный открытый вопрос.
- **Дальше:** (а) CBOW «Войны и мира» и диалогов при $d = 20, 30, 50$ — проверить плато; (б) калибровка на торах, сферах и аттракторе Лоренца с разбиением k-means / муравьиный алгоритм / случайно (уже считается, 30 задач); (в) промежуточные блуждания между eps и dist.

Приложение. Воспроизводимость

Скрипты: `pseudolang.py` (использует `calib_trajectories.measure`),
`8b_pseudolang_array.sbatch` (задача 4370978, 8 подзадач: $m \times$ блуждание), сводка
`pseudo_agg.py`. На HSE: `~/wap_run/pseudo_results` (208 JSON + meta),
`~/wap_run/pseudo_table.csv`. Сиды: точки 2026, тексты 8i + 2, CBOW seed 1.