

Калибровка, раунд 2: большие d , фракталы, объём данных, ложные соседи

Ответ на три вопроса В. А. Громова (5 октября 2026). Задачи HSE 4377311 и 4377944 (53 конфигурации, ~ 700 облаков). Те же тексты-траектории, что в первом раунде, CBOW и SVD до $d = 100$, четыре оценщика, FNN / FNF / Цао.

Главное. (1) **Большие d .** CBOW + TwoNN / Hidalgo / Швайнхарт держит плато до $d = 100$ для $m \leq 8$; для $m = 10-12$ плато наступает только около $d \approx 50$ ($\approx 2m$ — порог Уитни), а SVD растёт с d вплоть до 100 у всех объектов. (2) **Фракталы.** На центрах ячеек Швайнхарт даёт $\approx D_0$ (салфетка 1,5, ковёр 1,7, губка 2,5), а локальные TwoNN / Hidalgo — заниженно (≈ 1), потому что на масштабе соседних ячеек дискретный фрактал выглядит как набор отрезков. CBOW на всех фракталах с $D \leq 3$ даёт одинаковые $\approx 3,2-4,1$ — **малые размерности CBOW не различает**. Для мультифрактала оценки по центрам ближе к D_2 , чем к D_0 . (3) **Детерминированные потоки** (Рёсслер, Лоренц-96) восстанавливаются гораздо лучше броуновских блужданий: CBOW-биграммы Лоренц-96 $N = 10$ дают 6,6–6,8 при $D_{KY} = 6,55$. (4) **Объём данных:** больше слов (V) уменьшает завышение CBOW на словах (T^4 : 9,2 $\rightarrow$ 6,6 при V 1000 $\rightarrow$ 20 000), число траекторий влияет слабо. (5) **Слепой режим.** Классический FNN по скалярной координате находит размерность вложения для потоков (Лоренц $k = 3$), ложные соседи на складках (FNF) видны как рост доли ложных соседей и наклона корреляционного интеграла с k . Для текста работает аналог Такенса: облако k слов подряд у детерминированного потока насыщается (наклон $\approx D$ при любом k), у броуновского — растёт с k . Простая обратная модель «оценки CBOW $\rightarrow m$ », проверенная без подглядывания (каждый объект предсказывается моделью, обученной на остальных), восстанавливает m с медианной ошибкой **13-14 %** (максимум $\approx 40 \%$).

1. Что посчитано

Тексты строятся как в первом раунде: 500 траекторий $\times$ 1500 шагов, разбиение на $V = 5000$ ячеек-слов (случайные центры), повторы схлопываются, предложения по 20 слов. Эмбединги: **эталон** (центры ячеек), **SVD** (как у Громова), **CBOW** (30 эпох, min_count 1, окно 5) при $d = 5, 10, 15, 30, 50, 100$; слова и биграммы. Оценщики — Швайнхарт, TwoNN, FisherS, Hidalgo.

объект	размерность	как строится текст
торы $T^2 \dots T^{12}$, сферы S^4, S^8, S^{12}	m	броуновское блуждание, шаг $\approx$ размер ячейки
Лоренц, Рёсслер	2,06; 2,01 (Каплан—Йорке, посчитано)	траектория потока
Лоренц-96, $N = 6$ и 10 ($F = 8$)	4,0; 6,6 (Каплан—Йорке)	траектория потока
салфетка / ковёр / тетраэдр / 4- и 7-симплекс Серпинского / губка Менгера	1,585 / 1,893 / 2 / 2,32 / 3 / 2,727 (D_0)	случайное блуждание по клеткам фрактала

объект	размерность	как строится текст
мультифракталы на салфетке (веса 0,6/0,25/0,15) и тетраэдре (0,4/0,3/0,2/0,1)	$D_0 / D_1 / D_2 = 1,585 / 1,353 / 1,168$ и $2 / 1,846 / 1,737$	блуждание Метрополиса с этой мерой

Размерность Каплана—Йорке потоков я считаю по спектру Ляпунова (QR-метод); проверка: Лоренц 2,06, Рёсслер 2,01 — совпадает с литературой. Мультифрактал на тетраэдре досчитывается (задача mftetra идёт дольше остальных) — в таблицах прочерки.

2. Вопрос 1а: большие размерности пространства вложения




Рис. 1. TwoNN в зависимости от d (логарифмическая шкала) для торов, Лоренца и Лоренца-96. Сплошные — CBOW, пунктир — SVD. Штриховая — оценка = d.

TwoNN, слова

объект	m	эталон	CBO W d=5	CBO W d=10	CBO W d=15	CBO W d=30	CBO W d=50	CBO W d=100	SVD d=30	SVD d=100
T ²	2,0	2,0	4,0	4,6	4,9	5,0	5,0	5,0	5,4	6,5
T ⁴	4,0	4,1	4,0	7,6	8,1	8,5	8,7	8,7	17,4	28,3
T ⁶	6,0	6,3	4,1	8,5	10,7	11,5	11,6	11,7	23,2	49,3
T ⁸	8,0	8,4	4,1	8,6	12,5	14,5	14,8	14,4	23,8	49,4
T ¹⁰	10,0	11,9	4,0	8,9	12,4	18,7	22,2	22,8	23,4	51,6
T ¹²	12,0	14,5	4,2	8,7	12,8	22,0	29,2	35,1	23,9	49,6
S ⁴	4,0	3,9	4,0	7,7	7,9	8,3	8,5	8,5	15,1	21,7
S ⁸	8,0	7,8	4,0	11,0	11,8	12,8	12,9	12,5	23,4	49,8
S ¹²	12,0	11,2	4,1	8,6	13,9	17,2	18,6	17,9	22,2	50,7
Лоренц	2,1	2,0	3,6	3,6	3,9	4,0	4,0	4,0	6,9	9,0
Рёсслер	2,0	2,0	3,7	3,4	3,4	3,4	3,4	3,4	5,1	7,0
Лоренц-96, N=6	4,0	3,8	4,2	4,9	5,0	5,1	5,1	5,1	7,9	9,3
Лоренц-96, N=10	6,6	6,3	4,3	6,9	7,4	7,6	7,7	7,7	13,8	15,7

TwoNN, биграммы

объект	m	эталон	CBO W d=5	CBO W d=10	CBO W d=15	CBO W d=30	CBO W d=50	CBO W d=100	SVD d=30	SVD d=100
T ²	2,0	2,8	4,4	4,0	4,1	4,1	4,1	4,1	4,3	4,9
T ⁴	4,0	5,8	6,3	6,5	6,8	6,9	6,8	6,8	8,8	11,2
T ⁶	6,0	9,4	7,1	9,7	9,8	9,8	9,7	9,8	11,2	14,4
T ⁸	8,0	12,3	7,2	11,9	12,3	12,2	12,4	11,8	11,8	14,4
T ¹⁰	10,0	13,8	7,5	12,2	13,2	13,0	12,2	12,3	12,0	14,5
T ¹²	12,0	13,8	7,5	12,5	13,4	12,5	12,5	12,9	11,8	14,7
S ⁴	4,0	5,4	6,0	6,4	6,5	6,6	6,6	6,3	8,1	10,0
S ⁸	8,0	10,4	7,1	10,7	10,6	10,7	10,9	10,9	11,6	14,7
S ¹²	12,0	12,6	7,4	12,2	12,8	12,4	12,3	12,3	12,0	14,6
Лоренц	2,1	2,4	3,1	3,1	3,2	3,4	3,3	3,4	8,2	10,6
Рёсслер	2,0	2,2	3,3	3,1	3,1	3,1	3,1	3,1	6,2	8,5
Лоренц-96, N=6	4,0	4,3	4,5	4,9	5,0	5,1	5,0	5,0	7,8	9,1
Лоренц-96, N=10	6,6	6,2	5,7	6,2	6,6	6,6	6,8	6,7	9,8	12,1

Вывод. (а) Для $m \leq 8$ CBOW выходит на плато к $d = 15-30$ и **не уходит с него до $d = 100$** : T^8 14,5 / 14,8 / 14,4 при $d = 30 / 50 / 100$. Значит, плато — не случайность выбранного диапазона d . (б) Для T^{10} и T^{12} рост продолжается до $d \approx 50$ и только потом замедляется (T^{10} : 18,7 $\rightarrow$ 22,2 $\rightarrow$ 22,8), т. е. плато наступает примерно при $d \approx 2m$, как и предсказывает теорема Уитни. Уровень плато на словах $\approx 1,6-2,5 \cdot m$. (в) SVD растёт с d всегда (T^6 : 23 $\rightarrow$ 49 при $d = 30 \rightarrow 100$) — это ещё раз подтверждает вывод первого раунда. (г) На биграммах оценки всех методов, включая эталон, для $m \geq 8$ упираются в $\approx 12-14$: для такой размерности 10 000 точек уже мало (проклятие размерности), и биграммы перестают различать $m = 8, 10, 12$. (д) Поток восстанавливается намного точнее броуновских блужданий: Лоренц-96 с $D = 6,55$ даёт на биграммах 6,6-6,8, на словах 7,6-7,7; Рёсслер 3,4 / 3,1.

Швайхарт и Hidalgo ведут себя так же, как TwoNN (полные таблицы — в `calib2_table.csv`); у Швайхарта при больших m и биграммах чаще нет допустимых α .

3. Вопрос 16: фракталы и мультифракталы

объект	D ₀	эталон: Ш вайхарт	эталон: TwoNN	CBOW d=30: TwoNN слова	CBOW d=30: TwoNN биграммы	CBOW d=100: TwoNN слова	SVD d=15: TwoNN слова
салфетка Серпинского	1,6	1,5-1,9	1,0	3,2	3,4	3,1	1,8
ковёр Серпинского	1,9	1,7-1,9	1,3	3,8	3,9	3,7	2,6
тетраэдр Серпинского	2,0	1,8-2,2	1,0	3,3	3,3	3,3	2,6
4-симплекс Серпинского	2,3	2,0-2,6	1,1	3,4	3,5	3,4	2,9
губка Менгера	2,7	2,5-3,0	2,5	4,1	4,2	4,1	3,2
7-симплекс Серпинского	3,0	2,7-3,2	1,9	3,5	3,9	3,4	3,0
мультифрактал на салфетке	1,6	1,1-1,3	1,0	2,7	3,1	2,7	1,6

Вывод. (а) **Сами методы на фракталах.** Швайнхарт на центрах ячеек близок к D_0 (салфетка 1,5 при 1,585, ковёр 1,7 при 1,89, губка 2,5 при 2,73, 7-симплекс 2,7 при 3), а TwoNN и Hidalgo занижают до $\approx 1-2$: они смотрят на расстояния до 1-го и 2-го соседа, а на этом масштабе дискретный фрактал состоит из отрезков. Швайнхарт использует весь диапазон масштабов, поэтому для фракталов он надёжнее. (б) **CBOW** на всех фракталах даёт 3,2–4,1 и не различает D от 1,6 до 3: при $d \geq 10$ есть плато, но его уровень почти не зависит от D . Это то же, что мы видели на двумерных объектах в первом раунде, — у CBOW есть «пол» около 3–4. (в) **Мультифрактал:** на центрах (они распределены по мере) TwoNN 1,0 и Швайнхарт 1,1 — ниже $D_0 = 1,585$ и ближе к $D_2 = 1,17$. То есть оценки по выборке точек меряют размерность меры (D_1 – D_2), а не носителя. CBOW мультифрактала — 2,7, меньше, чем у «равномерной» салфетки (3,2). (г) SVD при $d = 10$ –15 случайно оказывается близко к D_0 (салфетка 1,8, губка 3,2), но растёт с d , поэтому верить ему нельзя.

4. Вопрос 2: влияние числа точек и числа траекторий

T^4 ($m = 4,0$), TwoNN

V (слов)	траекторий	эталон TwoNN	CBOW 15 слова	CBOW 30 слова	CBOW 30 биграммы	CBOW 30 Швайнхарт слова
1000	500	4,6	9,2	10,0	6,7	7,8–7,8
2000	500	4,0	8,3	8,9	6,6	нет α
5000	100	3,9	7,4	7,4	6,2	6,1–7,5
5000	250	4,2	7,9	8,2	6,5	6,4–6,9
5000	500	4,1	8,1	8,5	6,9	нет α
5000	1000	3,9	8,1	8,8	7,1	6,4–7,0
5000	2000	4,1	8,7	9,1	7,3	6,3–6,9
10000	500	4,1	7,7	8,0	7,2	6,4–6,6
20000	500	4,0	6,6	6,9	7,2	5,9–6,3

T^6 ($m = 6,0$), TwoNN

V (слов)	траекторий	эталон TwoNN	CBOW 15 слова	CBOW 30 слова	CBOW 30 биграммы	CBOW 30 Швайнхарт слова
1000	500	6,7	12,7	14,0	9,9	11,1–13,5
2000	500	6,5	10,9	12,0	9,4	10,1–13,3
5000	100	6,4	10,0	10,1	8,9	9,4–10,6
5000	250	6,2	10,1	10,3	9,3	9,0–10,3
5000	500	6,3	10,7	11,5	9,8	9,0–9,8
5000	1000	6,3	10,6	11,6	10,1	9,2–11,1
5000	2000	6,3	10,9	11,8	10,6	9,3–10,8
10000	500	6,2	10,1	10,3	10,2	8,8–9,2
20000	500	6,2	9,5	9,7	10,5	8,4–9,5

S^4 ($m = 4,0$), TwoNN

V (слов)	траекторий	эталон TwoNN	CBOW 15 слова	CBOW 30 слова	CBOW 30 биграммы	CBOW 30 Швайнхарт слова
1000	500	4,0	8,6	9,4	6,7	6,9–7,6
2000	500	4,2	8,6	9,1	6,4	6,9–7,6
5000	100	4,0	6,8	—	—	—
5000	500	3,9	7,9	8,3	6,6	6,7–6,7

V (слов)	траекторий	эталон TwoNN	CBOW 15 слова	CBOW 30 слова	CBOW 30 биграммы	CBOW 30 Швайнхарт слова
10000	500	4,1	7,5	7,9	6,9	6,2-6,6
20000	500	4,0	6,4	6,5	6,9	5,7-6,2

Лоренц ($m = 2,1$), TwoNN

V (слов)	траекторий	эталон TwoNN	CBOW 15 слова	CBOW 30 слова	CBOW 30 биграммы	CBOW 30 Швайнхарт слова
1000	500	2,2	3,7	4,3	3,5	нет α
2000	500	2,1	3,7	4,0	3,3	3,7-4,0
5000	100	2,1	3,7	—	—	—
5000	500	2,0	3,9	4,0	3,4	3,7-4,2
10000	500	2,0	4,2	4,2	3,6	3,9-4,3
20000	500	2,0	4,2	4,2	4,2	4,4-4,6

Вывод. (а) **Число слов V** — главный фактор: на торах и сфере чем больше словарь, тем меньше завышение CBOW на словах (T^4 : $9,2 \rightarrow 8,3 \rightarrow 8,1 \rightarrow 7,7 \rightarrow 6,6$ при $V = 1000 \rightarrow 20\,000$; T^6 : $12,7 \rightarrow 9,5$). На биграммах обратная, но слабая тенденция (T^4 $6,7 \rightarrow 7,2$). Для Лоренца, наоборот, слова растут с V ($3,7 \rightarrow 4,2$). (б) **Число траекторий** (длина корпуса при $V = 5000$) влияет слабо: T^4 $7,4 \rightarrow 8,7$ при $100 \rightarrow 2000$ траекториях, T^6 $10,0 \rightarrow 10,9$. (в) Эталон от V и числа траекторий почти не зависит. Практический смысл: при сравнении корпусов надо выравнивать размер словаря — это сильнее влияет на оценку, чем длина корпуса.

5. Вопрос 3: истинная размерность неизвестна — FNN, FNF и обратная модель

5.1. Ложные соседи по Малинецкому—Потапову

По книге Г. Г. Малинецкого и А. Б. Потапова «Современные проблемы нелинейной динамики» (2000, § 11.4.2 и § 13.3) ложные соседи бывают двух типов. **FNN** (false nearest neighbours) — точки, близкие в реконструкции, но далёкие на аттракторе, потому что окно реконструкции $w = (m - 1)\tau$ слишком мало; при росте m они исчезают, и по этому находят размерность вложения. **FNF** (false neighbours on folds, ложные соседи на складках) появляются, когда окно слишком велико: реконструкция складывается, и на масштабах больше ε_{fr} снова возникают ложные соседи. Для малых размерностей есть «окно» хороших m , для больших оба типа сосуществуют. Слепой признак FNF — рост наклона корреляционного интеграла с m .

Что я считаю для каждого объекта: (1) классическое вложение с задержкой по одной координате траектории, $k = 1 \dots 20$; (2) то же для текста — k подряд идущих слов (k -граммы), векторы слов = центры ячеек или CBOW $d = 15 / 30$. Для каждого k : доля FNN (критерий Кеннела, $Rtol\ 2/5/10/15$ и $Atol\ 2$), критерии Цао $E1$ и $E2$, наклон корреляционного интеграла на масштабах $C = 10^{-3}, 10^{-2}, 10^{-1}$ и — поскольку в калибровке исходные состояния известны — прямая доля ложных соседей (сосед по реконструкции в исходном пространстве в 3 раза дальше настоящего ближайшего соседа).




Рис. 2. Классическое вложение с задержкой. Слева — FNN по Кеннелу, в центре — доля соседей, ложных в исходном пространстве (FNN + FNF), справа — наклон корреляционного интеграла на малом масштабе.

Вывод по рис. 2. FNN по Кеннелу у всех объектов падает до нуля к $k = 3-7$, в том числе у броуновского T^6 — критерий Кеннела не отличает шум от динамики. Прямая проверка это показывает: у Лоренца доля ложных соседей минимальна при $k = 3-4$ (14 %) и потом растёт до 43 % при $k = 12$ — это FNF, ровно как в книге; у Рёсслера ложных почти нет (1-2 %) при любом $k \geq 3$; у Лоренца-96 $N = 10$ минимум 60 % — FNN и FNF сосуществуют, как Малинецкий и Потапов предсказывают для аттракторов большой размерности; у броуновского тора ложные ≈ 90 % при любом k . Наклон корреляционного интеграла насыщается у Лоренца (2,0) и Рёсслера (1,8) и растёт линейно у Лоренца-96 и у тора. Критерий Цао E2 отличает детерминированные потоки ($E2 = 0,02-0,25$ при $k = 2-3$) от броуновских ($E2 \approx 1$ при любом k).




Рис. 3. Тот же приём для текста: облако из k подряд идущих слов. Слева — слова как центры ячеек, справа — векторы CBOW $d = 30$. Наклон корреляционного интеграла на масштабе $C = 0,01$.

Вывод по рис. 3. Для текста работает аналог теоремы Такенса. Если слова — центры ячеек, у детерминированных потоков облако k -грамм насыщается сразу: наклон $\approx D$ при любом k (Лоренц 2,1, Рёсслер 1,7, Лоренц-96 3,5 $\rightarrow$ 3,9 и 4,4 $\rightarrow$ 5,6). У броуновского T^6 наклон растёт на $\approx 2-4$ с каждым словом — каждое следующее слово добавляет новые случайные измерения. С CBOW картина та же, но со сдвигом вверх: потоки дают постоянные 6-7 (Лоренц-96 $N = 10$ медленно растёт 7,4 $\rightarrow$ 10,7), T^6 растёт 8,6 $\rightarrow$ 26. Значит, по поведению k -грамм можно отличить «динамический» текст от «случайного блуждания» без знания ответа.

5.2. Обратная модель: из оценок — в размерность

Строю модель вида $\log m = a + b \cdot \log(\text{оценка})$ по всем объектам, кроме одного, и предсказываю оставшийся (leave-one-out). Объекты делю на две группы по слепому признаку — критерию Цао E2 при $k = 2$ для CBOW-слов (порог 0,9): в одной броуновские торы, сферы и мультифрактал ($E2 \approx 1$), в другой потоки и блуждания по фракталам ($E2 = 0,6-0,9$). Для каждой группы — своя кривая.




Рис. 4. Размерность, восстановленная вслепую по CBOW-биграммам TwoNN $d = 30$ (leave-one-out), против истинной.

признак	медианная ошибка	максимальная
TwoNN слова $d=30$	13 %	39 %
TwoNN биграммы $d=30$	14 %	39 %
Hidalgo биграммы $d=30$	16 %	37 %
TwoNN биграммы $d=15$	15 %	40 %
без деления на группы (TwoNN слова $d=30$)	15 %	51 %

Вывод. Абсолютные значения CBOW смещены, но смещение систематическое, поэтому по калибровочной кривой размерность восстанавливается с медианной ошибкой 13–16 %. Хуже всего — малые фракталы (CBOW их не различает) и T^{12} (биграммы насыщаются). Предупреждение: калибровка годится для текстов, похожих на калибровочные (одинаковые V , длина корпуса, CBOW 30 эпох).

Что это даёт для диалогов (отчёт по фреймам, 4 октября). Там CBOW-биграммы TwoNN $d = 30 \approx 8,7-9,5$, слова $\approx 14-16$ без плато. Если текст диалогов ведёт себя как «броуновская» группа, калибровка даёт $m \approx 6-7$ по биграммам и $\approx 8-9$ по словам; для «детерминированной» группы кривая уходит за пределы калибровки ($m > 7$) и не применима. Чтобы решить, к какой группе относится язык диалогов, нужно посчитать для них E2 и поведение k -грамм — это следующий шаг. Кроме того, у диалогов другой словарь (≈ 6000 лемм) и другое распределение частот, так что это ориентир, а не измерение.

6. Итог: кому и как верить

- **Сравнивать объекты** — по CBOW + TwoNN / Hidalgo / Швайнхарт на плато ($d = 15-50$): порядок по размерности сохраняется до $m \approx 8$ и для потоков. Для $m \geq 10$ нужно $d \geq 50$.
- **Абсолютное значение** — только через калибровочную кривую (ошибка $\approx 15\%$), и после проверки, к какой группе относится текст (E2 / поведение k-грамм).
- **Малые и фрактальные размерности ($D \leq 3$)** CBOW не различает; для них нужен Швайнхарт на исходных координатах — в языке недоступных — или другой эмбединг.
- **SVD и FisherS** — не использовать (растут с d / завышают уже на эталоне).
- **Размер словаря** влияет на оценку сильнее длины корпуса — сравнивать корпуса при одинаковом V .
- **FNN по Кеннелу** сам по себе не отличает шум от динамики; нужны E2 и наклон корреляционного интеграла (признак FNF).

Приложение. Воспроизводимость

Код `calib2.py` (задачи 4377311, 4377944; 0-20 — часть A, 21-28 — часть B), сводка `calib2_agg.py` → `calib2_table.csv` (облака), `calib2_aux.json` (мета, FNN/FNF/Цао). Отчёт и рисунки — `calib2_report.py`. Литература: Малинецкий Г. Г., Потапов А. Б. Современные проблемы нелинейной динамики. М.: Эдиториал УРСС, 2000, § 11.3–11.4, 13.3; Kennel M. B. et al., 1992; Cao L., 1997.