

Калибровка на траекториях: объекты известной размерности

Предложение В. А. Громова: текст = траектория по «смысловому» объекту, слова = ячейки разбиения. Тор, сфера, аттрактор Лоренца → тексты → SVD / CBOW → четыре оценщика. Задача HSE 4370967, октябрь 2026.

Главное. (1) **CBOW + Швайнхарт / TwoNN / Hidalgo** дают плато по d ($10 \rightarrow 15 \rightarrow 30$) для объектов с $m \leq 6$ и правильно упорядочивают объекты по m , но на **словах** завышают: Швайнхарт $\approx 1,2-1,9 \cdot m$, TwoNN и Hidalgo $\approx 1,5-2,5 \cdot m$. (2) На **биграммах** CBOW + TwoNN / Hidalgo при $d = 15-30$ совпадают с эталоном биграмм с точностью $\sim 10\%$ для $m = 4-10$. (3) **SVD** ни с одним оценщиком плато не даёт: оценка растёт вместе с d . (4) **FisherS** ошибается уже на эталоне (торы $\approx 1,6 \cdot m$, сферы $\approx m + 1$). (5) **k-means** ломает эталон для TwoNN / Hidalgo (центры почти решётка: $T^2 \rightarrow 7,5$); случайное разбиение и муравьиный алгоритм (асо) дают почти одинаковые результаты. (6) Для $m = 8-10$ плато нет даже у CBOW, а эталон на 5000 центрах сам завышен ($T^{10} \rightarrow 12-14$). Вывод для «кому верить»: на словах доверять *порядку* оценок CBOW + Швайнхарт / TwoNN, а не их абсолютному значению; абсолютное значение надёжнее на биграммах. В отличие от псевдоязыка (смещение $+0,2 \dots 0,9$) здесь смещение на словах большое — причина пока не установлена (гипотезы в разделе 7).

Что ещё считается. Тор T^6 с разбиением асо (подзадача 4370967_22, ~ 15 ч на момент отчёта): готовы эталон и SVD $d = 5, 10$ (слова и биграммы), $d = 15$ (слова); остальные клетки в таблицах помечены «идёт».

1. Постановка и методы

1.1. Объекты

- **Торы T^m** , $m = 2, 4, 6, 8, 10$: произведение m окружностей, вложено в R^{2m} ($\cos \theta_i, \sin \theta_i$) / $\sqrt{m}$ — плоский тор, кривизны нет, но ambient-размерность вдвое больше m .
- **Сферы S^m** , $m = 2, 4, 6, 8$: единичная сфера в R^{m+1} — искривлённый объект, ambient-размерность $m + 1$.
- **Аттрактор Лоренца** ($\sigma = 10, r = 28, b = 8/3$): фрактал, корреляционная размерность $\approx 2,05$, клеточная $\approx 2,06$; траектории интегрируются методом Рунге-Кутты ($dt = 0,005$, прогрев 2000 шагов), координаты нормированы.

1.2. Тексты

На каждом объекте запускается 500 траекторий по 1500 шагов. На торах и сферах — броуновское блуждание: шаг — гауссовский с $\sigma = c \cdot V^{-1/m}$ ($c = \pi$ для углов тора, 1 для сферы; $V = 5000$), т. е. за один шаг траектория сдвигается примерно на размер одной ячейки. Каждая траектория = документ.

Объект разбивается на **V = 5000 ячеек** (ячейка = «слово») тремя способами — центры ячеек:

- **случайное** (random): 5000 случайных точек траекторий; ячейка = область Вороного вокруг центра. Основной вариант.
- **k-means**: MiniBatchKMeans по 150 000 точкам. Даёт почти равномерную решётку центров.
- **асо** (муравьиный алгоритм): 4 «муравья» × 10 итераций выбирают 5000 центров из 50 000 кандидатов с вероятностью $\propto$ феромону, феромон усиливается на лучшем наборе (минимальное среднее расстояние до ближайшего центра).

Траектория переписывается номерами ближайших центров; подряд идущие одинаковые номера схлопываются (стоять в ячейке = одно слово); документ режется на предложения по 20 слов. Получается ~500 документов, корпус в сотни тысяч словоупотреблений; биграммы — все пары соседних слов в предложениях.

1.3. Эмбединги

- **Эталон**: сами центры ячеек в координатах объекта (R^{2m} для тора, R^{m+1} для сферы, R^3 для Лоренца). Это то, что можно было бы получить при идеальном эмбединге. Биграмма эталона = конкатенация координат двух центров.
- **SVD (энтропийно взвешенная матрица слово × документ, строки U без S)**, как для «Войны и мира» и в предложении Громова: k_{ij} — число употреблений слова i в документе j , вес $(1 - \epsilon_i)$, где ϵ_i — нормированная энтропия распределения слова по документам; svds, первые d столбцов U .
- **CBOW (30 эпох, min_count 1, окно 5 — настройки «Войны и мира»)**: gensim Word2Vec, sg = 0, negative 5, seed 1; $d = 5, 10, 15, 30$.
- Векторы биграмм — конкатенация векторов двух слов (размерность $2d$).

Whitney: m -мерное многообразие гарантированно вкладывается без самопересечений в R^{2m} , поэтому при $d = 5$ корректно можно показать только $m \leq 2$, при $d = 10$ — $m \leq 5$, при $d = 15$ — $m \leq 7$, при $d = 30$ — $m \leq 15$. Отсюда колонка $d = 5$ почти везде упирается в потолок ≈ 4 .

1.4. Оценщики (те же, что для псевдоязыка и «Войны и мира»)

- **Швайнхарт**: длина минимального остовного дерева (персистентные гомологии H_0) на подвыборках растущего размера, $L \propto n^{(d-\alpha)/d}$; две «лестницы» подвыборок, все допустимые α ; в таблице — диапазон min-max. «нет α » — ни одно α не прошло проверку линейности.
- **TwoNN**: по отношению расстояний до 2-го и 1-го ближайшего соседа.
- **FisherS**: разделимость точек по Фишеру после центрирования и выбеливания (whitening).

- **Hidalgo**: байесовская смесь двух размерностей по тем же отношениям соседей; в таблице — обе компоненты min/max.
- До 10 000 точек на облако (для биграмм — случайная подвыборка), Hidalgo — 5000 точек, 5000 итераций.

1.5. Как читать таблицы

Каждый раздел ниже — пара «метод ТДА + эмбединг». Строки — объекты (m — истинная размерность), «эталон» — оценка тем же методом по центрам ячеек случайного разбиения. Колонки $d = 5...30$ — случайное разбиение, справа — асо и k-means при $d = 15$ и 30 . Зелёная заливка — рабочий диапазон $d = 15-30$, в котором ищем плато. «Надёжность» понимаем так: (а) плато по d , (б) близость к m или к эталону, (в) правильный порядок объектов. Плато само по себе не доказывает правильность (оно показывает устойчивость), поэтому сравниваем и с m .

2. Эталон: облако центров ячеек

Прежде чем проверять эмбединги, проверяем сами оценщики на точках с известной размерностью. Ниже — слова (центры) для трёх разбиений.

объект	m	Швайнхарт случ.	TwoNN случ.	FisherS случ.	Hidalgo случ.	Швайнхарт k-means	TwoNN k-means	TwoNN асо
T^2	2	2,0-2,1	2,0	3,5	1,9/2,0	1,9-1,9	7,5	2,0
S^2	2	1,9-2,1	2,0	3,0	2,0/2,1	нет α	6,8	2,0
Лоренц	2,06	2,0-2,1	2,0	1,9	1,9/2,1	нет α	7,3	2,0
T^4	4	4,1-4,4	4,1	6,4	4,0/4,1	нет α	10,8	4,1
S^4	4	3,9-4,1	3,9	5,0	3,9/3,9	нет α	10,8	4,1
T^6	6	6,5-6,8	6,3	9,4	5,9/6,5	10,0-12,1	13,9	6,5
S^6	6	5,7-6,2	5,9	7,0	5,8/5,8	9,7-10,4	13,1	6,1
T^8	8	9,6-10,1	8,4	12,3	8,1/8,7	13,6-16,6	17,2	8,7
S^8	8	7,3-8,1	7,8	9,0	7,7/7,8	11,1-13,9	15,1	7,5
T^{10}	10	12,6-14,2	11,9	16,4	10,9/12,6	16,9-21,6	19,9	11,8

- Случайное разбиение + Швайнхарт / TwoNN / Hidalgo: точно для $m \leq 6$ (ошибка $\leq 0,5$), для T^8 разброс 8,1-10,1, для T^{10} — 10,9-14,2: 5000 точек мало для $m = 10$ (нужно экспоненциально много), это предел самих данных.
- **FisherS** ошибается уже здесь: торы $\approx 1,6 \cdot m$ (T^2 3,5, T^4 6,4, T^6 9,4, T^{10} 16,4), сферы $\approx m + 1$ (2,97; 5,0; 7,0; 9,0) — то есть FisherS видит размерность объемлющего пространства / кривизну, а не m .
- **k-means**: центры почти равноудалены, отношение расстояний до 2-го и 1-го соседа ≈ 1 у всех точек, и TwoNN / Hidalgo резко завышают (T^2 7,5, Лоренц 7,3, S^4 10,8). Швайнхарт на k-means часто не находит допустимых α . Поэтому k-means — не эталонный вариант разбиения.
- **асо** $\approx$ случайное разбиение (T^2 2,0, T^6 6,5, S^8 7,6).

Эталон биграмм центров при случайном разбиении — примерно $1,3-1,5 \cdot m$ (T^2 2,9, T^4 5,8-6,5, T^6 9,4-10,4): биграмма — это точка плюс направление шага, и её облако по построению больше m . Поэтому биграммы ниже сравниваем с эталоном биграмм, а не с m .




Рис. 1. Оценка по словам против истинной m (случайное разбиение, $d = 30$). Серые кружки — эталон (центры ячеек), синие — CBOW, оранжевые — SVD. Пунктир — оценка = m , точки — оценка = $2m$.




Рис. 2. TwoNN по словам в зависимости от d : CBOW (случайное разбиение) выходит на плато при $m \leq 6$, SVD растёт с d , CBOW на k-means — плато выше.

3. Швайнхарт + CBOW

Эмбединг: CBOW (30 эпох, min_count 1, окно 5 — настройки «Войны и мира»).

слова

объект	m	эталон	случ. d=5	случ. d=10	случ. d=15	случ. d=30	асо d=15	асо d=30	k-mean s d=15	k-mean s d=30
T ²	2	2,0-2,1	3,8-4,0	3,6-3,8	3,5-3,8	3,4-3,6	3,5-3,7	3,4-3,6	нет α	нет α
S ²	2	1,9-2,1	4,0-4,2	3,9-4,2	3,7-4,0	3,3-3,7	3,5-4,0	3,4-3,7	нет α	3,1-3,5
Лоренц	2,06	2,0-2,1	3,6-4,2	3,7-4,1	3,8-4,0	3,7-4,2	3,8-4,0	3,9-4,1	3,3-3,4	3,3-3,5
T ⁴	4	4,1-4,4	3,8-4,3	5,9-6,3	5,9-6,5	нет α	6,1-7,0	6,5-7,1	7,5-7,5	нет α
S ⁴	4	3,9-4,1	4,0-4,2	5,7-6,1	6,0-6,4	6,7-6,7	6,0-6,5	6,2-6,8	нет α	нет α
T ⁶	6	6,5-6,8	4,0-4,3	7,8-9,1	8,8-10,1	9,0-9,8	идёт	идёт	10,4-12,0	11,8-13,6
S ⁶	6	5,7-6,2	4,0-4,3	7,5-8,3	7,9-9,5	8,3-9,9	7,8-8,8	8,6-9,6	9,5-10,8	10,8-12,3
T ⁸	8	9,6-10,1	4,1-4,5	8,2-9,1	10,8-12,3	13,1-15,6	10,9-13,0	12,7-14,7	12,1-14,4	15,2-18,9
S ⁸	8	7,3-8,1	4,0-4,2	9,1-10,4	9,6-11,7	9,9-11,3	9,9-11,3	10,4-11,9	12,7-13,0	11,6-14,2
T ¹⁰	10	12,6-14,2	4,0-4,4	8,3-9,6	11,4-13,3	16,9-20,2	12,4-14,1	17,3-19,9	11,5-13,3	18,7-23,6

биграммы, случайное разбиение

объект	m	эталон: биграммы центров	случ. d=5	случ. d=10	случ. d=15	случ. d=30
T ²	2	2,9-3,0	5,1-5,8	4,1-4,8	4,1-4,5	4,1-4,2
S ²	2	2,8-2,9	5,1-5,7	4,3-5,0	4,0-4,3	3,9-4,0
Лоренц	2,06	2,6-2,7	4,1-4,8	3,9-4,4	4,0-4,5	4,0-4,6
T ⁴	4	6,5-7,2	6,3-6,9	7,3-7,9	7,6-8,2	7,7-8,2
S ⁴	4	5,8-6,4	6,3-6,6	7,2-7,7	7,3-7,8	7,4-8,0
T ⁶	6	10,4-11,7	7,2-7,8	10,7-12,6	11,4-12,5	11,8-12,7
S ⁶	6	8,9-9,6	6,8-7,1	9,6-10,4	9,9-10,7	10,1-11,0
T ⁸	8	14,7-15,7	7,2-7,6	12,7-13,5	14,9-16,1	15,1-16,4
S ⁸	8	11,8-12,5	7,0-7,9	11,9-12,8	12,2-13,3	12,8-13,7
T ¹⁰	10	16,8-18,1	7,6-8,1	13,4-14,7	16,1-17,6	нет α

Вывод. Плато по d есть для $m \leq 6$ и для S^8 : от $d = 10-15$ до 30 оценка меняется на 0,1-1. Но оценка завышена: двумерные объекты (T², S², Лоренц) дают 3,3-3,9 вместо 2, четырёхмерные — 5,9-6,7, шестимерные — 7,5-9,0. Порядок объектов по m сохраняется, т. е. метод **ранжирует** правильно, но абсолютное значение надо пересчитывать по калибровочной кривой. Для T⁸ и T¹⁰ плато нет (10,8 → 13,1 и 11,4 → 16,9). На биграммах — заметно лучше: при $m \geq 4$ CBOW $d = 15-30$ попадает в эталон биграмм с точностью ~10-15 %. асо ≈ случайному разбиению; k-means часто не даёт допустимых α (решётка центров).

4. Швайнхарт + SVD

Эмбединг: SVD (энтропийно взвешенная матрица слово × документ, строки U без S).

слова

объект	m	эталон	случ. d=5	случ. d=10	случ. d=15	случ. d=30	асо d=15	асо d=30	k-mean s d=15	k-mean s d=30
T ²	2	2,0-2,1	3,2-3,4	3,5-3,8	3,6-4,1	3,9-4,6	3,6-4,1	3,9-4,7	3,5-4,0	3,9-4,3
S ²	2	1,9-2,1	2,7-3,0	3,0-3,2	3,0-3,3	3,3-3,6	3,1-3,3	3,2-3,6	3,0-3,3	3,2-3,6
Лоренц	2,06	2,0-2,1	3,2-4,0	3,9-4,5	4,3-5,0	4,8-5,6	4,4-5,1	5,0-6,0	3,6-4,1	4,0-4,4
T ⁴	4	4,1-4,4	4,6-4,9	8,3-9,5	11,1-12,6	15,7-19,9	10,4-12,1	14,8-18,4	10,0-12,1	13,8-18,9
S ⁴	4	3,9-4,1	4,5-5,0	7,6-8,7	9,8-11,2	12,9-15,8	9,8-10,6	13,4-15,3	9,3-10,3	12,2-14,7
T ⁶	6	6,5-6,8	4,5-5,0	8,7-9,8	13,1-15,1	нет α	12,1-13,4	идёт	11,8-14,9	22,0-24,4
S ⁶	6	5,7-6,2	4,5-4,9	9,1-9,8	11,7-13,5	20,7-25,1	12,7-14,5	22,3-25,2	12,5-14,1	21,2-25,9
T ⁸	8	9,6-10,1	4,3-5,0	8,6-11,1	12,7-15,5	24,1-27,4	12,6-15,3	20,5-23,3	12,6-14,1	20,7-24,0
S ⁸	8	7,3-8,1	4,4-4,7	8,9-10,0	14,0-16,2	23,9-26,6	13,0-13,9	21,7-27,6	13,1-14,9	21,2-24,4
T ¹⁰	10	12,6-14,2	4,4-4,8	9,1-10,8	13,4-15,1	25,1-28,1	12,8-15,1	21,9-24,3	12,3-13,8	20,4-25,1

биграммы, случайное разбиение

объект	m	эталон: биграммы центров	случ. d=5	случ. d=10	случ. d=15	случ. d=30
T ²	2	2,9-3,0	4,0-4,3	4,2-4,6	4,5-4,8	4,7-5,1
S ²	2	2,8-2,9	3,7-3,9	3,9-4,1	4,0-4,2	4,2-4,3
Лоренц	2,06	2,6-2,7	4,7-6,2	5,4-6,5	5,9-7,0	7,3-8,3
T ⁴	4	6,5-7,2	7,5-7,8	10,1-10,8	нет α	нет α
S ⁴	4	5,8-6,4	7,0-7,4	8,8-9,6	9,4-10,1	нет α
T ⁶	6	10,4-11,7	7,5-9,0	13,8-14,6	16,2-17,0	нет α
S ⁶	6	8,9-9,6	7,5-7,9	12,1-12,9	14,5-15,4	нет α
T ⁸	8	14,7-15,7	7,8-8,9	13,7-15,3	16,4-18,7	нет α
S ⁸	8	11,8-12,5	7,7-8,7	13,2-15,8	16,0-18,6	нет α
T ¹⁰	10	16,8-18,1	7,9-9,3	14,2-16,3	17,6-18,0	нет α

Вывод. Плато нет: оценка растёт с d у всех объектов с $m \geq 4$ (T⁴: 4,6 → 8,3 → 11,1 → 15,7). Для двумерных объектов рост медленный, но тоже есть (Лоренц 3,2 → 4,8). Как и на псевдоязыке, SVD без весов S делает все направления равными, и оценка следует за d, а не за m. **Не использовать.**

5. TwoNN + CBOW

Эмбединг: CBOW (30 эпох, min_count 1, окно 5 — настройки «Войны и мира»).

слова

объект	m	эталон	случ. d=5	случ. d=10	случ. d=15	случ. d=30	асо d=15	асо d=30	k-means d=15	k-means d=30
T ²	2	2,0	4,0	4,6	4,9	5,0	4,7	5,0	6,6	6,9
S ²	2	2,0	4,1	4,7	4,8	4,8	4,9	5,1	6,2	6,4
Лоренц	2,0 6	2,0	3,6	3,6	3,9	4,0	3,9	4,0	3,9	3,9
T ⁴	4	4,1	4,0	7,6	8,1	8,5	8,3	8,8	10,4	11,0
S ⁴	4	3,9	4,0	7,7	7,9	8,3	8,0	8,3	10,2	10,9
T ⁶	6	6,3	4,0	8,5	10,7	11,5	идёт	идёт	14,1	14,8
S ⁶	6	5,9	4,0	9,4	9,7	10,6	9,8	10,7	12,9	13,9
T ⁸	8	8,4	4,1	8,6	12,5	14,5	12,0	14,3	13,7	18,2
S ⁸	8	7,8	4,0	11,0	11,8	12,8	11,7	12,8	14,8	15,8
T ¹⁰	10	11,9	4,0	8,8	12,4	18,7	12,7	19,6	12,6	21,4

биграммы, случайное разбиение

объект	m	эталон: биграммы центров	случ. d=5	случ. d=10	случ. d=15	случ. d=30
T ²	2	2,8	4,4	4,0	4,1	4,1
S ²	2	2,6	4,6	4,1	4,0	4,1
Лоренц	2,0 6	2,4	3,1	3,1	3,2	3,4
T ⁴	4	5,8	6,3	6,5	6,8	6,9
S ⁴	4	5,4	6,0	6,4	6,5	6,6
T ⁶	6	9,4	7,1	9,7	9,8	9,8
S ⁶	6	8,0	6,7	8,6	9,0	8,9
T ⁸	8	12,3	7,2	11,9	12,3	12,2
S ⁸	8	10,4	7,1	10,7	10,6	10,7
T ¹⁰	10	13,8	7,5	12,2	13,2	13,0

Вывод. Плато для $m \leq 6$ (T⁴ 7,6 / 8,1 / 8,5 при d = 10 / 15 / 30), но смещение больше, чем у Швайнхарта: примерно 2m (T² ≈ 4,9, T⁴ ≈ 8,1, S⁶ ≈ 9,7). Лоренц — исключение: 3,6–4,0. Для m = 8–10 плато нет. На биграммах TwoNN + CBOW — лучшая пара этой калибровки: при d = 15 T⁴ 6,8 (эталон 5,8), T⁶ 9,8 (9,4), S⁶ 9,0 (8,0), T⁸ 12,3 (12,3), S⁸ 10,6 (10,4), T¹⁰ 13,2 (13,8), и от d = 10 до 30 почти не меняется. На k-means TwoNN завышает ещё сильнее — потому что ломается уже эталон.

6. TwoNN + SVD

Эмбединг: SVD (энтропийно взвешенная матрица слово × документ, строки U без S).

слова

объект	m	эталон	случ. d=5	случ. d=10	случ. d=15	случ. d=30	асо d=15	асо d=30	k-means d=15	k-means d=30
T ²	2	2,0	3,6	4,4	5,0	5,4	4,8	5,5	4,8	5,5
S ²	2	2,0	3,0	3,3	3,6	4,2	3,7	3,9	3,8	4,2
Лоренц	2,0 6	2,0	4,3	5,4	5,9	6,9	5,7	6,7	5,6	6,0
T ⁴	4	4,1	4,9	8,6	11,9	17,4	11,9	17,6	11,8	17,6
S ⁴	4	3,9	4,8	8,3	10,8	15,1	10,6	14,7	10,5	14,9
T ⁶	6	6,3	4,7	9,0	13,2	23,2	12,8	идёт	13,0	23,0
S ⁶	6	5,9	4,7	9,2	12,8	22,5	12,7	23,1	13,0	22,9
T ⁸	8	8,4	4,5	9,1	13,5	23,8	13,8	23,0	13,1	22,6
S ⁸	8	7,8	4,6	8,9	13,0	23,4	13,5	23,1	13,3	23,9
T ¹⁰	10	11,9	4,3	8,9	13,1	23,4	13,3	22,6	13,0	23,1

биграммы, случайное разбиение

объект	m	эталон: биграммы центров	случ. d=5	случ. d=10	случ. d=15	случ. d=30
T ²	2	2,8	3,7	3,9	4,1	4,3
S ²	2	2,6	3,2	3,4	3,5	3,7
Лоренц	2,0 6	2,4	5,9	6,5	6,9	8,2
T ⁴	4	5,8	7,0	7,8	8,0	8,7
S ⁴	4	5,4	6,5	7,3	7,6	8,1
T ⁶	6	9,4	7,4	11,7	11,9	11,2
S ⁶	6	8,0	7,3	10,3	10,6	10,8
T ⁸	8	12,3	7,5	12,2	13,2	11,7
S ⁸	8	10,4	7,5	11,8	12,6	11,4
T ¹⁰	10	13,8	7,4	12,8	13,0	11,9

Вывод. Растёт с d почти линейно: при d = 30 для любого m ≥ 4 получается 15-23 — то есть оценка близка к d, а не к m. **Не использовать.**

7. FisherS + CBOW

Эмбединг: CBOW (30 эпох, min_count 1, окно 5 — настройки «Войны и мира»).

слова

объект	m	эталон	случ. d=5	случ. d=10	случ. d=15	случ. d=30	асо d=15	асо d=30	k-means d=15	k-means d=30
T ²	2	3,5	4,0	7,4	7,8	7,8	7,7	7,8	7,3	7,5
S ²	2	3,0	4,0	7,8	8,1	8,2	8,1	8,2	8,1	8,1
Лоренц	2,06	1,9	4,0	6,6	7,6	7,8	7,7	7,8	7,3	7,6
T ⁴	4	6,4	4,0	6,8	7,9	9,1	7,9	9,0	8,1	9,3
S ⁴	4	5,0	4,0	6,9	7,7	8,5	7,6	8,5	7,8	8,9
T ⁶	6	9,4	4,0	8,7	10,7	10,7	идёт	идёт	11,6	11,3
S ⁶	6	7,0	4,0	7,8	9,2	10,6	9,2	10,8	9,4	11,1
T ⁸	8	12,3	4,0	9,0	13,8	15,4	13,7	15,4	14,4	17,2
S ⁸	8	9,0	4,0	9,8	9,8	9,6	9,6	9,6	9,9	9,9
T ¹⁰	10	16,4	4,0	8,9	13,9	28,2	13,9	29,1	13,9	29,2

биграммы, случайное разбиение

объект	m	эталон: биграммы центров	случ. d=5	случ. d=10	случ. d=15	случ. d=30
T ²	2	3,4	4,0	6,6	6,9	7,8
S ²	2	3,0	4,0	7,0	7,7	8,1
Лоренц	2,06	1,9	4,0	6,4	8,1	8,7
T ⁴	4	6,4	5,9	10,6	10,8	10,6
S ⁴	4	5,0	4,0	6,7	8,1	10,7
T ⁶	6	16,0	7,9	15,6	17,1	17,2
S ⁶	6	12,9	7,9	13,5	14,0	13,8
T ⁸	8	19,6	8,0	15,5	19,8	20,7
S ⁸	8	16,2	7,9	15,9	16,7	16,0
T ¹⁰	10	22,5	8,0	15,6	19,7	26,8

Вывод. Неинформативно: на двумерных объектах 7–8 (при $d \geq 10$), на T¹⁰ при $d = 30$ — 28. Причина та же, что на псевдоязыке: FisherS «выбеливает» облако (выравнивает дисперсии по осям), а в CBOW-векторах шумовые направления имеют сопоставимую дисперсию — после выбеливания они становятся полноправными измерениями. Кроме того, FisherS ошибается уже на эталоне (см. раздел 2). **Не использовать.**

8. FisherS + SVD

Эмбединг: SVD (энтропийно взвешенная матрица слово × документ, строки U без S).

слова

объект	m	эталон	случ. d=5	случ. d=10	случ. d=15	случ. d=30	асо d=15	асо d=30	k-means d=15	k-means d=30
T ²	2	3,5	4,2	4,7	5,2	6,0	4,5	5,5	4,5	5,6
S ²	2	3,0	3,7	4,2	4,1	5,0	4,1	5,0	4,2	5,0
Лоренц	2,06	1,9	2,6	4,5	5,4	7,5	5,4	7,4	5,1	6,7
T ⁴	4	6,4	4,0	8,4	11,9	19,6	11,8	19,3	11,8	19,6
S ⁴	4	5,0	4,0	7,3	9,8	15,6	9,8	15,8	9,7	15,7
T ⁶	6	9,4	4,0	9,0	14,0	29,3	14,0	идёт	14,0	29,3
S ⁶	6	7,0	4,0	8,9	13,8	28,0	13,8	28,2	13,8	28,7
T ⁸	8	12,3	4,0	9,0	14,1	29,3	14,1	28,7	14,1	29,0
S ⁸	8	9,0	4,0	9,0	14,0	28,6	14,1	29,4	14,1	28,9
T ¹⁰	10	16,4	4,0	9,0	14,0	29,4	14,1	28,5	14,0	29,2

биграммы, случайное разбиение

объект	m	эталон: биграммы центров	случ. d=5	случ. d=10	случ. d=15	случ. d=30
T ²	2	3,4	3,4	3,9	4,4	5,6
S ²	2	3,0	2,9	3,5	4,1	4,9
Лоренц	2,06	1,9	4,4	7,3	8,3	10,8
T ⁴	4	6,4	7,9	13,1	15,8	19,0
S ⁴	4	5,0	7,8	12,6	14,6	17,7
T ⁶	6	16,0	8,0	15,1	18,5	23,7
S ⁶	6	12,9	7,9	14,6	18,0	23,8
T ⁸	8	19,6	8,0	14,9	18,9	25,2
S ⁸	8	16,2	8,0	15,1	18,6	23,9
T ¹⁰	10	22,5	8,0	15,4	18,4	25,3

Вывод. Растёт с d (T⁶: 4 → 9 → 14 → 29) — показывает d. **Не использовать.**

9. Hidalgo + CBOW

Эмбединг: CBOW (30 эпох, min_count 1, окно 5 — настройки «Войны и мира»).

слова

объект	m	эталон	случ. d=5	случ. d=10	случ. d=15	случ. d=30	асо d=15	асо d=30	k-mean s d=15	k-mean s d=30
T ²	2	1,9/2,0	3,9/4,0	4,5/4,7	4,8/4,9	5,0/5,0	4,7/4,9	4,9/5,1	6,7/6,8	7,1/7,1
S ²	2	2,0/2,1	4,1/4,2	4,5/5,0	4,8/4,9	4,9/5,0	4,9/5,0	5,0/5,1	6,2/6,5	6,5/6,8
Лоренц	2,0 6	1,9/2,1	3,6/3,8	3,7/3,8	3,9/4,1	4,0/4,1	3,9/4,1	3,9/4,3	3,8/4,3	3,9/4,2
T ⁴	4	4,0/4,1	3,9/4,1	7,6/7,7	8,2/8,2	8,4/8,8	8,3/8,3	8,7/9,1	10,5/10,6	11,0/11,6
S ⁴	4	3,9/3,9	3,9/4,0	7,7/7,8	7,8/8,2	8,4/8,5	7,9/8,2	8,2/8,6	10,3/10,4	10,8/11,5
T ⁶	6	5,9/6,5	3,9/4,2	8,5/8,6	10,7/10,7	11,4/11,6	идёт	идёт	14,1/14,3	14,9/15,2
S ⁶	6	5,8/5,8	3,9/4,1	9,3/9,7	9,7/9,9	10,6/11,1	9,8/9,9	10,6/11,1	12,9/13,3	13,9/14,1
T ⁸	8	8,1/8,7	4,0/4,2	8,5/8,7	12,3/12,7	14,3/14,8	11,8/12,1	13,7/15,0	13,7/13,8	18,2/18,5
S ⁸	8	7,7/7,8	4,0/4,1	10,6/11,5	11,7/12,0	12,4/13,1	11,7/11,9	12,5/13,1	14,6/15,2	15,6/16,5
T ¹⁰	10	10,9/12,6	3,9/4,1	8,8/8,8	12,1/12,7	18,1/19,4	12,5/12,9	19,3/19,6	12,5/12,6	21,1/22,0

биграммы, случайное разбиение

объект	m	эталон: биграммы центров	случ. d=5	случ. d=10	случ. d=15	случ. d=30
T ²	2	3,0/3,0	4,6/4,8	4,2/4,5	4,3/4,4	4,3/4,6
S ²	2	2,8/3,0	5,0/5,0	4,1/4,6	4,3/4,3	4,4/4,4
Лоренц	2,0 6	2,4/2,5	3,5/3,7	3,5/3,5	3,3/3,6	3,5/3,8
T ⁴	4	6,1/6,2	6,4/6,5	6,7/6,8	7,0/7,2	7,4/7,7
S ⁴	4	5,6/5,7	5,8/6,1	6,5/6,9	6,7/6,8	7,1/7,1
T ⁶	6	9,6/10,3	6,9/7,1	9,5/10,0	9,7/10,3	10,3/10,7
S ⁶	6	8,4/8,5	6,7/6,9	8,7/9,2	9,1/9,1	9,3/9,4
T ⁸	8	12,3/13,5	7,1/7,8	11,6/12,0	12,7/13,6	13,1/13,7
S ⁸	8	10,4/10,6	7,0/7,4	10,9/11,4	10,9/11,2	11,0/11,2
T ¹⁰	10	14,2/14,8	7,2/7,7	12,3/12,5	13,4/14,7	13,4/14,1

Вывод. Почти совпадает с TwoNN (это ожидаемо: оба метода работают с отношением расстояний до 1-го и 2-го соседей). Плато при $m \leq 6$, смещение $\approx 2m$ на словах; на биграммах близко к эталону (T⁶ 9,7 при эталоне 9,6, S⁸ 10,9 при 10,4). Разброс min/max между двумя компонентами смеси мал — признаков смеси размерностей нет.

10. Hidalgo + SVD

Эмбе́динг: SVD (энтропийно взвешенная матрица слово × документ, строки U без S).

слова

объект	m	эталон	случ. d=5	случ. d=10	случ. d=15	случ. d=30	асо d=15	асо d=30	k-mean s d=15	k-mean s d=30
T ²	2	1,9/2,0	3,5/3,8	4,4/4,5	4,9/5,1	5,4/5,6	4,8/4,9	5,3/6,0	5,0/5,0	5,5/5,9
S ²	2	2,0/2,1	2,9/3,1	3,2/3,5	3,4/3,8	4,2/4,2	3,5/3,9	3,9/4,1	3,8/3,9	4,2/4,3
Лоренц	2,0 6	1,9/2,1	4,2/4,4	5,3/5,4	5,8/5,9	6,5/7,3	5,7/5,7	6,5/6,7	5,4/5,8	5,9/6,3
T ⁴	4	4,0/4,1	4,8/5,1	8,7/8,7	11,8/12,0	17,2/17,8	11,6/12,3	17,5/17,9	11,8/12,1	17,5/17,6
S ⁴	4	3,9/3,9	4,8/4,9	8,1/8,3	10,7/11,1	14,9/15,8	10,3/11,0	14,8/15,0	10,3/10,7	14,9/15,0
T ⁶	6	5,9/6,5	4,8/4,8	9,0/9,0	12,9/13,3	22,7/23,7	12,7/13,1	идёт	12,5/13,8	22,0/23,8
S ⁶	6	5,8/5,8	4,5/4,8	9,3/9,3	12,5/12,9	21,5/23,2	12,0/13,4	22,5/23,3	12,9/13,2	22,3/23,4
T ⁸	8	8,1/8,7	4,3/4,7	8,9/9,3	13,1/13,8	22,6/24,4	13,6/13,8	22,3/23,5	12,8/13,4	22,4/22,6
S ⁸	8	7,7/7,8	4,6/4,7	8,8/9,2	12,8/13,1	22,9/23,6	13,4/13,8	22,6/23,9	12,5/13,9	23,4/23,9
T ¹⁰	10	10,9/12,6	4,2/4,4	8,8/9,1	13,2/13,2	22,7/23,8	13,1/13,3	21,7/23,3	12,3/13,4	22,7/23,4

бигра́ммы, случайное разбиение

объект	m	эталон: биграммы центров	случ. d=5	случ. d=10	случ. d=15	случ. d=30
T ²	2	3,0/3,0	3,7/3,9	4,1/4,1	4,2/4,4	4,4/4,6
S ²	2	2,8/3,0	3,2/3,3	3,4/3,6	3,4/3,8	3,8/3,9
Лоренц	2,0 6	2,4/2,5	5,1/6,3	6,1/6,1	6,3/6,8	7,2/8,2
T ⁴	4	6,1/6,2	6,8/7,4	8,2/8,6	8,7/9,2	8,9/9,0
S ⁴	4	5,6/5,7	6,5/6,7	8,0/8,0	8,4/8,4	8,4/8,7
T ⁶	6	9,6/10,3	7,4/7,5	11,9/12,4	12,9/13,0	11,4/12,4
S ⁶	6	8,4/8,5	6,9/7,5	10,3/10,6	10,5/12,7	10,6/11,6
T ⁸	8	12,3/13,5	7,4/7,7	12,4/13,6	13,2/14,0	10,7/14,4
S ⁸	8	10,4/10,6	7,1/7,6	11,9/12,5	10,7/16,6	10,2/14,0
T ¹⁰	10	14,2/14,8	7,0/7,4	12,4/13,2	13,3/15,0	12,0/14,1

Вывод. Как TwoNN + SVD: растёт с d. **Не использовать.**

11. Сводка: кому верить

пара	плато ($m \leq 6$)	слова: оценка / m	биграммы: оценка / эталон	вердикт
Швайнхарт + CBOW	да	1,2-1,9	1,0-1,5	порядок верный; абсолют — по калибровке
TwoNN + CBOW	да	1,5-2,5	1,0-1,2 ($m \geq 4$)	лучший на биграммах
Hidalgo + CBOW	да	1,5-2,5	1,0-1,2 ($m \geq 4$)	как TwoNN
FisherS + CBOW	нет	1,4-4	1,0-4	не использовать
любой + SVD	нет (растёт с d)	$\approx d/2 \dots d$	растёт с d	не использовать

Сравнение с псевдоязыком (облако 5000 точек в кубе без шаров, ерс-блуждание): там CBOW + Швайнхарт / TwoNN / Hidalgo на словах давали смещение всего +0,2...0,9 и плато на $d = 10-15$. Здесь та же пара даёт плато, но смещение на словах $\approx 1,2-2,5$ раза. Общие выводы совпадают: SVD и FisherS неприменимы, CBOW + Швайнхарт / TwoNN / Hidalgo — рабочие, k-means-подобные «решётчатые» словари опасны для TwoNN / Hidalgo.

12. Почему на траекториях слова завышены — гипотезы и что проверить

- **Длина шага.** $\sigma \approx$ размер ячейки, и схлопывание повторов делает соседние слова в предложении соседями по объекту лишь в среднем; окно CBOW = 5 охватывает ~ 5 шагов броуновского движения, т. е. область радиуса $\sim \sqrt{5}$ ячеек. В псевдоязыке шаг был равномерным внутри ϵ и слова — сами точки. Проверка: σ в 2 раза меньше и больше.
- **Гауссовский шаг против равномерного:** длинный хвост гауссовских шагов даёт «прыжки» — немного от dist-блуждания (отрицательного контроля псевдоязыка).
- **Размер корпуса:** 500 $\times$ ~ 1000 слов против 1000 текстов разной длины в псевдоязыке; на словах CBOW с min_count 1 видит редкие ячейки по несколько раз. Проверка: 2000 траекторий.
- **Ambient-размерность тора** ($2m$) — CBOW может частично восстанавливать вложение в R^{2m} , а не внутреннюю размерность. Против: на сферах ($m + 1$) смещение того же порядка.

Приложение. Воспроизводимость

Скрипт `calib_trajectories.py` ($V = 5000$, 500 траекторий $\times$ 1500 шагов, 2 лестницы, $\leq 10\,000$ точек, Hidalgo 5000 итераций), массив `9_calib_array.sbatch`: задача 4370967, 30 подзадач (10 объектов $\times$ 3 разбиения). Сводка `calib_agg.py` $\rightarrow$ `~/wap_run/calib_table.csv` (529 строк). На HSE: `~/wap_run/calib_results/<объект>_<разбиение>_<эмб>_d<d>_n<n>.json`; в репозитории LANC — `experiments/dimension/`.