

# Как измерить размерность облака точек

Четыре метода, которыми мы считали «Войну и мир»: Швайнхарт (дерево), TwoNN (два соседа), FisherS (отделимость) и Hidalgo (смесь). Объяснение на пальцах, с картинками и числами.

## 0. Что вообще такое размерность

Представь муравья. Если он живёт на **нитке**, он может ползти только вперёд или назад: одно направление, размерность 1. На **листе бумаги** можно ползти вперёд-назад и влево-вправо: размерность 2. Если муравей умеет летать в **комнате**, добавляется вверх-вниз: размерность 3.




Одни и те же точки могут жить на нитке, на листе или в объёме.


Важная тонкость: **внутренняя** размерность может быть меньше, чем пространство, в котором лежат точки. Поверхность мяча находится в трёхмерном мире, но муравей на мяче может ходить только в две стороны: его мир двумерный. Именно эту «внутреннюю» размерность и ищут все четыре метода.

Вторая тонкость: размерность бывает **дробной**. Ковёр Серпинского получается, если из квадрата много раз вырезать середину. Он «дырявее» листа (меньше 2), но гуще линии (больше 1). Его размерность  $\log 8 / \log 3 \approx 1,89$ . Такие объекты называют фракталами. Громов и соавторы считают, что язык устроен похоже, поэтому ожидают нецелые числа.

поверхность шара: живёт в 3D, но по ней можно ходить в 2 стороны



ковёр Серпинского: «дырявый лист», размерность 1,89



## Как слово становится точкой


Чтобы мерить размерность текста, каждое слово превращают в список чисел (вектор) — это его «адрес» в пространстве. Мы пробовали три способа получить адрес:

- **SVD** (как у Громова): считаем, в каких главах и как часто встречается слово, и сжимаем эту таблицу. Слова, живущие в одних и тех же главах, получают близкие адреса.
- **CBOW / word2vec** (второй способ Громова): маленькая нейросеть учится угадывать слово по соседям. Слова, которые встречаются в похожем окружении («граф» и «князь»), получают близкие адреса.
- **ruBERT**: большая языковая модель читает каждое предложение целиком, и адрес слова — среднее того, что модель «думает» о нём во всех местах романа.

Биграмма (пара соседних слов) — это просто два адреса, записанные подряд. Так мы получаем облако из 17 900 точек-слов или 152 568 точек-биграмм, и дальше спрашиваем: какой у этого облака размерность?

## 1. Метод Швайнхарта: растущее дерево

Идея: соединим все точки самой короткой возможной «сетью дорог» без петель — это **минимальное остовное дерево** (MST). Потом посмотрим, как быстро растёт его длина, если точек становится больше.



Минимальное дерево для 40 и 320 случайных точек на квадрате.


**Почему это связано с размерностью.** Когда точек в 8 раз больше, они стоят теснее, и каждая дорожка короче. Насколько короче — зависит от размерности:

- на **нитке** длиной 1 дерево — это сама нитка: сколько точек ни добавляй, длина остаётся 1;
- на **листе** соседние точки становятся ближе в  $\sqrt{8} \approx 2,8$  раза, но дорожек в 8 раз больше, поэтому общая длина растёт в  $8 / 2,8 \approx 2,8$  раза. На картинке выше:  $4,2 \rightarrow 12,0$ , то есть в 2,86 раза;
- в **комнате** точки сближаются только в  $\sqrt[3]{8} = 2$  раза, и длина растёт в  $8 / 2 = 4$  раза.

Общее правило (теорема Стила, обобщённая Швайнхартом): если точек  $n$ , то длина дерева растёт как

$$E(n) \approx C \cdot n^{1 - 1/d}$$

Если нарисовать график в логарифмах (ось  $n$  и ось  $E$ ), получится прямая с наклоном  $k = 1 - 1/d$ . Измеряем наклон — получаем размерность:  $d = 1 / (1 - k)$ .



Наш код на отрезке, квадрате и кубе: наклоны 0, 0,5 и 0,65 дают размерности 1,00, 1,98 и 2,89.

**Что такое  $\alpha$ .** Можно складывать не сами длины дорожек, а длины в степени  $\alpha$ :  $E_\alpha = \sum |\text{ребро}|^\alpha$ . Тогда наклон равен  $1 - \alpha/d$  и  $d = \alpha / (1 - k)$ . При маленьком  $\alpha$  все дорожки весят почти одинаково, при большом  $\alpha$  главными становятся самые длинные дорожки. Громов перебирает  $\alpha$  от 0,0001 до 10 с шагом 0,1.


**Фильтр 10%.** Для каждого  $\alpha$  получается своя оценка и её «вилка» (95%-й доверительный интервал). Если вилка шире 10% от самой оценки, такое  $\alpha$  выбрасывается. Итог — самое маленькое и самое большое из оставшихся чисел. Поэтому у Громова в таблицах диапазоны, например «4,65–5,52».

**Пример из жизни.** Сколько нужно верёвки, чтобы связать все дома в деревне? Если деревня вытянута вдоль дороги (1D), новые дома почти не добавляют верёвки. Если дома разбросаны по полю (2D), верёвки нужно заметно больше. По тому, как растёт расход верёвки, можно понять, какая это деревня.

**Сильные стороны:** работает с дробными размерностями, есть строгая теорема, это метод статьи Громова. **Слабые:** нужно очень много точек и точное дерево (у нас до 194 тыс. точек в 2304 измерениях считалось часами); при малом числе точек оценка «плывёт» с  $\alpha$ .

## 2. TwoNN: два ближайших соседа

Идея: для каждой точки найдём **первого** и **второго** ближайшего соседа и посмотрим на отношение расстояний  $\mu = r_2 / r_1$ . Больше ничего не нужно — поэтому метод называется «минимальная информация о соседях» (Фассо и соавторы, 2017).



Слева: одна точка, её первый и второй сосед. Справа: как распределено  $\mu$  в 1D, 2D и 5D.

**Почему это работает.** Представь, что ты стоишь в толпе и ищешь двух ближайших людей. На узкой тропинке (1D) второй человек часто стоит гораздо дальше первого — впереди или позади места мало. На площади (2D) вокруг тебя больше места, и второй сосед обычно ближе. В многомерном пространстве «вокруг» так много места, что второй сосед оказывается почти так же близко, как первый:  $\mu$  почти всегда чуть больше 1.

Математически: для точек, равномерно заполняющих  $d$ -мерную область, вероятность того, что  $\mu$  больше  $x$ , равна

$$P(\mu > x) = x^{-d}$$

**Считаем на пальцах.** Возьмём  $x = 2$  (второй сосед хотя бы вдвое дальше первого):

- в 1D таких точек  $1/2 = 50\%$ ;
- в 2D —  $1/4 = 25\%$ ;
- в 5D —  $1/32 \approx 3\%$ .

Обратная задача: если мы **посчитали**, что у 25% точек  $\mu > 2$ , то  $d = \log(1/0,25) / \log 2 = 2$ . Настоящий алгоритм делает то же самое для всех  $x$  сразу: строит график  $-\log(1 - F(\mu))$  против  $\log \mu$  и берёт наклон прямой через ноль. 10% самых больших  $\mu$  отбрасываются (это выбросы).

**Прореживание (decimation).** Авторы советуют повторить оценку на половине, четверти, восьмой части точек. Если число не меняется — ему можно верить. Если сильно меняется — облако устроено по-разному на разных масштабах. Мы это тоже считаем и храним в результатах.


**Сильные стороны:** очень быстрый, работает на сотнях тысяч точек, на наших фигурах почти не ошибается. **Слабые:** видит только самый маленький масштаб

(ближайших соседей); на смеси двух облаков выдаёт одно среднее число; ломается на одинаковых точках ( $r_1 = 0$ ), поэтому дубликаты мы убираем.

### 3. FisherS: можно ли отрезать точку одной плоскостью

Идея: в пространстве большой размерности почти каждую точку можно отделить от всех остальных одним прямым разрезом (линейно). Чем выше размерность, тем больше таких «одиноких» точек. Значит, по доле отделимых точек можно узнать размерность (Albergante, Vas, Zinovyev, 2019).

**Пример.** Встанем на круглой арене (2D) и попробуем провести прямую, которая отрежет одного человека от всех. Для тех, кто на краю, это легко, а для тех, кто в середине, невозможно. Теперь представь «арену» в 20 измерениях: там почти все стоят у края (это удивительное свойство больших размерностей, **концентрация меры**), и почти каждого можно отрезать.



Доля точек, которые можно отрезать одной плоскостью, резко растёт с размерностью.

#### Как именно считается.

- Облако центрируют, поворачивают на главные оси (PCA), оставляют оси, где разброс не меньше 1/10 от самого большого, выравнивают масштаб по осям и проецируют все точки на сферу радиуса 1.
- Точка **у мешает** отрезать точку **х**, если скалярное произведение  $\langle x, y \rangle \geq \alpha$  (у точек на единичной сфере это значит: у лежит в «шапочке» вокруг **х**). Параметр  $\alpha$  от 0,6 до 0,98 задаёт ширину шапочки.
- Считаем  $p_\alpha$  — среднюю долю таких «мешающих» точек.

Для идеальной  $n$ -мерной сферы есть формула

$$p_\alpha \approx (1 - \alpha^2)^{(n-1)/2} / (\alpha \cdot \sqrt{2\pi n})$$

**Считаем на пальцах** при  $\alpha = 0,8$  ( $1 - \alpha^2 = 0,36$ ): для  $n = 5$  получается  $p \approx 0,36^2 / (0,8 \cdot \sqrt{31,4}) \approx 0,029$  — каждой точке мешают около 3% соседей. Для  $n = 10$  уже  $p \approx 0,0016$  — мешает одна точка из шестисот. Мы измеряем  $p$  на своих данных и решаем

уравнение обратно относительно  $n$  (для этого нужна функция Ламберта  $W$ ). Итоговое число берут при  $\alpha$ , равном 0,9 от самого большого  $\alpha$ , где оценка ещё существует.

**Сильные стороны:** устойчив к шуму, хорошо работает в высоких размерностях.

**Слабые:** меряет «линейную» размерность, поэтому **завышает** её для изогнутых поверхностей: сфера  $S^6$  дала 7,0 вместо 6, Swiss roll — 2,9 вместо 2. На смеси двух облаков с разной размерностью вообще выдал 0,9. Поэтому его числа на «Войне и мире» мы читаем осторожнее всего.

## 4. Hidalgo: а вдруг в облаке несколько частей разной размерности

Идея: TwoNN предполагает, что всё облако одной размерности. А если половина точек лежит на плоскости, а половина в шестимерном кубе? Hidalgo (Allegra, Facco, Denti, Laio, Mira, 2020) считает, что точки бывают нескольких «пород», у каждой своя размерность, и одновременно угадывает, какая точка какой породы и какова размерность каждой породы.



У точек плоскости второй сосед обычно заметно дальше первого ( $\mu$  крупнее), у точек куба — ближе.

### Как он угадывает.

- У каждой точки есть своё  $\mu$  (как в TwoNN). Точки плоскости «тянут» к размерности 2, точки куба — к 6.
- Добавлено правило «**соседи обычно одной породы**»: с вероятностью  $\zeta = 0,8$  точка той же породы, что её три ближайших соседа. Без этого правила две породы с перекрывающимися  $\mu$  невозможно разделить.
- Дальше работает **выборка Гиббса**: игра «угадай и поправь». Сначала всем точкам случайно раздают породы. Потом 10 000 раз по кругу: (1) при нынешнем разбиении пересчитываем размерность каждой породы; (2) пересчитываем долю пород; (3) каждую точку заново спрашиваем, какой она породы, учитывая её  $\mu$  и её соседей. Первые 90% кругов — разминка, по последним 10% усредняем ответы.

**Пример из жизни.** В классе перемешались ученики двух школ, и нужно понять, кто откуда, не спрашивая. Известно, что у одной школы форма синяя, у другой красная, но оттенки похожи. Смотрим на цвет каждого и на то, с кем он сидит: друзья обычно из одной школы. Постепенно картинка проясняется.

**Что получилось на проверке:** на смеси «плоскость 2D + куб 6D» Hidalgo нашёл 2,06 и 5,70 — единственный из трёх новых методов, кто увидел обе части (TwoNN дал среднее 3,1, FisherS — 0,9). На однородных фигурах обе «породы» получают почти одинаковую размерность — это знак, что облако однородное.

**Сильные стороны:** находит неоднородность и говорит, какая доля точек в какой части. **Слабые:** медленный (мы берём 5 000 случайных точек), число пород K задаём сами (у нас  $K = 2$ ), в больших размерностях, как и TwoNN, склонен немного занижать.

**Находка на «Войне и мире».** Для SVD-векторов Hidalgo выделил часть с размерностью около 0,2–0,6, в которой 13–32% слов. Это редкие слова, которые встречаются только в одной главе: по формуле SVD их адреса лежат на 361 «луче» (по одному на главу), а луч — это почти одномерный объект. Мы нашли этот эффект раньше вручную, а Hidalgo подтвердил его сам.

## 5. Проверка на фигурах с известной размерностью

Прежде чем мерить роман, все методы проверили на суперкомпьютере HSE на фигурах, где правильный ответ известен: 20 000 точек (для Швайнхарта — 50 000), спрятанных в 15-мерное пространство случайным поворотом.

| фигура            | истина | Швайнхарт<br>(диапазон по $\alpha$ ) | TwoNN | FisherS | Hidalgo (2 породы) |
|-------------------|--------|--------------------------------------|-------|---------|--------------------|
| куб 5D            | 5      | 4,62–4,82                            | 4,80  | 4,81    | 4,73 / 4,77        |
| куб 8D            | 8      | 7,03–7,27                            | 7,38  | 7,56    | 7,13 / 7,19        |
| сфера $S^6$       | 6      | 5,91–5,95                            | 5,93  | 7,00    | 5,64 / 6,48        |
| ковёр Серпинского | 1,893  | 1,88–1,90                            | 1,88  | 1,94    | 1,83 / 1,87        |
| Swiss roll        | 2      | —                                    | 1,96  | 2,88    | 1,91 / 2,05        |
| смесь 2D + 6D     | 2 и 6  | —                                    | 3,11  | 0,92    | 2,06 / 5,70        |

Все методы немного **занижают** размерность кубов: у куба есть края и углы, возле них соседей меньше. Это известный эффект, и он растёт с размерностью.

## 6. Шпаргалка

| метод           | что меряет                                        | на что смотрит                                      | главная слабость                       |
|-----------------|---------------------------------------------------|-----------------------------------------------------|----------------------------------------|
| Швайнхарт (MST) | фрактальную размерность, с диапазоном по $\alpha$ | как растёт длина минимального дерева с числом точек | нужно очень много точек, долго считать |
| TwoNN           | локальную размерность                             | отношение расстояний до 2-го и 1-го соседа          | одно число на всё облако               |

|         |                                            |                                                       |                                                                 |
|---------|--------------------------------------------|-------------------------------------------------------|-----------------------------------------------------------------|
| FisherS | «линейную»<br>эффективную<br>размерность   | долю точек, которые<br>можно отрезать<br>плоскостью   | завышает на<br>изогнутых<br>поверхностях,<br>путается на смесях |
| Hidalgo | размерности<br>нескольких частей<br>облака | то же $\mu$ , что TwoNN, +<br>правило «соседи похожи» | медленный, число<br>частей задаём сами                          |

**Как читать результаты вместе.** Если TwoNN, Hidalgo и Швайнхарт дают близкие числа, а Hidalgo показывает две почти одинаковые «породы», — облако однородное, и число надёжное. Если Hidalgo находит породу с очень маленькой размерностью, в облаке есть «вырожденная» часть (как лучи у SVD). Если FisherS сильно больше остальных, облако скорее всего изогнуто.

Источники: Gromov, Borodin, Yerbolova (2024) Complexity; Schweinhart (2021) J. Topol. Anal.; Facco et al. (2017) Sci. Rep. 7:12140; Albergante, Bac, Zinovyev (2019) arXiv:1901.06328; Bac et al. (2021) Entropy 23:1368 (scikit-dimension); Allegra et al. (2020) Sci. Rep. 10:16193; Denti et al. (2023) J. Stat. Softw. 106(9) (intRinsic).