

Ответы на четыре вопроса Громова: калибровка оценок размерности

Эксперименты E10–E16, 5–7 октября 2026 (HSE CHARISMa). Около 1 500 облаков точек, 27 калибровочных объектов, 4 оценщика (Швайнхарт, TwoNN, Hidalgo, FisherS), эмбединги CBOW и SVD, слова и биграммы.

Коротко. (1) Большие d . Для CBOW оценка выходит на плато с $d \approx 15$ при $m \leq 8$ и только с $d \approx 2m$ при $m = 10$ –12 (это и есть порог Уитни); дальше до $d = 100$ не меняется. SVD растёт с d до 100 у всех объектов — для SVD плато нет. **(2)**

Фракталы. Швайнхарт на точных координатах даёт D_0 (салфетка 1,7, губка 2,8, 7-симплекс 3,0), на мультифракталах — ближе к D_2 . TwoNN и Hidalgo занижают. CBOW даёт 3,3–4,2 для любого фрактала с $D \leq 3$: малые и дробные размерности он не различает. **(3) Число точек и траекторий.** Число траекторий почти не влияет;

размер словаря V влияет сильно (T^4 : $9,2 \rightarrow 6,6$ при $V = 1\,000 \rightarrow 20\,000$). Оценки по биграммам зависят от числа точек, и у «Войны и мира» эта зависимость сильнее, чем у любого калибровочного объекта. **(4) Реальная ситуация.** По тексту можно определить тип динамики (Цао E_2 , рост размерности k -грамм): язык — стохастический, не детерминированный поток, и классические FNN / FNF / Такенс для него m не дают. Поправка, выученная на калибровке, восстанавливает m с ошибкой 6–17 % для текстов того же типа, но на другом генераторе ошибается на 34–56 %. Мы нашли, от чего это зависит (от матрицы переходов между соседними словами, а не от памяти и не от шума CBOW), но пока не знаем, какая калибровка применима к языку. Для «Войны и мира» совместимый со всеми методами интервал — $m \approx 3,5$ –9.

Как читать числа

Есть три уровня утверждений, и для каждого числа ниже понятно, к какому оно относится. **Описание** — что получилось на конкретных конфигурациях. **Перенос на новый объект** — поправка учится без проверяемого объекта. **Перенос на новые условия** — поправка учится без целого семейства условий (или без целого генератора); это ближе всего к языку. Конфигурации не независимы: эффективный размер выборки — 15 объектов броуновского типа и 13 семейств условий, а не 1 500 облаков.

Вопрос 1. Что будет при ещё больших размерностях пространства вложения

Объекты: торы T^2 – T^{12} , сферы S^4 , S^8 , S^{12} ; эмбединги CBOW и SVD при $d = 5, 10, 15, 30, 50, 100$ (E10).

объект (m)	CBOW слова: $d = 5$	$d = 10$	15	30	50	100	SVD слова: $d = 15 / 30 / 50 / 100$	CBOW биграммы: $d = 15 / 30 / 50 / 100$
T^4 (4)	4,0	7,6	8,1	8,5	8,7	8,7	12,0 / 17,4 / 21,8 / 28,3	6,8 / 6,9 / 6,8 / 6,8
T^8 (8)	4,1	8,6	12,5	14,5	14,8	14,4	13,5 / 23,8 / 32,8 / 49,4	12,3 / 12,2 / 12,4 / 11,8
T^{10} (10)	4,0	8,9	12,4	18,7	22,2	22,8	13,1 / 23,4 / 33,8 / 51,6	13,2 / 13,0 / 12,2 / 12,3
T^{12} (12)	4,2	8,7	12,8	22,0	29,2	35,1	13,3 / 23,8 / 34,2 / 49,6	13,4 / 12,5 / 12,5 / 12,9
S^{12} (12)	4,1	8,6	13,9	17,2	18,6	17,8	13,0 / 22,2 / 32,7 / 50,7	12,8 / 12,4 / 12,3 / 12,3

Табл. 1. TwoNN, слова и биграммы, $V = 5\,000$, 500 траекторий (E10). Уровень «описание».




Рис. 1. Отношение «оценка / m» в зависимости от d по всем броуновским объектам (медиана и полоса 10-90 %).

- **CBOW.** При $d = 5$ все оценки упираются в $d (\approx 4)$. Плато наступает с $d \approx 15$ для $m \leq 8$ и с $d \approx 50$ для $m = 10-12$, т. е. примерно при $d \geq 2m$ — это порог Уитни. На плато оценка от d не зависит (T^8 : 14,5 / 14,8 / 14,4 при $d = 30 / 50 / 100$), но она завышена в 1,3-2,5 раза (см. вопрос 4).
- **SVD** растёт с d без насыщения до $d = 100$ у всех объектов: SVD по матрице «слово $\times$ документ» не даёт плато, на нём m не измерить.
- **Биграммы CBOW** насыщаются на 12-14 для всех $m \geq 8$: при $d \leq 100$ и 10 000 точках TwoNN выше ~ 13 не поднимается. Это ограничение метода и объёма данных, а не свойство объектов.
- **Практический вывод:** d выбирать так, чтобы $d \geq 2m$ и $d \geq 15$, и проверять плато по нескольким d. Выход на плато — необходимое, но не достаточное условие правильной оценки.

Вопрос 2. Фракталы и мультифракталы

Самоподобные фракталы (блуждание по графу ячеек уровня L) и мультифрактальные меры (блуждание Метрополиса с весами p), E10.

объект	D_0	точные: Ш вайнхарт	точные: TwoNN	точные: Hidalgo	CBOW 15: TwoNN	CBOW 15: Швайнхарт
салфетка Серпинского	1,58	1,71	1,01	1,15	3,28	нет α
ковёр Серпинского	1,89	1,82	1,28	1,39	3,82	нет α
тетраэдр Серпинского	2,00	1,97	0,99	1,24	3,32	нет α
4-симплекс	2,32	2,31	1,10	1,39	3,45	3,62
губка Менгера	2,73	2,76	2,49	2,20	4,24	4,23
7-симплекс	3,00	2,97	1,89	2,09	3,54	3,92
мультифрактал на салфетке (D_1 1,35, D_2 1,17)	1,58	1,23	1,04	1,15	2,75	нет α
мультифрактал на тетраэдре (D_1 1,85, D_2 1,74)	2,00	1,75	1,08	1,28	—	—

Табл. 2. Слова, $V = 5\,000$. «Нет α » — у Швайнхарта не нашлось допустимого показателя.

- **Швайнхарт на точных координатах** воспроизводит D_0 самоподобных фракталов с точностью $\pm 0,1$. На мультифракталах он даёт число между D_1 и D_2 (1,23 при $D_2 = 1,17$; 1,75 при $D_2 = 1,74$) — то есть видит корреляционную размерность меры, а не

размерность носителя. Это ожидаемо: MST-оценка чувствительна к тому, где лежит масса.

- **TwoNN и Hidalgo занижают** (≈ 1 для салфетки и тетраэдра): на масштабе ближайших соседей дискретный фрактал конечного уровня выглядит как набор отрезков.
- **CBOW не различает малые размерности:** для любого фрактала с $D \leq 3$ он даёт 3,3–4,2, а Швайнгарт на CBOW-векторах часто вообще не находит степенного участка. Если у языка есть фрактальная компонента с $D \leq 3$, CBOW её не покажет.

Вопрос 3. Как влияют число точек и число траекторий

объект (m)	V 1 000	2 000	5 000	10 000	20 000	T 100	250	500	1 000	2 000
T ⁴ (4)	9,2	8,3	8,1	7,7	6,6	7,4	7,9	8,1	8,1	8,7
T ⁶ (6)	12,7	10,9	10,7	10,1	9,5	10,0	10,1	10,7	10,6	10,9
S ⁴ (4)	8,6	8,6	7,9	7,5	6,4	6,8	—	7,9	—	—
Лоренц (2,06)	3,7	3,7	3,9	4,2	4,2	3,7	—	3,9	—	—

Табл. 3. CBOW d = 15, TwoNN, слова (E10, часть B). V — размер словаря (500 траекторий), T — число траекторий (V = 5 000).

- **Размер словаря V** — сильный фактор: чем больше слов, тем меньше завышение (T⁴: 9,2 → 6,6; T⁶: 12,7 → 9,5). В E12 при V = 18 000 множитель на словах 1,2–1,9 против 1,5–2,5 при V = 5 000.
- **Число траекторий** (объём текста при том же словаре) влияет слабо и скорее увеличивает оценку (T⁴: 7,4 → 8,7 при 100 → 2 000).
- **Число точек в облаке биграмм** (E13). Для пар соседних точек непрерывной траектории отношение «биграммы / слова» — одна кривая от ρ = шаг / расстояние до соседа для всех $m = 2$ –12 (1,0 при $\rho < 0,2$; 2,0 при $\rho > 1,3$; разброс ± 10 –15 %). Для пар дискретных слов это не так: с ростом числа точек оценка по биграммам падает к m , потому что у каждого слова лишь несколько слов-последователей.
- **«Война и мир»:** оценка по биграммам растёт с числом точек (TwoNN 6,2 при 1 тыс. → 9,3 при 152 тыс.); отношение «все / 10 тыс.» = 1,41 при калибровочных 0,75–1,34. Это первое прямое расхождение текста с калибровкой.

Вопрос 4. Модель реальной ситуации: истинное m неизвестно

4.1. Что дают Уитни, Такенс, FNN и FNF

- **FNN (Кеннел)** уходит в 0 при росте k для всех объектов, включая броуновские блуждания, — по нему m не определить.
- **FNF** (ложные соседи на складках, Малинецкий–Потапов, §11.4.2, §13.3) мы ловим двумя способами: по доле ближайших соседей реконструкции, далёких в исходном пространстве, и по росту наклона корреляционного интеграла с k . У Лоренца минимум ложных соседей 14 % при $k = 3$ –4 и рост до 43 % при $k = 12$; у Лоренца-96 ($N = 10$) — не ниже 60 %: FNN и FNF сосуществуют.

- **Цао E₂** разделяет детерминированные потоки (0,02–0,25) и случайные блуждания (≈ 1). Облака k слов подряд у потоков насыщаются на D, у блужданий растут с k.
- **Для потоков схема работает:** CBOW-биграммы Лоренца-96 (D = 6,55) дают 6,6–6,7.

4.2. К какой группе относится язык (E11)

«Война и мир»: $E_2(k = 2) = 1,00$ — как у той же книги с перемешанными словами; размерность облаков k слов растёт с 2,3 до 12,5 при $k = 1 \dots 8$. Диалоги: $E_2 = 0,88\text{--}0,92$ (перемешанные — 1,00). Язык — стохастическая последовательность, не поток. Значит, теоремы Уитни и Такенса к нему напрямую не применимы, и m надо восстанавливать через калибровку на стохастических генераторах.

4.3. Насколько хороша калибровка




Рис. 2. «Оценка / m »: голубое — точные координаты, оранжевое — CBOW $d = 15\text{--}30$ (15 броуновских объектов).

метод	слова: сырое число	слова: после поправки, медиана / 90 %	биграммы: сырое число	биграммы: после поправки
TwoNN	$1,97 \cdot m$	10 % / 34 %	$1,63 \cdot m$	9 % / 35 %
Hidalgo	$2,00 \cdot m$	12 % / 36 %	$1,74 \cdot m$	10 % / 33 %
Швайнхарт	$1,62 \cdot m$	7 % / 28 %	$1,96 \cdot m$	8 % / 21 %

Табл. 4. Ошибка восстановления m на новом объекте того же типа (поправка $\log(\text{оценка}) = a + b \cdot \log m$ учится без него).

семейство условий, не участвовавшее в обучении поправки	слова TwoNN	слова Швайнхарт	биграммы TwoNN	биграммы Швайнхарт
разбиение, число траекторий, длина предложения, окно CBOW	$\pm 3 \%$	$\pm 6 \%$	$\pm 6 \%$	$\pm 6 \%$
шаг блуждания $\times 0,5 / 2 / 3$	+10 %	+6 %	+24 %	+12 %
словарь $V = 18\,000$	−25 %	−7 %	+10 %	−5 %
цифровские частоты (наклон −1, как у текста)	+4 %	+13 %	−33 %	−14 %
другой генератор (псевдоязык E7)	−55 %	−37 %	−38 %	−35 %

Табл. 5. Медианный сдвиг восстановленного m на условиях, которых не было в калибровке.

4.4. Почему поправка не переносится: что мы выяснили

- **Множитель завышения не универсален (E12):** на словах от 1,2 до 3,8 в зависимости от V , шага и частот.

- **Дело не в шуме CBOW (E14):** усреднение пяти бутстреп-прогонов и отбрасывание редких слов почти не меняют оценку (T^4 : $8,1 \rightarrow 7,7$). Завышение систематическое.
- **Дело в генераторе текста (E15, 24 перекрёстные замены).** Форма пространства (тор или куб с дырами) и нарезка текста почти не влияют ($\leq 15\%$). Влияет способ блуждания: если следующее слово выбирается среди соседей текущего, CBOW даёт $1,1-1,6 \cdot m$; если непрерывная точка движется и «округляется» до слов — $1,5-2,5 \cdot m$ (при $m = 6$: $7,1$ против $10,4$).
- **Важна только матрица переходов между соседними словами (E16).** На марковской копии текста — те же переходы, но без памяти — CBOW даёт ту же размерность во всех 13 случаях (разница $\leq 0,3$), включая «Войну и мир» ($13,1 \rightarrow 13,0$). Память у текстов есть («Война и мир»: выигрыш $+0,10$ бит на слово от второго предыдущего слова), но на геометрию CBOW она не влияет.

4.5. Что получается для «Войны и мира»

метод	слова: измерено $\rightarrow \hat{m}$	биграммы: измерено $\rightarrow \hat{m}$
TwoNN	$12,95 \rightarrow 9,0$	$6,6 \rightarrow 4,0$
Hidalgo	$12,7 \rightarrow 8,8$	$\approx 6,2 \rightarrow 3,4$
Швайнхарт	$9,5-10,4 \rightarrow 7,0$	$6,3-10,4 \rightarrow 4,4$

Табл. 6. Поправка, обученная на всех броуновских объектах (CBOW $d = 15$).

Слова дают 7–9, биграммы 3,4–4,4. На текстах того же типа, что калибровка, слова и биграммы после поправки совпадают в пределах $\pm 25\%$; здесь расхождение вдвое. Вывод: калибровочное семейство не описывает «Войну и мир», и единственное, что можно честно сказать, — интервал $m \approx 3,5-9$, совместимый со всеми методами.

4.6. Почему непонятно, как действовать дальше

- **Нет внешней «гири».** Для языка истинного m нет. Значит, точность можно установить только через генераторы, а результат зависит от того, какой генератор считать похожим на язык.
- **Теоремы вложения тут не помогают.** Уитни и Такенс гарантируют восстановление размерности для детерминированных систем. У языка $E_2 \approx 1$, облака k -грамм не насыщаются — то есть «насыщение по k », на котором стоит вся процедура FNN / FNF, не наступает.
- **Множитель CBOW определяется матрицей переходов, и мы не знаем, как именно.** Два генератора с одинаковым m , одинаковой формой и одинаковым текстом дают множители 1,1 и 2,5 — в зависимости от того, как устроены переходы. Подобрать генератор под текст по нескольким статистикам можно, но без понимания механизма это будет подгонка с неизвестной ошибкой.
- **Слова и биграммы у текста противоречат друг другу, а у калибровки — нет.** Пока это противоречие не объяснено, ни одно число m не является измерением.
- **Возможно, вопрос поставлен не в той форме.** Оценка у текста зависит от масштаба и от числа точек (биграммы $6,2 \rightarrow 9,3$), поэтому «одна размерность языка» может быть некорректно определённой величиной; нужна договорённость, какую размерность мы ищем (на каком масштабе, для какого объекта — слова, пары, предложения).

Возможные пути, между которыми нужно выбрать

- **Теория вместо подбора.** CBOW с отрицательными примерами по сути раскладывает матрицу PMI «слово × контекст» (Levy, Goldberg, 2014). Тогда ожидаемую геометрию CBOW можно вычислить из матрицы переходов текста и проверить на марковских цепях с известной геометрией. Это даст поправку, обоснованную механизмом.
- **Подбор генератора под текст** (приближённый байесовский вывод): параметры генератора и m подбираются так, чтобы воспроизвести все измеримые свойства «Войны и мира» сразу. Дорого и не гарантирует, что язык лежит в семействе.
- **Отказ от одного числа:** публиковать зависимость оценки от масштаба и интервал, совместимый со всеми методами, с явными условиями согласия (слова, биграммы и методы после поправки должны совпадать).

Приложение: где лежат данные и код

EXPERIMENTS.md (E10–E16); таблицы results/calib2_table.csv, calib3_table.csv, calib4_table.csv, calib5_table.csv, calib_pooled.csv; код code/calib2.py ... calib7.py; отчёты reports/kalibrovka_raund2.pdf, ustoichivost_mnozhitelya_E12.pdf, tochnost_cbow_metodov.pdf.