

Калибровка на псевдоязыке: можно ли узнать истинную размерность

Тексты порождаются блужданием по фигуре известной размерности m ; по ним строятся эмбединги (SVD, CBOW, BERT), и к ним применяются те же четыре метода, что и к «Войне и миру». Вопрос: какой цифре можно верить. Расчёт — суперкомпьютер НИУ ВШЭ CHARISMa, 2–3 октября 2026.

Главное

1. **Верить можно связке «CBOW + Швайнхарт / TwoNN / Hidalgo» при $d \geq 10$, если оценка стабильна между $d = 10$ и 15 .** На локальном тексте она завышает истину на 0,2–0,9 (Швайнхарт, $d = 15$: 2,6 / 3,5 / 4,3 / 6,2 для $m = 2 / 3 / 4 / 6$).
2. **Признак надёжности — плато по d .** Если оценка продолжает расти с d , это не размерность.
3. **SVD** завышает и растёт с d ; **BERT** (обученный с нуля, усреднённые контекстные векторы) завышает ещё сильнее и не различает $m = 3, 4, 6$; BERT без сжатия даёт 20–38. **FisherS** на эмбедингах неинформативен.
4. Блуждание тетрадки ($p \propto 1/d^2$) при $m \geq 3$ почти не локально: текст не несёт геометрии, все оценки растут с d . Профиль CBOW «Войны и мира» по d (4,7 → 8,9 → 10,0) похож именно на этот режим.

Часть I. Введение и методы

1. Зачем этот эксперимент и как читать таблицы

Для настоящего языка истинная размерность неизвестна, поэтому нельзя проверить, какой метод ошибается. Здесь мы сами строим «язык» с известной геометрией и смотрим, какую размерность выдают эмбединг и метод. Обозначения во всех таблицах:

- **m** — истинная размерность фигуры, по которой строились тексты (2, 3, 4 или 6). Её мы знаем по построению.
- **эталон** (в прошлой версии — «точки») — оценка тем же методом прямо по координатам точек фигуры, без текста и эмбедингов. Это то, что метод выдаёт на идеальных данных; например, TwoNN при $m = 6$ даёт 5,6, а не 6 (мало точек для 6D, край куба). Хороший эмбединг должен быть близок и к m , и к эталону.
- **d** — размерность эмбединга (2, 5, 10, 15; у BERT без сжатия — 256).
- **eps / dist** — способ порождения текста (раздел 3).
- Для Швайнхарта указан диапазон «минимум–максимум» по всем допустимым α на двух лестницах; «нет α » — ни одно α не прошло критерий 10%. Для Hidalgo — две найденные размерности d_1/d_2 . Для TwoNN и FisherS — одно число.

2. Объекты: откуда известна истинная размерность

Куб $[0,1]^m$, в который бросаются 5000 случайных точек, после чего вырезаются 4 шара («дырки»; для $m = 2$ — круги из тетрадки). Остаётся 4581–4999 точек; каждая точка — одно «слово». Куб с дырками — m -мерное многообразие с краем: около любой точки он выглядит как кусок R^m , дырки меняют топологию, но не размерность. Поэтому истинная размерность — m .

3. Тексты: два способа блуждания

1000 текстов; длина каждого — длина случайного русского текста из russian_Prussner_wolframe100.csv, делённая на $k = 60\,000 // V$ (как в тетрадке); всего $\approx 0,84$ – $0,94$ млн словоупотреблений. Текст — блуждание по точкам; следующее слово выбирается так:

- **eps** (наш вариант): равновероятно среди точек ближе $\epsilon = 1,5 \cdot V^{-1/m}$ — несколько ближайших соседей. Соседние слова текста всегда близки на фигуре.
- **dist** (тетрадка): любая точка, с вероятностью $\propto 1/(\text{расстояние})^2$. Число точек на расстоянии r растёт как r^{m-1} , поэтому длина шага распределена $\propto r^{m-3}$: при $m = 2$ шаги короткие, при $m = 3$ длинные и короткие равновероятны, при $m \geq 4$ доминируют дальние прыжки.

m	медиана шага, dist	медиана шага, eps	до ближайшего соседа	шаг dist / сосед
2	0,005	0,016	0,007	0,7
3	0,27	0,070	0,032	8,4
4	0,51	0,15	0,075	6,8
6	0,80	0,32	0,18	4,4

«Шаг dist / сосед» — во сколько раз типичный шаг текста длиннее расстояния до ближайшего соседа. Около 1 — текст идёт к соседям, геометрия сохраняется; 4–8 — за одно слово текст перескакивает через десятки-сотни точек, соседство в тексте почти ничего не говорит о близости на фигуре.

4. Эмбединги

- **SVD** (методика статьи «A Language and Its Dimensions»): матрица слово $\times$ текст с энтропийными весами, усечённое SVD, строки U — векторы слов. Первые компоненты — гладкие «гармоники» на фигуре, хвостовые — шумные (оценены по 1000 текстам).
- **CBOW** (word2vec): сеть предсказывает слово по окну ± 5 . Две настройки: тетрадки (5 эпох, min_count 3) и «Войны и мира» (30 эпох, min_count 1). word2vec раскладывает матрицу PMI; при локальном тексте PMI $\approx$ ядро диффузии по фигуре, и эмбединг похож на diffusion maps — сохраняет форму. Шум обучения добавляет небольшую «толщину» во всех d направлениях.
- **BERT**: маленький BERT (4 слоя $\times$ 256, 4 головы, 4,4 млн параметров), обученный с нуля маскированным предсказанием на тех же текстах, 30 эпох (84–124 мин на 2 ядрах). Вектор слова — среднее контекстных векторов последнего слоя по всем вхождениям (как ruBERT для «Войны и мира»); затем PCA до 2/5/10/15 и полный вектор 256.

- **Биграммы** — склейка векторов двух соседних слов ($2d$); до 10 000 случайных биграмм. Их истинная размерность зависит от масштаба: на $\text{eps} \approx m + 1$, на dist при $m \geq 3 \approx 2m$ (см. эталон).

объект	точность MLM	loss	PCA 5	PCA 10	PCA 15
$m = 2, \text{eps}$	0,33	1,93	13%	24%	33%
$m = 3, \text{eps}$	0,31	2,25	12%	21%	28%
$m = 4, \text{eps}$	0,22	2,78	23%	32%	39%
$m = 6, \text{eps}$	0,19	3,53	24%	39%	48%
$m = 2, \text{dist}$	0,57	2,40	16%	27%	37%
$m = 3, 4, 6, \text{dist}$	0,10–0,11	7,7–7,8	5%	10%	14%

Точность MLM — доля верно угаданных замаскированных слов; PCA k — доля дисперсии векторов BERT в первых k компонентах. На dist при $m \geq 3$ BERT почти ничего не выучил ($\text{loss} \approx \ln 5000 - 0,7$): следующее слово там почти случайно.

5. Методы оценки размерности

- **Швайнхарт** (размерность через минимальное остовное дерево). Для n точек строится MST, $E_\alpha(n) = \sum |e|^\alpha$ растёт как $n^{(d-\alpha)/d}$; по наклону $\ln E$ от $\ln n$ на лестнице из 10 вложенных подвыборок ($N/16 \dots N$) $d = \alpha/(1 - \text{наклон})$. α от 10^{-4} до 10; допустимы α , у которых 95%-ные интервалы и наклона, и d уже 10%. Охватывает диапазон масштабов, поэтому мелкий шум сказывается слабее, чем у TwoNN; при неоднородном облаке диапазон по α расширяется или α нет вовсе.
- **TwoNN** (Fasso et al., 2017). Отношение $\mu = r_2/r_1$ расстояний до второго и первого соседа распределено по Парето с показателем d ; d — наклон $-\ln(1 - F(\mu))$ от $\ln \mu$ (10% крайних μ отброшены). Самый локальный: любой шум на масштабе ближайшего соседа завышает оценку; мало точек и край — занижают.
- **FisherS** (Albergante, Gorban et al., 2019). Центрирование, PCA-отбеливание, проекция на сферу; доля точек, линейно не отделимых от остальных, сравнивается с равномерным распределением на n -мерной сфере. Отбеливание выравнивает шумовые направления с настоящими — поэтому на эмбедингах FisherS измеряет «число направлений после нормировки», а не размерность.
- **Hidalgo** (Allegra et al., 2020). Байесовское обобщение TwoNN: смесь двух многообразий с размерностями d_1, d_2 (соседи с вероятностью 0,8 на том же многообразии, Гиббс). $d_1 \approx d_2$ — облако однородно; большой разрыв — смесь.

Те же реализации, что в отчёте по «Войне и миру»; эталоны на кубах и сферах проверены там же (ошибка Швайнхарта 0,4–12%).

Часть II. Результаты: метод оценки + эмбединг

Каждый раздел — одна связка. Строки — истинная размерность m , столбцы — эталон и размерность эмбединга d для двух способов блуждания. Сравнивайте столбцы eps с m и с эталоном: хорошая связка близка к ним и почти не меняется между $d = 10$ и 15 .

6. Швайнхарт

6.1. Швайнхарт + SVD

слова

m	эталон	eps $d=2$	eps $d=5$	eps $d=10$	eps $d=15$	dist $d=2$	dist $d=5$	dist $d=10$	dist $d=15$
2	1,9-2,0	1,0-1,0	нет α	1,5-2,1	1,6-2,3	1,8-2,0	4,0-4,7	5,0-5,6	5,7-6,3
3	2,8-3,0	1,8-2,3	2,9-3,8	4,1-4,7	4,0-5,2	1,6-2,0	4,1-4,8	7,7-7,7	нет α
4	3,7-3,9	2,0-2,1	4,3-4,8	5,9-6,8	6,7-7,7	2,0-2,1	4,7-4,9	7,4-8,0	8,2-8,8
6	5,2-5,9	2,1-2,2	4,9-5,1	7,9-8,4	нет α	1,9-2,1	4,3-4,6	6,8-7,2	7,9-8,4

биграммы

m	эталон	eps $d=2$	eps $d=5$	eps $d=10$	eps $d=15$	dist $d=2$	dist $d=5$	dist $d=10$	dist $d=15$
2	2,4-2,6	1,8-2,0	2,2-2,6	2,1-3,0	2,1-3,0	3,8-3,8	нет α	нет α	нет α
3	3,8-3,8	3,2-3,8	3,6-4,8	3,7-5,4	4,2-5,5	3,9-4,1	7,0-7,7	8,3-10,0	8,7-10,0
4	5,1-5,2	3,6-4,0	5,7-6,2	6,3-7,4	6,4-7,7	3,2-4,0	7,2-7,4	8,8-9,2	9,4-9,5
6	6,9-7,5	3,0-4,0	6,1-7,2	6,5-8,5	7,8-8,8	3,6-3,9	7,1-7,3	9,1-9,5	нет α

Ненадёжно. На eps оценка растёт с d и при $m \geq 3$ сильно завышена ($m = 4$: $4,3-4,7 \rightarrow 5,9-6,8 \rightarrow 6,7-7,7$ при $d = 5/10/15$); при $d = 2$ занижает (≈ 1). Часто нет допустимых α . На dist — рост без плато.

6.2. Швайнхарт + CBOW, настройки «Войны и мира»

слова

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	1,9-2,0	1,8-2,0	2,9-3,3	2,6-2,8	2,6-2,7	1,7-2,0	3,6-3,8	4,5-5,0	5,2-5,8
3	2,8-3,0	1,6-1,8	3,3-3,5	3,2-3,4	3,4-3,6	1,7-1,9	3,3-4,0	5,3-6,0	6,5-7,6
4	3,7-3,9	1,7-1,9	3,6-3,9	4,0-4,3	4,2-4,4	1,9-2,0	3,9-4,2	6,6-7,5	8,9-9,9
6	5,2-5,9	1,6-1,9	4,0-4,3	5,5-6,0	5,7-6,8	1,7-1,9	3,9-4,3	7,6-8,6	11,8-13,5

биграммы

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,4-2,6	2,5-2,7	3,4-3,9	2,9-3,4	3,0-3,1	2,7-3,2	5,4-5,9	6,9-7,3	8,0-11,8
3	3,8-3,8	2,4-2,8	4,2-4,7	4,1-4,4	4,2-4,4	2,5-2,7	5,8-6,4	7,6-8,4	8,9-10,1
4	5,1-5,2	2,4-2,8	5,0-5,5	5,1-5,5	5,3-5,7	2,4-2,5	6,4-6,7	9,3-10,6	12,3-13,3
6	6,9-7,5	2,3-2,7	6,1-6,5	6,5-7,9	7,0-8,2	2,2-2,5	7,1-7,6	12,7-13,7	15,8-18,5

Лучшая связка. На eps при d = 10-15 оценка выходит на плато около m: 2,6 / 3,4-3,6 / 4,2-4,4 / 5,7-6,8 для m = 2 / 3 / 4 / 6. При d = 5 упирается в потолок около 4. На dist растёт с d — геометрии в тексте нет.

6.3. Швайнхарт + CBOW, настройки тетрадки

слова

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	1,9-2,0	1,9-2,0	3,1-3,3	2,6-2,7	2,5-2,6	1,8-2,0	3,3-3,7	3,8-4,5	4,4-4,8
3	2,8-3,0	1,8-2,0	3,4-3,5	3,3-3,4	3,2-3,3	2,1-2,1	3,8-4,2	4,9-5,8	нет α
4	3,7-3,9	1,9-2,0	3,7-4,0	4,1-4,2	4,1-4,2	2,0-2,0	4,1-4,5	8,3-8,7	9,7-12,0
6	5,2-5,9	1,8-2,0	4,2-4,3	5,3-6,6	5,4-6,5	2,0-2,1	4,4-4,7	8,9-10,1	12,3-13,4

биграммы

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,4-2,6	2,9-3,4	3,6-4,3	3,0-3,2	2,8-3,8	3,2-3,6	5,6-5,7	6,0-7,1	6,2-7,2
3	3,8-3,8	2,7-3,0	4,4-4,9	4,1-4,3	4,2-4,3	3,4-3,5	6,2-6,8	6,1-7,5	5,6-7,6
4	5,1-5,2	2,8-3,2	5,3-5,9	5,2-5,8	5,2-5,7	2,6-3,2	5,8-7,8	9,8-11,8	13,1-15,3
6	6,9-7,5	2,8-3,2	6,0-6,5	6,5-8,8	7,2-8,9	3,3-3,4	7,7-8,0	13,2-14,5	16,5-17,2

Надёжно, почти как с настройками «Войны и мира». На eps при d = 15: 2,5-2,6 / 3,2-3,3 / 4,1-4,2 / 5,4-6,5 — даже ближе к истине, чем CBOW с 30 эпохами, но разброс по α при m = 6 шире.

6.4. Швайнхарт + BERT → PCA

слова

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	1,9-2,0	2,0-2,1	4,1-4,6	4,1-4,1	нет α	2,0-2,1	3,7-4,0	3,9-4,1	4,1-4,2
3	2,8-3,0	2,0-2,1	4,4-4,9	5,8-6,8	6,5-7,5	2,0-2,2	5,0-5,8	8,9-10,8	12,4-14,6
4	3,7-3,9	2,0-2,1	4,2-4,5	5,3-6,2	6,0-7,2	2,0-2,2	5,2-5,6	9,8-10,8	13,1-15,4
6	5,2-5,9	2,0-2,2	4,3-4,8	5,4-6,0	6,0-6,6	2,0-2,1	4,9-5,4	9,1-10,9	12,2-15,0

биграммы

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,4-2,6	3,6-4,0	4,9-5,9	4,1-4,6	3,8-4,0	3,9-4,2	6,6-7,8	7,5-10,4	8,4-12,1
3	3,8-3,8	3,9-4,4	5,6-6,3	5,8-6,7	6,0-6,4	4,0-4,3	9,6-11,4	15,1-16,6	17,7-19,5
4	5,1-5,2	3,8-4,1	5,7-6,1	6,3-6,6	6,8-7,1	4,0-4,3	8,8-10,5	13,5-16,2	16,6-18,8
6	6,9-7,5	3,9-4,3	6,5-7,1	7,2-7,7	7,5-8,1	4,0-4,8	9,1-10,0	14,4-15,4	17,0-18,6

Ненадёжно. На eps оценка не различает $m = 3, 4, 6$ (при $d = 15$ все $\approx 6-7,5$) и растёт с d ; при $d = 5$ упирается в d . PCA до 15 сохраняет лишь 28-48% дисперсии BERT.

6.5. Швайнхарт + BERT без сжатия (256)

слова

m	эталон	eps, d=256	dist, d=256
2	1,9-2,0	9,1-10,8	12,1-13,4
3	2,8-3,0	19,6-26,4	69,3-81,7
4	3,7-3,9	27,4-33,2	70,1-87,8
6	5,2-5,9	26,7-32,5	69,5-84,7

биграммы

m	эталон	eps, d=256	dist, d=256
2	2,4-2,6	6,0-6,5	11,7-12,2
3	3,8-3,8	нет α	нет α
4	5,1-5,2	нет α	нет α
6	6,9-7,5	нет α	нет α

Неприменимо. Слова: 9-11 ($m = 2$), 20-33 ($m = 3-6$); на dist при $m \geq 3$ — 69-88. На биграммах чаще всего нет допустимых α.

7. TwoNN

7.1. TwoNN + SVD

слова

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,0	1,0	2,2	2,6	2,8	2,0	4,4	6,2	7,0
3	2,9	2,1	4,1	5,3	6,0	2,1	4,8	8,3	10,8
4	3,9	2,0	4,7	7,2	8,3	2,0	4,9	8,8	10,6
6	5,6	2,0	4,9	8,4	9,8	2,0	4,7	8,6	10,7

биграммы

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,4	1,8	2,6	2,7	2,7	3,6	6,3	6,7	7,2
3	3,4	3,6	4,2	4,6	4,8	3,9	7,3	9,2	8,6
4	4,5	3,7	5,1	5,8	6,0	3,8	7,1	7,6	7,4
6	5,9	3,7	6,3	6,6	6,5	3,8	6,9	8,0	7,7

Ненадёжно. Самое сильное завышение на SVD: eps, d = 15 — 2,8 / 6,0 / 8,3 / 9,8. Метод смотрит на ближайших соседей, а шумные хвостовые компоненты SVD как раз на этом масштабе.

7.2. TwoNN + CBOW, настройки «Войны и мира»

слова

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,0	2,0	2,9	2,8	2,9	2,0	3,5	4,9	5,5
3	2,9	2,0	3,4	3,6	3,9	2,0	3,8	6,5	8,0
4	3,9	2,0	3,7	4,5	4,8	2,0	3,9	7,4	10,4
6	5,6	2,0	4,0	6,0	6,3	2,1	4,0	8,6	12,4

биграммы

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,4	2,9	2,9	3,0	3,0	3,6	5,3	6,7	7,4
3	3,4	2,9	3,7	4,0	4,0	3,2	6,1	8,0	9,1
4	4,5	3,1	4,7	4,9	5,0	3,1	6,8	10,1	11,8
6	5,9	3,1	5,5	5,9	6,1	3,0	7,2	11,9	13,2

Надёжно, с завышением около +0,3...0,9. eps, d = 15: 2,9 / 3,9 / 4,8 / 6,4; плато между d = 10 и 15. Чуть выше Швайнхарта: шум обучения CBOW заметнее на самом мелком масштабе.

7.3. TwoNN + CBOW, настройки тетрадки

слова

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,0	2,1	3,3	2,9	2,9	2,0	3,5	3,7	3,6
3	2,9	2,0	3,6	3,7	3,7	2,1	4,4	6,4	7,5
4	3,9	2,0	3,8	4,4	4,5	2,0	4,5	8,7	12,3
6	5,6	2,0	4,3	5,8	5,9	2,0	4,7	8,8	12,2

биграммы

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,4	3,4	3,1	3,0	3,0	3,6	5,2	5,7	5,8
3	3,4	3,3	3,8	3,9	3,8	3,8	6,2	7,4	7,8
4	4,5	3,5	4,6	4,7	4,6	3,6	7,2	11,0	12,3
6	5,9	3,5	5,5	5,9	5,9	3,7	7,6	12,9	13,3

Надёжно. eps, d = 15: 2,9 / 3,7 / 4,5 / 5,9 — та же картина, что и с настройками «Войны и мира».

7.4. TwoNN + BERT → PCA

слова

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,0	2,0	4,5	4,1	4,5	2,0	3,6	3,0	2,8
3	2,9	2,0	4,8	6,8	8,0	2,0	5,2	9,7	14,0
4	3,9	2,1	4,5	7,1	8,9	2,0	5,1	10,0	13,8
6	5,6	2,1	4,7	6,7	7,8	2,0	5,0	10,0	13,6

биграммы

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,4	3,4	3,7	3,8	4,0	3,8	6,1	6,8	7,3
3	3,4	3,7	5,0	5,4	6,0	3,8	8,8	13,0	13,5
4	4,5	3,6	5,2	5,9	6,4	3,9	8,8	13,3	13,4
6	5,9	3,6	5,8	6,2	6,6	3,9	8,9	13,0	13,5

Ненадёжно. eps, d = 15: 4,5 / 8,0 / 8,9 / 7,9 — m = 2 отделяется, но m = 3, 4, 6 неразличимы и все сильно завышены. Роста к плато нет.

7.5. TwoNN + BERT без сжатия (256)

слова

m	эталон	eps, d=256	dist, d=256
2	2,0	21,2	13,3
3	2,9	29,1	74,2
4	3,9	35,6	78,2
6	5,6	37,5	77,3

биграммы

m	эталон	eps, d=256	dist, d=256
2	2,4	11,2	13,4
3	3,4	14,3	27,0
4	4,5	14,6	26,1
6	5,9	12,8	26,5

Неприменимо. eps: 21 / 29 / 36 / 38, dist: 13 / 74–78. Растёт с m, но в 6–10 раз выше истины.

8. FisherS

8.1. FisherS + SVD

слова

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	1,9	0,5	0,9	2,4	3,3	0,6	1,1	2,1	3,9
3	2,9	0,9	2,7	3,5	4,3	0,9	3,0	5,9	7,6
4	3,9	0,9	3,6	4,8	5,7	0,9	3,8	6,9	7,8
6	5,7	1,9	4,4	6,9	8,2	0,9	3,8	6,8	7,6

биграммы

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	1,9	0,5	0,9	2,4	3,2	0,8	1,7	3,7	7,0
3	2,9	0,9	2,6	3,5	4,2	1,8	5,2	8,7	10,3
4	3,8	0,9	3,5	7,2	8,7	1,9	6,6	9,4	10,8
6	5,6	1,9	7,3	11,0	11,9	1,9	6,6	9,1	10,3

Неинформативно. Занижает при малых d (0,5–1 при d = 2), при больших d — то занижает, то завышает; связи с m почти нет.

8.2. FisherS + CBOW, настройки «Войны и мира»

слова

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	1,9	1,4	4,1	6,7	7,0	0,9	3,4	5,3	6,6
3	2,9	1,5	4,0	6,4	6,8	0,9	3,6	5,2	6,7
4	3,9	1,5	4,0	6,4	7,0	0,9	3,8	6,3	8,9
6	5,7	0,9	4,0	6,9	7,6	0,9	3,9	8,6	13,5

биграммы

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	1,9	1,4	4,1	6,3	6,5	1,9	6,0	9,4	11,1
3	2,9	1,5	4,0	6,1	6,5	1,9	6,6	9,4	12,1
4	3,8	1,5	4,0	6,2	6,6	1,9	7,2	11,7	15,2
6	5,6	0,9	3,9	6,6	7,9	2,0	7,7	15,2	18,6

Неинформативно. При $d \geq 10$ даёт 6,4–7,6 при любом m: отбеливание растягивает шумовые направления до единичной дисперсии.

8.3. FisherS + CBOW, настройки тетрадки

слова

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	1,9	1,6	4,7	6,8	6,9	1,7	4,1	5,5	5,9
3	2,9	1,7	4,7	6,5	6,7	0,9	3,4	4,3	4,3
4	3,9	1,6	4,7	5,9	6,8	0,9	3,9	4,7	5,3
6	5,7	1,7	3,9	6,2	6,5	0,9	3,9	8,8	13,5

биграммы

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	1,9	1,6	4,8	6,4	6,4	1,9	6,0	9,1	9,2
3	2,9	1,7	4,0	5,8	6,0	1,9	6,3	7,0	6,6
4	3,8	1,6	3,9	5,8	6,1	2,0	7,7	7,4	6,9
6	5,6	1,7	3,9	6,1	6,4	2,0	7,8	15,5	19,5

Неинформативно по той же причине: 6,5–6,9 при $d = 15$ для любого m.

8.4. FisherS + BERT → PCA

слова

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	1,9	2,0	4,9	7,7	8,0	1,9	4,3	6,8	8,1
3	2,9	2,0	4,9	7,8	9,6	2,0	5,0	10,0	15,1
4	3,9	2,0	4,8	7,0	8,4	2,0	5,0	10,0	15,1
6	5,7	1,9	4,5	6,8	7,6	2,0	5,0	10,0	15,1

биграммы

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	1,9	2,0	4,8	7,2	7,3	3,8	8,0	11,2	12,5
3	2,9	2,0	4,8	8,4	10,2	4,0	9,9	16,1	19,9
4	3,8	2,0	4,7	6,4	7,2	4,0	9,8	16,1	19,4
6	5,6	1,9	4,5	7,2	7,7	4,0	9,9	16,3	19,8

Неинформативно. Следует за d ($\approx 7,6$ – $9,6$ при d = 15), а не за m.

8.5. FisherS + BERT без сжатия (256)

слова

m	эталон	eps, d=256	dist, d=256
2	1,9	21,5	24,3
3	2,9	52,3	41,5
4	3,9	28,5	—
6	5,7	11,6	—

биграммы

m	эталон	eps, d=256	dist, d=256
2	1,9	11,1	16,9
3	2,9	21,8	52,2
4	3,8	9,4	54,6
6	5,6	8,8	54,9

Неприменимо. Хаотично: 11–54.

9. Hidalgo

9.1. Hidalgo + SVD

слова

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,0/2,1	0,9/1,0	2,1/2,2	2,4/2,7	2,8/2,9	1,8/2,1	3,0/5,0	3,0/8,0	2,7/9,3
3	2,9/2,9	2,0/2,1	3,9/4,3	5,0/5,5	5,7/6,2	2,0/2,0	4,7/4,8	6,8/8,6	7,5/11,9
4	3,8/4,0	1,9/2,0	4,7/4,8	7,1/7,2	8,2/8,2	2,0/2,1	4,8/5,1	7,9/9,2	9,7/10,9
6	5,4/5,6	1,9/2,1	4,9/5,0	8,2/8,8	9,3/10,0	2,0/2,0	4,6/5,0	7,8/9,1	8,7/11,7

биграммы

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,5/2,8	1,9/1,9	2,5/2,7	2,6/3,0	2,5/2,9	3,3/3,6	4,0/7,6	3,7/9,7	3,7/11,4
3	3,6/3,9	3,4/3,9	4,1/4,5	4,8/4,8	4,9/5,0	3,8/3,8	6,9/7,2	6,9/11,6	5,8/12,3
4	4,8/5,0	3,7/3,7	5,5/5,8	6,2/6,2	6,4/6,5	3,7/3,8	6,3/8,0	6,0/10,8	6,1/10,8
6	6,4/6,4	3,4/3,5	6,2/6,9	6,1/7,9	5,8/8,4	3,7/4,0	6,2/8,0	5,9/9,5	5,8/10,3

Ненадёжно. Те же завышения, что у TwoNN; большой разрыв d_1/d_2 на dist (2,7/9,3 при $m = 2$, $d = 15$) — сигнал неоднородного облака.

9.2. Hidalgo + CBOW, настройки «Войны и мира»

слова

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,0/2,1	1,9/2,2	2,8/3,0	2,9/2,9	2,9/3,1	2,0/2,0	3,1/3,7	4,3/4,6	4,8/5,2
3	2,9/2,9	2,0/2,1	3,3/3,5	3,6/3,6	3,7/4,1	2,0/2,0	3,7/3,8	6,2/6,5	7,7/8,0
4	3,8/4,0	1,8/2,1	3,7/3,8	4,3/4,7	4,8/4,8	2,0/2,1	3,9/3,9	7,3/7,5	10,1/10,7
6	5,4/5,6	2,0/2,1	4,0/4,0	5,9/6,1	6,4/6,4	2,0/2,1	3,9/4,1	8,3/9,0	12,2/12,6

биграммы

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,5/2,8	2,9/3,0	3,1/3,1	3,3/3,3	3,2/3,2	3,3/3,6	5,1/5,2	6,6/6,6	7,2/7,7
3	3,6/3,9	2,6/3,0	3,9/4,0	4,1/4,4	4,1/4,6	3,0/3,1	5,7/6,0	7,7/7,8	8,7/8,9
4	4,8/5,0	2,8/2,9	4,7/4,9	5,2/5,4	5,3/5,5	2,8/3,1	6,9/7,0	9,8/9,9	11,3/11,8
6	6,4/6,4	2,9/3,0	5,5/5,9	6,3/6,4	6,3/6,5	2,5/3,0	6,9/7,5	11,9/12,1	13,6/14,4

Надёжно. Почти совпадает с TwoNN (eps, d = 15: 2,9–3,1 / 3,7–4,1 / 4,8 / 6,4), $d_1 \approx d_2$ — облако однородное.

9.3. Hidalgo + CBOW, настройки тетрадки

слова

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,0/2,1	1,9/2,2	3,2/3,5	3,0/3,0	3,0/3,0	2,0/2,0	2,6/4,8	2,2/6,4	2,2/7,1
3	2,9/2,9	1,9/2,1	3,6/3,7	3,7/3,8	3,8/3,9	2,0/2,1	4,4/4,4	5,9/6,5	6,4/7,7
4	3,8/4,0	1,9/2,0	3,8/3,9	4,3/4,6	4,5/4,5	2,0/2,1	4,3/4,5	8,6/8,8	12,1/12,2
6	5,4/5,6	2,0/2,0	4,1/4,5	5,7/5,8	5,8/6,0	2,0/2,0	4,6/4,8	8,8/8,9	11,7/12,6

биграммы

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,5/2,8	3,2/3,4	3,3/3,3	3,1/3,2	3,0/3,2	3,6/3,8	4,6/5,7	5,5/5,7	5,5/5,7
3	3,6/3,9	3,2/3,4	4,1/4,1	3,9/4,2	4,1/4,2	3,5/3,7	6,0/6,2	6,9/7,3	7,5/7,5
4	4,8/5,0	3,4/3,4	4,6/4,8	4,9/5,1	4,8/5,4	3,3/3,8	7,1/7,3	11,1/11,1	11,2/14,4
6	6,4/6,4	3,3/3,7	5,6/5,7	6,1/6,4	6,2/6,3	3,6/3,7	6,8/8,1	12,4/13,1	13,2/15,2

Надёжно. eps, d = 15: 3,0 / 3,8–3,9 / 4,5–4,6 / 5,8–6,0.

9.4. Hidalgo + BERT → PCA

слова

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,0/2,1	1,9/2,1	4,4/4,6	4,2/4,2	4,4/4,6	2,0/2,0	3,5/3,8	2,8/3,5	2,5/3,3
3	2,9/2,9	1,9/2,0	4,8/4,8	6,8/7,0	8,0/8,2	2,0/2,0	5,1/5,2	9,6/9,7	13,5/14,4
4	3,8/4,0	2,0/2,1	4,4/4,5	6,9/7,3	9,0/9,2	2,0/2,0	4,8/5,3	9,9/10,0	13,5/14,0
6	5,4/5,6	2,0/2,1	4,7/4,8	6,5/6,9	7,8/8,1	1,9/2,1	4,8/5,2	9,4/10,4	13,5/13,9

биграммы

m	эталон	eps d=2	eps d=5	eps d=10	eps d=15	dist d=2	dist d=5	dist d=10	dist d=15
2	2,5/2,8	3,5/3,5	3,9/4,1	3,7/4,0	3,9/4,1	3,6/3,8	6,0/6,2	6,6/7,1	7,0/7,7
3	3,6/3,9	3,4/3,9	5,5/5,5	5,7/5,9	6,2/6,4	3,9/3,9	8,9/8,9	12,9/13,9	14,8/14,9
4	4,8/5,0	3,7/3,8	5,0/5,5	6,2/6,4	6,5/6,7	4,0/4,0	8,3/8,8	12,4/14,0	14,1/14,6
6	6,4/6,4	3,6/3,6	5,7/6,4	6,7/6,8	6,9/7,3	3,8/3,9	8,4/9,1	13,3/13,9	13,8/16,1

Ненадёжно — как TwoNN: eps, d = 15: 4,4–4,6 / 8,0–8,2 / 9,0–9,2 / 7,8–8,1.

9.5. Hidalgo + BERT без сжатия (256)

слова

m	эталон	eps, d=256	dist, d=256
2	2,0/2,1	20,6/21,8	13,1/13,5
3	2,9/2,9	29,3/29,9	56,8/79,4
4	3,8/4,0	35,1/36,9	74,2/78,1
6	5,4/5,6	37,6/38,0	74,1/76,3

биграммы

m	эталон	eps, d=256	dist, d=256
2	2,5/2,8	7,7/7,8	11,8/11,9
3	3,6/3,9	9,0/9,1	11,8/12,6
4	4,8/5,0	9,3/10,0	10,9/12,4
6	6,4/6,4	9,6/9,8	10,9/12,0

Неприменимо. eps: 21–22 / 29–30 / 35–37 / 38.

Часть III. Итог

10. Сводная картина




Рис. 1. TwoNN по словам при $d = 15$ против истинной m . Слева (eps): оба CBOW идут вдоль диагонали чуть выше неё; SVD и BERT → PCA сильно завышают, BERT не различает $m = 3-6$. Справа (dist): все эмбединги далеко от истины.




Рис. 2. TwoNN по словам в зависимости от d ; пунктир — истинная m , серая линия — «оценка = d ». Только CBOW на локальном тексте выходит на плато около m . SVD, BERT → PCA и CBOW на нелокальном тексте растут с d .

	SVD	CBOW (ВиМ)	CBOW (тетр.)	BERT → PCA	BERT 256
Швайхарт	нет	да	да	нет	нет
TwoNN	нет	да (+0,3...0,9)	да	нет	нет
FisherS	нет	нет	нет	нет	нет
Hidalgo	нет	да	да	нет	нет

Таблица: можно ли читать оценку как размерность (на локальном тексте, $d = 10-15$, при плато по d).

11. Что это значит для «Войны и мира»

- **CBOW** романа: $4,7 \rightarrow 8,9 \rightarrow 10,0$ (Швайнхарт, слова, $d = 5/10/15$) — рост без плато, как у нелокального блуждания. Значение ≈ 10 пока нельзя считать размерностью; нужно досчитать $d = 20, 30, 50$ и посмотреть, есть ли плато.
- **ruBERT** романа (PCA 15: 10,9–12,4; без сжатия: 18–27 на словах, 14,5–18,2 на биграммах). На псевдоязыке усреднённые контекстные векторы BERT завышают в 2–6 раз и не различают $m = 3–6$, поэтому эти числа вероятнее всего завышены и не являются размерностью языка. Оговорка: у нас BERT маленький и обучен на 0,9 млн токенов, ruBERT — большой и предобученный.
- **SVD** романа: не стоит читать как абсолютную размерность (рост с d , проблема крупных документов).
- **Оговорка.** Калибровка верна для текстов, где соседние слова близки в «пространстве смыслов». Насколько локализован реальный язык в этом смысле — главный открытый вопрос; его можно оценить по профилю оценок по d .

12. Дальше

- CBOW «Войны и мира» и диалогов при $d = 20, 30, 50$ — проверка плато.
- Калибровка на торах, сферах и аттракторе Лоренца с разбиением k -means / муравьиный алгоритм / случайно (идёт на HSE).
- Промежуточные блуждания между ϵ и dist ($p \propto 1/d^s$ с разными s) — где ломается восстановление.

Приложение. Воспроизводимость

Скрипты: `pseudolang.py` (задача 4370978, 8 подзадач), `pseudo_bert.py` (4371985, 8 подзадач), оценщики — `calib_trajectories.measure`, сводка `pseudo_agg.py`. На HSE: `~/wap_run/pseudo_results` (288 JSON + meta), `~/wap_run/pseudo_table.csv`; в репозитории LANC — `experiments/dimension/`. Сиды: точки 2026, тексты $8i + 2$, CBOW seed 1, BERT seed 1.