

Размерность языка диалогов по фреймам (CBOW)

Короткие диалоги двух агентов SmolLM2-135M: 3 фрейма × 24 карточки × 150 сидов, 10 реплик. CBOW отдельно на каждом фрейме → четыре оценщика. Задачи HSE 4369353 (генерация) и 4373243 (анализ), 4 октября 2026.

Главное. (1) **Фреймы не различаются:** соревнование, сотрудничество и нейтральный дают одинаковые оценки при любом d и любом методе — разница между фреймами (до 1-1,5) не больше разницы между $\min_count$ 1 и 5. (2) **Слова: плато нет.** TwoNN растёт вместе с d (4,6 → 8,7 → 11 → 13 → 15), Hidalgo тоже; Швайнхарт при $d \geq 15$ почти всегда не находит допустимых α . По калибровкам это картина «нелокального» текста или высокой размерности ($m \geq 8$), а не $m \leq 6$. (3) **Биграммы: плато есть.** Швайнхарт 8-10 при $d = 10...30$, Hidalgo 6-9, TwoNN 7,0-7,4 → 8,7-9,5 (медленный рост). (4) FisherS, как и в калибровках, неинформативен (11-12 на биграммах при любом $d \geq 10$). Ответ на исходный вопрос MVP — «отличается ли геометрия языка в зависимости от фрейма» — на уровне общей внутренней размерности CBOW-облака: **нет**.

1. Данные и методы

Диалоги. Протокол MVP: два агента SmolLM2-135M, 24 карточки-стимула × 3 фрейма (competition / cooperation / neutral) × сиды 1...150 = 10 800 диалогов по 10 реплик, CPU-кластер HSE. Сгенерированы все 10 800 (по 3600 на фрейм).

Корпуса по фреймам (spaCy en_core_web_sm, леммы; имена собственные → <PROPN>, числа → <NUM>):

фрейм	диалогов	предложений	токенов	типов (лемм)	доля n-грамм
соревнование	3600	98 475	660 732	6108	20,6 %
сотрудничество	3600	89 954	641 005	5966	18,1 %
нейтральный	3600	100 743	696 301	6365	19,9 %

Эмбединг. CBOW с настройками «Войны и мира» (gensim Word2Vec, sg = 0, окно 5, negative 5, 30 эпох, seed 1), обучен отдельно для каждого фрейма, двумя вариантами словаря: **min_count 1** (все леммы, ~6000) и **min_count 5** (~3700-3800). $d = 5, 10, 15, 20, 30$ — шире, чем в «Войне и мире», чтобы проверить плато. Биграммы — конкатенация векторов двух соседних лемм (размерность $2d$), по всем уникальным парам внутри предложений; для оценки — случайные 10 000.

Оценщики — те же, что в калибровках на псевдоязыке и траекториях: Швайнхарт (MST / PH_0 , 2 лестницы, диапазон min-max по допустимым α ; «нет α » — ни одна лестница не прошла проверку), TwoNN, FisherS, Hidalgo (две компоненты, min/max). Код: dialogue_cbow.py, dialogue_dims.py.

Как читать. По калибровкам (псевдоязык, траектории) надёжная пара — CBOW + Швайнхарт / TwoNN / Hidalgo, и признак надёжности — плато по d при $d \geq 10$. Если оценка растёт вместе с d , она показывает размер вектора, а не геометрию текста. Зелёным выделены $d = 15, 20, 30$.




Рис. 1. Оценка в зависимости от d. Слева — слова (TwoNN): рост без плато. В центре и справа — биграммы: TwoNN растёт медленно, Швайнхарт выходит на плато ≈ 9 . Линии фреймов практически совпадают.

2. Швайнхарт + CBOW

слова

фрейм	min_count	N слов	слова d=5	слова d=10	слова d=15	слова d=20	слова d=30
соревнование	1	6108	4,3-4,7	9,0-9,0	нет α	нет α	нет α
соревнование	5	3684	4,5-4,8	8,2-8,5	нет α	нет α	нет α
сотрудничество	1	5966	4,6-5,3	нет α	нет α	нет α	нет α
сотрудничество	5	3765	4,1-5,0	9,2-9,5	нет α	нет α	нет α
нейтральный	1	6365	4,2-5,1	нет α	нет α	нет α	нет α
нейтральный	5	3824	4,4-4,7	нет α	11,7-12,2	нет α	нет α

биграммы (случайная подвыборка 10 000 из всех уникальных пар соседних лемм)

фрейм	min_count	биграммы d=5	биграммы d=10	биграммы d=15	биграммы d=20	биграммы d=30
соревнование	1	6,1-7,0	9,0-9,7	8,2-10,4	8,7-10,0	9,0-10,0
соревнование	5	6,4-7,5	8,8-9,7	8,9-10,1	нет α	8,5-10,0
сотрудничество	1	6,1-7,0	8,0-9,4	8,8-9,5	7,8-9,5	7,9-9,7
сотрудничество	5	6,3-7,5	8,8-10,0	8,6-9,8	8,5-10,0	8,7-9,7
нейтральный	1	6,2-6,9	8,0-9,8	8,1-10,3	8,8-9,5	8,3-9,7
нейтральный	5	6,4-7,5	8,7-10,0	8,8-9,7	8,6-10,0	9,3-10,0

Вывод. Слова: при $d = 5$ оценка 4,1-5,3 (потолок d), при $d = 10$ — 8,2-9,5 там, где α нашлись; при $d \geq 15$ почти везде «нет α » — длина MST не ведёт себя как степенной закон, т. е. облако слов не похоже на многообразие фиксированной размерности в этом диапазоне масштабов. Биграммы: устойчиво 7,8-10,4 при $d = 10 \dots 30$ у всех фреймов (плато).

3. TwoNN + CBOW

слова

фрейм	min_coun	N слов	слова d=5	слова d=10	слова d=15	слова d=20	слова d=30
соревнование	1	6108	4,6	8,7	10,9	12,9	14,8
соревнование	5	3684	4,4	7,8	10,6	12,3	14,8
сотрудничество	1	5966	4,7	8,4	10,9	12,8	14,7
сотрудничество	5	3765	4,4	7,9	10,2	11,9	14,1
нейтральный	1	6365	4,6	8,8	11,6	13,6	16,2
нейтральный	5	3824	4,3	8,1	11,2	12,9	15,6

биграммы (случайная подвыборка 10 000 из всех уникальных пар соседних лемм)

фрейм	min_coun		биграммы d=5	биграммы d=10	биграммы d=15	биграммы d=20	биграммы d=30
соревнование	1		5,5	7,1	7,9	8,3	8,9
соревнование	5		5,6	7,2	8,2	8,8	9,5
сотрудничество	1		5,5	7,0	7,7	8,3	8,9
сотрудничество	5		5,5	7,4	7,9	8,7	9,4
нейтральный	1		5,6	7,0	7,8	8,4	8,7
нейтральный	5		5,6	7,3	8,0	8,6	9,2

Вывод. Слова: растёт без насыщения (+0,3-0,5 на единицу d), плато нет; фреймы совпадают с точностью ± 1 . Биграммы: 7,0-7,4 $\rightarrow$ 7,8-8,2 $\rightarrow$ 8,3-8,8 $\rightarrow$ 8,7-9,5 при d = 10 $\rightarrow$ 15 $\rightarrow$ 20 $\rightarrow$ 30 — рост замедляется, но не останавливается полностью.

4. FisherS + CBOW

слова

фрейм	min_count	N слов	слова d=5	слова d=10	слова d=15	слова d=20	слова d=30
соревнование	1	6108	2,8	5,4	7,1	8,5	10,0
соревнование	5	3684	3,7	7,8	10,3	11,4	12,4
сотрудничество	1	5966	2,9	5,6	8,0	9,4	11,1
сотрудничество	5	3765	3,8	8,0	10,5	11,7	12,7
нейтральный	1	6365	2,6	5,2	6,9	8,6	10,7
нейтральный	5	3824	3,7	7,6	10,4	11,5	13,1

биграммы (случайная подвыборка 10 000 из всех уникальных пар соседних лемм)

фрейм	min_count		биграммы d=5	биграммы d=10	биграммы d=15	биграммы d=20	биграммы d=30
соревнование	1		7,4	10,8	11,2	11,5	11,8
соревнование	5		7,5	11,3	12,2	12,4	12,5
сотрудничество	1		7,4	10,8	11,4	11,7	11,9
сотрудничество	5		7,6	11,4	12,2	12,3	12,4
нейтральный	1		7,4	10,7	11,2	11,7	11,7
нейтральный	5		7,6	11,5	12,1	12,2	12,5

Вывод. Слова: растёт с d (2,6 → 10,7 при min_count 1; 3,7 → 13,1 при min_count 5). Биграммы ≈ 11–12,5. Как и в калибровках, FisherS после выбеливания считает шумовые оси CBOW измерениями — не использовать.

5. Hidalgo + CBOW

слова

фрейм	min_count	N слов	слова d=5	слова d=10	слова d=15	слова d=20	слова d=30
соревнование	1	6108	4,3/5,0	7,6/9,0	10,0/11,2	9,9/13,2	9,1/19,2
соревнование	5	3684	4,1/4,6	7,0/8,2	8,0/11,4	7,9/14,6	7,9/19,4
сотрудничество	1	5966	4,6/4,7	7,5/9,2	8,7/11,6	9,6/13,0	9,3/15,1
сотрудничество	5	3765	4,3/4,5	7,0/7,8	7,9/10,4	7,0/14,0	8,3/17,9
нейтральный	1	6365	4,4/4,9	7,7/9,4	10,0/12,4	11,0/13,2	10,8/17,1
нейтральный	5	3824	4,2/4,4	7,8/7,8	9,4/11,1	8,6/15,3	8,8/19,0

биграммы (случайная подвыборка 10 000 из всех уникальных пар соседних лемм)

фрейм	min_count		биграммы d=5	биграммы d=10	биграммы d=15	биграммы d=20	биграммы d=30
соревнование	1		5,4/5,7	6,0/7,7	6,8/7,3	6,4/8,1	6,8/7,4
соревнование	5		5,4/5,9	7,3/7,3	7,8/8,0	8,1/8,1	7,5/7,8
сотрудничество	1		5,7/5,8	6,7/7,2	6,9/7,0	6,7/7,7	6,6/7,7
сотрудничество	5		5,7/5,8	7,3/7,4	7,2/8,1	7,9/8,1	7,9/8,8
нейтральный	1		5,5/6,0	6,8/6,9	6,4/7,4	6,7/7,4	6,9/7,0
нейтральный	5		5,6/5,8	7,3/7,4	7,6/7,6	7,5/8,3	7,6/8,1

Вывод. Слова: две компоненты расходятся с ростом d (при d = 30: 8–11 и 15–19) — облако слов неоднородно по размерности. Биграммы: обе компоненты 6–8,8 и почти не меняются от d = 10 до 30 — плато.

6. Сравнение с калибровками

картина	псевдоязык (eps)	псевдоязык (dist)	траектории m ≤ 6	траектории m = 8–10	диалоги
слова, CBOW: плато по d	да	нет	да	нет	нет
биграммы, CBOW: плато по d	да	нет	да	частично	да (Швайнхарт, Hidalgo)
Швайнхарт на словах: «нет α»	редко	редко	редко	иногда	почти всегда при d ≥ 15

- Слова диалогов ведут себя как отрицательный контроль (dist-блуждание псевдоязыка) или как объекты высокой размерности (T^8 , T^{10}): оценка следует за d. Различить эти два случая по одним словам нельзя.
- Биграммы ведут себя как у «хороших» калибровочных объектов: плато Швайнхарта ≈ 9 , Hidalgo ≈ 7 –8, TwoNN ≈ 8 –9. На траекториях CBOW-биграммы при m = 6 давали TwoNN ≈ 9 –10, Швайнхарт ≈ 10 –11, а эталон биграмм был $\approx 1,3$ –1,5·m. Если перенести эту калибровку, биграммы диалогов соответствуют m порядка 5–7 — осторожная оценка, т. к. калибровка на траекториях сама показала смещение и не объяснила его.
- Для «Войны и мира» картина была та же: слова CBOW росли с d, биграммы попадали в диапазоны статьи. То есть поведение диалогов модели не уникально

— это общее свойство CBOW-облаков на реальном языке.

- Различий между фреймами нет ни на словах, ни на биграммах. Это согласуется с MVP: фрейм меняет лексику (топ слов почти одинаков: provide, ensure, need, share, help), но не общую размерность облака.

7. Что дальше

- **Сдвиг PCA по слоям (E9):** калибровка базисов 4372011 стоит в очереди (низкий приоритет, nice 20000), за ней короткие и длинные диалоги с rsa_32 после каждого из 30 слоёв. Их CBOW-размерность сравним с этой таблицей (нейтральный фрейм) — это контроль identity.
- **Длинные диалоги** (216 по 10 000 слов, готовы): тот же анализ на корпусе длинных текстов — проверить, появится ли плато на словах при более длинном контексте.
- **Тест различия фреймов чувствительнее общей размерности:** локальная размерность (по словам, общим для трёх фреймов), бутстреп по диалогам для доверительных интервалов.

Приложение. Воспроизводимость

Генерация: hse_short_dialogues.py (run short-10turn-cbow-v1), задача 4369353 (22 процесса, 4,2-6,6 ч каждый). Анализ: hse_cbow_pipeline.sbatch (задача 4373243, 41 мин): export → lemmatize → dialogue_cbow.py train --min-count 1 / 5 → dialogue_dims.py. Результаты на HSE: ~/wap_run/dialogue_dims_results/ (60 JSON), векторы — ~/lanc_run/results/short-10turn-cbow-v1/cbow/. Таблица в репозитории: experiments/dimension/results/dialogue_dims_table.csv.