

Что на самом деле известно о точности «CBOW + метод»

Сводка всех калибровок (E6, E7, E10, E12): 27 объектов с известной размерностью, ~1 500 облаков точек. 6 октября 2026.

Короткий ответ. (1) **Сырое число**, полученное CBOW + метод, от истинной m далеко: на словах TwoNN и Hidalgo дают около $2m$, Швайнхарт около $1,6m$; на биграммах TwoNN около $1,6m$, Hidalgo $1,7m$, Швайнхарт $2m$. Ошибка сырого числа — 60–100 %. (2) **После поправки**, выученной на калибровке, m восстанавливается с типичной ошибкой 6–17 % и в 90 % случаев не хуже 21–36 % — **но только если текст порождён процессом того же типа, что и калибровочные** (броуновское блуждание по гладкому многообразию, разбитому на ячейки). (3) Как только меняется сам процесс порождения, поправка перестаёт работать: на псевдоязыке (другой генератор, ни разу не участвовавший в обучении поправки) все методы занижают m на 34–56 %; ципфовские частоты сдвигают биграммы TwoNN/Hidalgo на –33 %. (4) Мы не знаем, к какому семейству принадлежит язык, поэтому **доказанной точности для текста у нас нет**. Честная оценка сейчас — «в пределах ± 25 %, если язык похож на калибровку, и до двух раз, если нет». Для «Войны и мира» слова дают $m \approx 6$ –9, биграммы ≈ 3 –4,5 — расхождение больше ± 25 %, и это само по себе признак, что текст за пределами семейства. (5) Самый устойчивый метод — **Швайнхарт** (наименьший разброс поправки и наименьшие сдвиги при смене условий), FisherS для этой задачи непригоден.

1. Что здесь считается доказательством

Слова «завышает в 1,5–2,5 раза» в прошлых отчётах — это **описание того, что мы видели** на конкретном наборе условий, а не закон. Доказать закон можно было бы только теоремой (её нет) или проверкой на всех мыслимых процессах (невозможно). Что можно сделать честно — это три уровня утверждений, и ниже для каждого числа указано, к какому уровню оно относится:

- **Описание:** «в наших N конфигурациях отношение лежало в таких-то пределах». Верно ровно для этих конфигураций.
- **Перенос на новый объект** (проверка с выбрасыванием): поправку учим на всех объектах, кроме одного, и проверяем на выброшенном. Это оценивает, насколько хорошо поправка работает на *новом объекте того же типа*.
- **Перенос на новые условия:** учим на всех семействах условий, кроме одного (например, кроме всех ципфовских), и проверяем на нём. Это ближе всего к ситуации с языком: у него заведомо есть свойства, которых не было в обучении.

Важно: конфигурации не независимы. Это 15 объектов броуновского типа (торы T^2 – T^{12} , сферы S^2 – S^{12} , кубы с дырами $m = 2$ –6 из псевдоязыка), каждый в 10–40 вариантах. Эффективный размер выборки — число объектов и семейств условий, а не 1 500 облаков. Поэтому для медианы отношения указан 95 %-интервал бутстрепом по объектам.

2. Сами методы, без CBOW: на точных координатах

Если вместо векторов CBOW взять истинные координаты центров ячеек, методы работают так (броуновские объекты, все условия):

метод	слова: оценка / m медиана	10-90 %	мин-макс	биграммы: оценка / m медиана	10-90 %	мин-макс	N
TwoNN	1,00	0,97-1,05	0,91-1,21	1,41	1,20-1,59	0,98-2,08	112
Hidalgo	1,00	0,97-1,05	0,92-1,18	1,47	1,25-1,65	0,99-2,11	112
Швайнхарт	1,02	0,93-1,12	0,81-1,34	1,58	1,36-1,84	1,10-2,35	112
FisherS	1,56	1,04-1,71	0,65-1,73	1,72	1,24-2,67	0,93-2,96	112

Табл. 1. Уровень «описание», 112 облаков на 15 объектах.

- **TwoNN, Hidalgo, Швайнхарт на словах точны:** медиана 1,00-1,02, 80 % случаев в пределах $\pm 5-12$ %. Значит, всё завышение дальше — от эмбединга, а не от метода.
- **FisherS неверен уже на точных точках** (1,56m на словах, большой разброс) — дальше его не рассматриваем.
- **Биграммы и на точных координатах дают не 2m, а $\approx 1,4-1,6m$:** соседние по тексту слова лежат рядом, облако пар прижато к «диагонали». Это свойство самих биграмм броуновского текста, а не ошибка метода (проверяется в E13).

3. Влияние размерности CBOW d




Рис. 1. Отношение «оценка / m» в зависимости от d (броуновские объекты; линия — медиана, полоса — 10-90 %).

- При $d = 5$ все методы **занижают** (медиана $\approx 0,7m$): для $m > 5$ векторам не хватает измерений.
- С $d = 15$ начинается плато: на словах $15 \rightarrow 30 \rightarrow 100$ медиана TwoNN $1,88 \rightarrow 2,07 \rightarrow 2,11$, Швайнхарта $1,55 \rightarrow 1,67 \rightarrow 1,65$; на биграммах $1,6-1,7$ и $\approx 2,0$ и почти не меняется. Для $m = 10-12$ плато наступает лишь около $d \approx 50$ ($\approx 2m$, E10).
- Значит, **d надо брать ≥ 15 и $\geq 2m$** ; дальше сравниваем $d = 15$ и 30 .

4. CBOW + метод: насколько сырое число далеко от m




Рис. 2. Отношение «оценка / m»: голубое — точные координаты, оранжевое — CBOW d = 15 и 30. Ящик — 25-75 %, усы — 5-95 %, точки — выбросы.

метод	n-граммы	медиан а	95 %-интервал медианы (по объектам)	10-90 % конф игураций	мин-макс	N
TwoNN	слова	1,97	1,63-2,23	1,48-2,46	1,06-4,15	219
Hidalgo	слова	2,00	1,64-2,25	1,49-2,48	1,07-5,20	219
Швайнхарт	слова	1,61	1,48-1,72	1,32-1,91	1,04-3,86	206
TwoNN	биграммы	1,63	1,42-1,98	1,25-2,09	1,01-2,75	219
Hidalgo	биграммы	1,74	1,48-1,93	1,33-2,20	0,97-2,81	219
Швайнхарт	биграммы	1,96	1,70-2,04	1,60-2,14	1,27-3,03	208

Табл. 2. Броуновские объекты (15), CBOW d = 15 и 30. Уровень «описание».

Отношение зависит от m. Ранговая корреляция «отношение — m» отрицательная для всех методов (слова: TwoNN $-0,73$, Hidalgo $-0,71$, Швайнхарт $-0,49$; биграммы $-0,69$ / $-0,69$ / $-0,54$): чем больше m, тем меньше завышение. Медиана по словам, TwoNN: m = 2 — 2,44; m = 4 — 2,08; m = 6 — 1,81; m = 8 — 1,54; m = 12 — 1,30. У Швайнхарта зависимость слабее: 1,76 / 1,62 / 1,58 / 1,33 / 1,23. Поэтому «умножить на одно число» — грубое приближение; лучше обратная модель $\log(\text{оценка}) = a + b \cdot \log m$.

Отказы Швайнхарта. На CBOW-словах броуновских объектов он не находит допустимого α в 6 % облаков (при сильном Ципфе $k = 5$ — в половине), на фракталах — в 50 %. TwoNN и Hidalgo дают число всегда.

5. Другие типы объектов

тип объекта	объект ов	слова, TwoNN	слова, Швайнх.	биграммы , TwoNN	биграммы, Швайнх.	что видно
потoki (Лоренц, Рёсслер, Л-96)	4	1,88	1,89	1,60	2,07	без шума; на биграммах ближе к истине при больших D (L96: 6,6 при D = 6,55)
фракталы и мультифракталы	7	1,66	1,55	1,70	1,85	CBOW даёт 3,2-4,1 для всех $D \leq 3$ — «пол»; отношение бессмысленно
псевдоязык, дальнее блуждание	4	2,64	2,36	3,00	3,18	нелокальное блуждание (шаг 4-8 расстояний до соседа)

тип объекта	объект ов	слова, TwoNN	слова, Швайх.	биграммы , TwoNN	биграммы, Швайх.	что видно
многообразия, центры k-means	10	2,33	1,67	1,65	1,92	регулярная решётка центров ломает TwoNN/Hidalgo

Табл. 3. Медианы «оценка / истинная размерность», CBOW d = 15 и 30.

Отсюда: множитель зависит не только от m , но и от **типа процесса**. Для языка это главное: тип процесса мы не знаем. По E11 текст ближе к броуновскому типу ($E_2 \approx 1$, размерность k -грамм растёт с k), но это необходимое, а не достаточное условие.

6. Главный вопрос: насколько близко к правде будет число после поправки

Поправка — обратная модель $\log(\text{оценка}) = a + b \cdot \log m$, обученная на калибровке; её применяют к измерению и получают $\hat{m}$. Ниже — ошибка $|\hat{m} / m - 1|$.

метод	n-граммы	без поправки медиана	постоянный множитель медиана / 90 %	обратная модель медиана / 90 %	объектов / облаков
TwoNN	слова	97 %	15 % / 32 %	10 % / 34 %	15 / 219
Hidalgo	слова	100 %	17 % / 34 %	12 % / 36 %	15 / 219
Швайнхарт	слова	61 %	9 % / 25 %	7 % / 28 %	15 / 206
TwoNN	биграммы	63 %	10 % / 34 %	9 % / 35 %	15 / 219
Hidalgo	биграммы	74 %	10 % / 33 %	10 % / 33 %	15 / 219
Швайнхарт	биграммы	96 %	6 % / 25 %	8 % / 21 %	15 / 208

Табл. 4. Перенос на новый объект того же типа (поправка учится без проверяемого объекта). CBOW d = 15 и 30.

На новом объекте того же типа ошибка после поправки — 6–17 % в типичном случае, в 90 % случаев до 21–36 %. Теперь жёстче: выбрасываем целое **семейство условий** и смотрим систематический сдвиг $\hat{m}$ на нём.

выброшенное семейство условий	слова TwoNN	слова Hidalgo	слова Швайх.	биграммы TwoNN	биграммы Hidalgo	биграммы Швайх.
E6, разбиение random	-3 %	-2 %	-3 %	+0 %	+2 %	-2 %
E6, разбиение aso	-2 %	-1 %	-1 %	+1 %	+3 %	-2 %
E10, база	-2 %	-1 %	-4 %	+0 %	+0 %	-2 %
E10, сетка по V	+1 %	-4 %	-2 %	+5 %	+2 %	-1 %
E10, сетка по числу траекторий	-2 %	+1 %	+1 %	+6 %	+7 %	+6 %
E12, база	-0 %	-1 %	-5 %	-1 %	+1 %	-2 %
E12, длина предложения / окно	+1 %	+2 %	-6 %	+1 %	+2 %	-2 %
E12, шаг $\times 0,5 / 2 / 3$	+10 %	+11 %	+6 %	+24 %	+21 %	+12 %
E12, $V = 18\,000$	-25 %	-32 %	-7 %	+10 %	+2 %	-5 %
E12, Ципф $k=1,5$	-5 %	-4 %	+8 %	-18 %	-15 %	+4 %
E12, Ципф $k=3$	+4 %	+5 %	+13 %	-33 %	-33 %	-14 %
E12, Ципф $k=5$	+12 %	+15 %	+17 %	-36 %	-33 %	-7 %
другой генератор (псевдоязык, E7)	-55 %	-56 %	-37 %	-38 %	-34 %	-35 %

Табл. 5. Медианный сдвиг $\hat{m}$ (знак: + — завышение, — — занижение) на семействе условий, которого не было в обучении поправки. Выделены условия, самые похожие на язык или прямо отличные от

калибровки.

- Смена разбиения, числа траекторий, длины предложения, окна CBOW — сдвиг в пределах $\pm 7\%$: к этим условиям поправка устойчива.
- Шаг блуждания: $+6\ldots+24\%$ в медиане, в отдельных случаях до 2–3 раз.
- Размер словаря $V = 18\,000$: слова TwoNN/Hidalgo $-25\ldots-32\%$, Швайнхарт -7% .
- Ципфовские частоты: на словах TwoNN/Hidalgo до $+12\ldots+15\%$, Швайнхарт $+8\ldots+17\%$; на биграммах TwoNN/Hidalgo $-15\ldots-36\%$, Швайнхарт $-14\ldots+4\%$.
- **Другой генератор** (псевдоязык E7: куб с дырами, другие длины текстов, шаг 1,5 ячейки) — все методы **$-34\ldots-56\%$** . Это единственная по-настоящему внешняя проверка, и её поправка не прошла.

7. Что это значит для «Войны и мира»

Применим обратную модель, обученную на всех броуновских объектах (CBOW $d = 15$), к числам «Войны и мира»:

метод	слова: измерено $\rightarrow \hat{m}$	биграммы: измерено $\rightarrow \hat{m}$
TwoNN	12,95 $\rightarrow$ 9,0	6,6 (10 тыс.) $\rightarrow$ 4,0
Hidalgo	12,7 $\rightarrow$ 8,8	$\approx$ 6,2 (две части 4,3 и 8,1) $\rightarrow$ 3,4
Швайнхарт	9,5–10,4 $\rightarrow$ 7,0	6,3–10,4 $\rightarrow$ 4,4

Слова дают 7–9, биграммы 3,4–4,4 — разница вдвое при ожидаемой ошибке $\pm 25\%$. Если бы текст был «как калибровка», слова и биграммы совпадали бы. Значит, к тексту поправка в нынешнем виде неприменима, и любое одно число m сейчас — не измерение, а догадка с ошибкой до двух раз. Интервал, совместимый со всеми методами, — **$m \approx 3,5-9$** .

8. Что нужно, чтобы получить доказанную точность

- **Внешняя проверка.** Поправку можно признать работающей, только если она проходит на генераторе, который не участвовал в обучении. Сейчас один такой (псевдоязык) — и он не прошёл. Нужно понять, что именно его отличает (длины текстов, форма, шаг), и добавить ещё 2–3 разных генератора.
- **Измеримые признаки текста** (шаг p , наклон Ципфа, V , доля редких слов), которые одинаково считаются на калибровке и на тексте, — чтобы поправка зависела не только от измеренной размерности, но и от того, «каким процессом» порождён текст (E13).
- **Необходимое условие согласия:** слова, биграммы и разные методы после поправки должны давать одно m . Если не дают — текст вне семейства, и число не публикуется как оценка.
- **Шум редких слов:** проверить, убирает ли фильтр по частоте основную часть завышения на словах (дешёвый тест, этап 2 E13).
- **Метод:** основным брать Швайнхарта (самый устойчивый), TwoNN и Hidalgo — как контроль; FisherS исключить.

Приложение: данные

Е6 — торы T^2 – T^{10} , сферы S^2 – S^8 , Лоренц; разбиения random / асо / k-means; CBOW и SVD $d = 5$ – 30 . Е7 — псевдоязык: куб $[0,1]^m$ без 4 шаров, $m = 2, 3, 4, 6$; блуждания eps (локальное) и dist (дальнее). Е10 — торы до T^{12} , сферы до S^{12} , потоки, фракталы, мультифракталы; d до 100; сетки по V и числу траекторий. Е12 — T^2 , T^4 , T^6 , S^4 , $S^8 \times 12$ вариантов (шаг, Ципф, V , длина предложения, окно). Для Швайнхарта в Е6/Е7/Е10 взята середина диапазона по допустимым α , в Е12 — медиана; для Hidalgo — среднее двух частей. Сводная таблица: results/calib_pooled.csv; код: code/calib_synthesis.py.