

Насколько устойчив множитель завышения CBOW (эксперимент E12)

Вопрос: «почему мы уверены, что внутри броуновской группы всегда завышение в 1,5–2,5 раза?». Задача HSE 4378998, 60 конфигураций (5 объектов × 12 вариантов), 360 облаков точек, 6 октября 2026.

Коротко. (1) **Не всегда.** На словах (CBOW $d = 15$, TwoNN) множитель от 1,24 до 3,78, при $d = 30$ — до 4,15. Полоса 1,5–2,5 — это базовые условия, а не закон. (2) **Не влияют** длина предложения (10/20/40) и окно CBOW (2/5/10): сдвиг не больше 0,2. (3) **Влияют:** размер словаря V (больше слов — меньше завышение: при $V = 18\,000$ множитель 1,2–1,9), длина шага блуждания (шаг $\times 3$ — до 2,3 при $d = 15$ и до 3,9 при $d = 30$) и **неравномерность частот слов**, но заметно только при малых m (T^2 : 2,4 → 3,8). Сам множитель падает с ростом m (S^8 : 1,2–1,5; T^2 : 1,9–3,8). (4) Биграммы ведут себя иначе: оценка близка к $2m$ или **ниже** (0,5–1,2 от $2m$), и чем сильнее перекося частот, тем ниже. (5) Для «Войны и мира» ($V = 17\,900$, наклон Ципфа $-1,20$, как у варианта $k = 5$) разные калибровки дают m от 3 до 13: по словам 7–13, по 10 тыс. биграмм 3–6, по всем биграммам 5,5–8,6. **Слова и биграммы противоречат друг другу:** модель «броуновское блуждание + ячейки» описывает текст лишь частично, и одним множителем m языка не получить.

1. Что меняли

Объекты T^2 , T^4 , T^6 , S^4 , S^8 (истинная $m = 2, 4, 6, 4, 8$). База — как в калибровке раунда 2: 500 траекторий × 1500 шагов, $V = 5000$ ячеек-слов, предложения по 20 слов, CBOW с окном 5, шаг блуждания примерно равен размеру ячейки, ячейки одинаковые. Каждый раз меняли один фактор: шаг $\times 0,5 / 2 / 3$; неравномерные ячейки (центры гуще там, где гладкое случайное поле больше; сила $k = 1,5 / 3 / 5$, наклон «ранг — частота» $-0,5 / -0,9 / -1,2$ против $-0,15$ в базе); $V = 18\,000$ (как в «Войне и мире»); длина предложения 10 / 40; окно CBOW 2 / 10. Векторы: истинные координаты центров и CBOW $d = 15$ и 30; облака слов (до 5000 точек) и биграмм (до 10 000, плюс TwoNN по всем уникальным биграммам, до 200 000). Множитель = оценка / m (для биграмм — оценка / $2m$).

2. Множитель на словах и биграммах




Рис. 1. Множитель завышения TwoNN по CBOW $d = 15$. Слева — слова (жёлтая полоса — «1,5–2,5»), справа — биграммы (пунктир — точное значение).

вариант	T^2	T^4	S^4	T^6	S^8	$d = 30$, T^6	Hidalgo, T^2	Швайнхар т, T^2
база	2,43	2,03	1,97	1,79	1,48	1,91	2,42	1,77
шаг $\times 0,5$	2,45	2,13	2,04	1,83	1,45	1,90	2,48	1,93
шаг $\times 2$	2,23	2,17	1,98	1,88	1,47	3,09	2,25	1,68
шаг $\times 3$	2,33	2,33	2,22	2,23	1,54	3,92	2,38	1,74
Цифф $\kappa=1,5$	2,33	1,89	1,89	1,79	1,44	1,97	2,36	1,79
Цифф $\kappa=3$	2,89	2,11	1,88	1,75	1,40	2,04	2,93	2,01
Цифф $\kappa=5$	3,78	2,25	1,94	1,81	1,40	2,14	4,24	2,06
$V = 18\ 000$	1,89	1,68	1,69	1,61	1,24	1,67	1,84	1,96
предл. 10	2,44	2,06	2,02	1,75	1,50	1,90	2,44	1,78
предл. 40	2,40	2,02	2,00	1,73	1,44	1,85	2,41	1,73
окно 2	2,65	2,08	2,10	1,83	1,50	1,94	2,64	1,81
окно 10	2,28	1,99	1,94	1,80	1,47	2,02	2,32	1,74

Табл. 1. Слова: оценка / m (TwoNN по CBOW $d = 15$, кроме трёх последних столбцов).

Hidalgo почти точно повторяет TwoNN. Швайнхарт завышает меньше (1,1–2,2), но тоже зависит от шага и перекаса частот. При $d = 30$ шаг влияет сильнее: длинный шаг ослабляет связь «соседние слова — соседние точки», и CBOW расходует лишние измерения.

Биграммы. Даже на истинных координатах облако биграмм даёт не $2m$, а 0,5–0,8 от $2m$: соседние слова лежат близко, и облако пар «сплющено» вдоль диагонали. CBOW добавляет к этому лишь 10–30 %. Перекас частот делает облако ещё тоньше ($\kappa = 5$: 0,5–0,6 от $2m$). Поэтому биграммы почти не завышают, но и $2m$ не показывают.

3. Что это значит для «Войны и мира»

Те же измерения на «Войне и мире» (CBOW $d = 15$, тот же код): TwoNN по 5000 случайным словам — 12,95; по 10 000 биграмм — 6,6; по всем 152 568 биграммам — 9,3. Частоты: наклон Циффа $-1,20$, на 1 % самых частых слов приходится 44 % текста (в калибровке при $\kappa = 5$ — 25 %). Для каждого варианта построена зависимость $\log(\text{оценка})$ от $\log m$ по пяти объектам, и она обращена:

вариант	по словам	по 10 тыс. биграмм	по всем биграммам
база	8,5 (наклон 0,66)	3,9 (наклон 0,72)	7,1 (наклон 0,59)
шаг ×0,5	8,4 (наклон 0,65)	4,3 (наклон 0,59)	6,9 (наклон 0,60)
шаг ×2	8,0 (наклон 0,72)	3,2 (наклон 0,82)	6,1 (наклон 0,66)
шаг ×3	6,9 (наклон 0,76)	2,8 (наклон 0,78)	5,5 (наклон 0,64)
Ципф $\kappa=1,5$	8,8 (наклон 0,68)	4,4 (наклон 0,64)	7,8 (наклон 0,58)
Ципф $\kappa=3$	10,1 (наклон 0,50)	5,5 (наклон 0,53)	8,3 (наклон 0,56)
Ципф $\kappa=5$	13,2 (наклон 0,31)	6,2 (наклон 0,47)	8,6 (наклон 0,53)
$V = 18\ 000$	10,1 (наклон 0,73)	3,6 (наклон 0,78)	8,0 (наклон 0,65)
предл. 10	8,5 (наклон 0,65)	3,9 (наклон 0,70)	6,9 (наклон 0,59)
предл. 40	8,8 (наклон 0,64)	3,9 (наклон 0,73)	7,1 (наклон 0,60)
окно 2	8,4 (наклон 0,60)	3,8 (наклон 0,73)	6,8 (наклон 0,55)
окно 10	8,4 (наклон 0,70)	3,9 (наклон 0,75)	7,0 (наклон 0,62)

Табл. 2. Какое m дала бы «Война и мир» при каждой калибровке. Выделены варианты, ближайшие к тексту по частотам и словарю. Наклон показывает, насколько оценка чувствует m (1 — идеально, 0 — не чувствует).

- По словам выходит $m \approx 8-10$ (база и $V = 18\ 000$), а при ципфовских частотах — до 13. Но при $\kappa = 5$ наклон 0,31: оценка почти не зависит от m , и обращение неустойчиво.
- По 10 тыс. биграмм выходит $m \approx 3-6$, по всем биграммам — 5,5–8,6.
- Главный результат — расхождение слов и биграмм почти в 2 раза: в модели биграммы «отстают» от слов меньше, чем в тексте. Значит, в тексте есть то, чего нет в модели: длинные зависимости, грамматика, очень частые служебные слова.

4. Выводы и что дальше

- Множитель 1,5–2,5 — свойство базовых условий. В реалистичном диапазоне параметров он 1,2–4. Самые сильные факторы — V , шаг и перекося частот.
- Перекося частот, как у настоящего текста, одновременно увеличивает завышение на словах и уменьшает чувствительность к m — по словам CBOW при таких частотах m восстанавливается плохо.
- Для языка честный ответ сейчас — интервал $m \approx 5-10$ (центр около 7), с оговоркой, что броуновская модель описывает текст неполностью.
- Следующий шаг — калибровка, совпадающая с «Войной и миром» сразу по $V \approx 18\ 000$, наклону Ципфа $-1,2$, доле частых слов 44 % и числу биграмм ≈ 150 тыс., на объектах $m = 4-12$. Если слова и биграммы и там разойдутся, нужна модель с памятью (не марковское блуждание).