

«Война и мир»: внутренняя размерность текста

Воспроизведение на одном романе протокола из статьи «A Language and Its Dimensions: Intrinsic Dimensions of Language Fractal Structures» (Complexity, 2024): векторы SVD, CBOW и ruBERT; n-граммы; методы Швайнхарта, TwoNN, FisherS и Hidalgo. Расчёты — суперкомпьютер НИУ ВШЭ CHARISMa, сентябрь 2026.

Главное в пяти пунктах

1. Метод Швайнхарта реализован точно (точное MST, сверено со scipy) и проверен на фигурах известной размерности: ошибка на кубах, сфере и ковре Серпинского от 0,4 до 12%.
2. С векторами SVD, построенными по методике статьи, размерности «Войны и мира» ниже её значений на 25–45%. Причина — в данных: в статье корпус из 6 429 текстов, у нас 361 глава одного романа, и 46,5% лемм встречаются только в одной главе (их SVD-векторы лежат на 361 «луче»).
3. **С векторами CBOW биграммы романа попадают внутрь диапазонов статьи (Табл. 5) при $d = 5, 10, 15$** — это наиболее близкое к статье, что можно получить на одном тексте.
4. Самый согласованный результат между методами — биграммы полного ruBERT-768: Швайнхарт 14,5–18,2, TwoNN 13,9, Hidalgo 14,2/15,0.
5. Размерность, как и в статье, дробная и растёт с d ; с длиной n-граммы растёт для SVD, CBOW и BERT→PCA. FisherS — наименее надёжный из методов.

1. Данные и предобработка

- Текст: war_and_peace_ru.txt, SHA-256 14935bc6...73c2 (проверяется скриптом). 361 глава — 361 «документ» для матрицы слово × документ.
- Удалены редакторские примечания (всё после «ПРИМЕЧАНИЯ») и номера сносок [n]; заголовки глав (римские цифры) — разделители.
- Лемматизация natasha 1.5; имена собственные → <PROPN>, числа → <NUM>; стоп-слова: служебные части речи и список NLTK (151 слово); французские фрагменты отброшены.
- Итог: **17 900 лемм, 152 568 уникальных биграмм и 193 693 триграммы** (соседние леммы внутри предложения). n-грамма = конкатенация векторов слов, как в статье (биграмма при $d = 10$ — точка в 20-мерном пространстве).

2. Векторы слов

Векторы	Как получены	Размерность
SVD (методика статьи)	$s_{ij} = (1-\epsilon) \cdot k_{ij} / \sum_j k_{ij}$, (ϵ — энтропия слова по главам), точное SVD, строки U . 17 900 лемм дают лишь 10 378 различных векторов: редкие слова одной главы совпадают.	5 / 10 / 15
CBOW (Табл. 5 статьи)	gensim 4.3 на HSE, window 5, negative 5, 30 эпох, seed 1, отдельная модель на каждое d .	5 / 10 / 15

Векторы	Как получены	Размерность
ruBERT → PCA	DeepPavlov/rubert-base-cased, последний слой; вектор леммы = среднее по всем 259 934 вхождениям (окна ≤ 512 токенов внутри главы, 0 потерянных вхождений); PCA объясняет 12 / 19 / 25% дисперсии.	5 / 10 / 15
ruBERT-768	те же векторы без сжатия	768 (биграммы 1536, триграммы 2304)

3. Методы оценки размерности

Подробное объяснение с примерами — отдельный файл *metody_razmernosti_obyasnenie.pdf*. Кратко:

- **Швайнхарт** (основной, как в статье). Для выборки из n точек строится минимальное остовное дерево; $E_\alpha = \sum |e|^\alpha$, $\ln E = \ln C + (1 - \alpha/d) \cdot \ln n$, откуда $d = \alpha / (1 - \text{наклон})$. $\alpha = 10^{-4}, 0,1 \dots 10$; α допустимо, если 95% ДИ и для d , и для наклона не шире 10%. Лестница из 10 вложенных выборок от $N/16$ до N , 3 случайные лестницы; в таблицах — $\min\text{-max } d$ по допустимым α . Точное евклидово MST алгоритмом Прима (numba/CPU или torch/GPU в float64), одно дерево на размер для всех α .
- **TwoNN** (Facco et al., 2017): отношение расстояний до второго и первого соседа; 10% крайних отношений отбрасываются; дополнительно — прореживание N , $N/2 \dots N/32$ для проверки зависимости от масштаба.
- **FisherS** (Albergante et al., 2019): доля точек, линейно отделимых от остальных после центрирования, отбеливания и проекции на сферу; до 30 000 случайных точек.
- **Hidalgo** (Allegra et al., 2020): смесь двух многообразий разной размерности ($K = 2, q = 3, \zeta = 0,8, 10\,000$ итераций Гиббса); показывает, однородно ли облако. 5 000 случайных точек.
- TwoNN и FisherS совпадают с пакетом scikit-dimension до последнего знака; Hidalgo — перенос авторского gibbs.c.

Как читать диапазон Швайнхарта «a-b». Лестница — 10 вложенных случайных подвыборок облака (от $1/16$ до всех точек); сид — номер, фиксирующий, какие точки попали в лестницу. Расчёт повторён на трёх лестницах (сиды 1, 2, 3). Каждое допустимое α даёт свою оценку d . В таблицах **a** — самая маленькая, **b** — самая большая оценка среди всех допустимых α на всех лестницах, у которых допустимые α нашлись. Пример (биграммы BERT-768): лестницы дают 14,50–17,66, 14,68–17,68 и 14,57–18,20, в таблице — 14,50–18,20. Правило одинаково для всех векторов и всех таблиц отчёта.

4. Проверка на фигурах известной размерности

фигура	истина	Швайнхарт	TwoNN	FisherS	Hidalgo d_1 / d_2
куб 5D	5	4,62–4,82	4,80	4,81	4,73 / 4,77
куб 8D	8	7,03–7,27	7,38	7,56	7,13 / 7,19

фигура	истина	Швайнхарт	TwoNN	FisherS	Hidalgo d_1 / d_2
сфера S^6	6	5,91–5,95	5,93	7,00	5,64 / 6,48
ковёр Серпинского	1,893	1,88–1,90	1,88	1,94	1,83 / 1,87
Swiss roll	2	—	1,96	2,88	1,91 / 2,05
смесь 2D + 6D	2 и 6	—	3,11	0,92	2,06 / 5,70

Фигуры вложены в 15-мерное пространство. TwoNN, FisherS и Hidalgo — 20 000 точек; Швайнхарт — 50 000 точек, одна лестница (диапазон по допустимым α).




Рис. 1. Относительная ошибка на фигурах. Все методы слегка занижают размерность больших кубов (известный эффект конечной выборки); FisherS завышает изогнутые поверхности. Hidalgo — единственный, кто разделил смесь 2D + 6D.

Швайнхарт для 30-мерного вложения тех же фигур (тоже 50 000 точек) даёт те же числа (сфера 5,93–6,00, Серпинский 1,87–1,90), то есть оценка не зависит от размерности объемлющего пространства.

5. Швайнхарт на векторах SVD — прямое сравнение с Таблицей 4

Задача HSE 4363712 (16 ядер, 61 мин). «Все точки» — как в статье (каждая уникальная n -грамма — точка); «без дубликатов» — совпадающие векторы склеены. Диапазоны — по правилу из раздела 3 (min и max по всем лестницам).

n -граммы	d	ВиМ, все точки	ВиМ, без дубликатов	статья, Табл. 4
слова	5	1,51–3,92 ¹	3,29–4,17 ¹	4,65–5,52
слова	10	2,40–3,75 ²	5,37–6,13 ²	7,14–8,20
слова	15	3,30–4,79 ²	6,21–7,17 ²	9,81–12,78
биграммы	5	3,46–3,98	3,59–3,91	5,11–7,79
биграммы	10	4,40–5,16	4,38–5,28	6,48–8,52
биграммы	15	4,96–5,77	4,80–5,88	8,26–10,70

¹ допустимые α есть у 2 из 3 лестниц; ² у 1 из 3 (тогда диапазон — по одной лестнице).

Качественно картина совпадает со статьёй: размерность дробная и растёт с d . Количественно значения для романа ниже на 25–45%. Для слов допустимых α мало (0,2–0,6) и они есть лишь у части лестниц (при $d = 5$ у двух из трёх, при $d = 10$ и 15 у одной) — оценка неустойчива; биграммы устойчивы (допустимые α есть во всех трёх лестницах, их границы расходятся не более чем на 0,7). Дело не в

объёме вычислений, а в корпусе: SVD по 361 главе кладёт редкие слова одной главы на общий луч (см. раздел 7, Hidalgo).

6. Другие векторы: CBOW и ruBERT

Задачи HSE 4364103, 4364182 (CBOW), 4364206 (BERT→PCA), 4364265 и 4365040 (BERT-768). Швайнхарт, три лестницы, min-max по сидам.

н-граммы	d (пространство)	CBOW	статья, CBOW (Табл. 5)	BERT→PCA	статья, SVD (Табл. 4)
слова	5 (5)	4,24–5,18	4,45–4,62	5,05–5,38	4,65–5,52
слова	10 (10)	7,85–9,91 ¹	5,04–7,18	8,79–9,62	7,14–8,20
слова	15 (15)	9,51–10,43 ²	5,98–9,57	10,87–12,40	9,81–12,78
биграммы	5 (10)	5,03–6,15	3,82–6,79	6,71–9,66	5,11–7,79
биграммы	10 (20)	5,94–8,96	4,85–9,43	8,88–15,40	6,48–8,52
биграммы	15 (30)	6,34–10,41	5,73–10,51	9,72–16,81	8,26–10,70
триграммы	5 (15)	6,98–9,67	—	9,25–12,69	—
триграммы	10 (30)	7,61–12,54	—	11,63–18,63	—
триграммы	15 (45)	7,81–12,45	—	12,69–20,79	—

¹ допустимые α есть у 2 из 3 лестниц; ² у 1 из 3. Для BERT в статье аналога нет, справа для ориентира приведены значения статьи для SVD.




Рис. 2. Швайнхарт на «Войне и мире» (синий) и диапазоны из статьи (оранжевый). SVD — вариант без дубликатов. CBOW-биграммы целиком внутри диапазонов статьи.

Полный ruBERT-768. Слова (768 измерений): 17,99–24,92 и 18,98–26,81 (у третьей лестницы нет допустимых α), $N = 17\,900$. **Биграммы (1536 измерений): 14,50–17,66 / 14,68–17,68 / 14,57–18,20**, допустимы почти все α 0,1–10, медиана $\approx 15,6$ у всех трёх лестниц — самая устойчивая оценка исследования. Триграммы (2304 измерения, 1 лестница): 14,98–22,82, медиана 18,7. Для слов оценка выше, чем для биграмм, — вероятно, смещение малой выборки (17,9 тыс. точек в 768 измерениях).




Рис. 3. Рост размерности с длиной n-граммы. Для CBOW, BERT→PCA и SVD она растёт или не падает; у полного BERT-768 порядок другой: слова > триграммы > биграммы.

7. Все методы вместе (слова и биграммы)

Задача HSE 4365900. Швайнхарт для SVD — вариант без дубликатов, как и у остальных методов. Hidalgo — размерности двух частей (в скобках доля меньшей, если части сильно различаются).

n	векторы	d	Швайнхарт	TwoN N	Fisher S	Hidalgo	статья
слова	SVD	5	3,29–4,17 ¹	4,18	2,07	0,59 (32%) / 4,96	4,65–5,52
слова	SVD	10	5,37–6,13 ²	5,89	3,89	0,28 (16%) / 6,90	7,14–8,20
слова	SVD	15	6,21–7,17 ²	6,88	5,16	0,24 (13%) / 7,66	9,81–12,78
слова	CBOW	5	4,24–5,18	5,03	3,13	4,96 / 5,22	4,45–4,62
слова	CBOW	10	7,85–9,91 ¹	9,73	5,88	9,33 / 9,42	5,04–7,18
слова	CBOW	15	9,51–10,43 ²	13,33	8,39	12,65 / 12,83	5,98–9,57
слова	BERT→PCA	5	5,05–5,38	5,03	4,60	5,02 / 5,07	—
слова	BERT→PCA	10	8,79–9,62	9,15	8,39	8,57 / 8,89	—
слова	BERT→PCA	15	10,87–12,40	11,34	10,86	10,81 / 11,74	—
слова	BERT-768	768	17,99–26,81 ₁	13,71	16,27	16,00 / 19,03	—
биграммы	SVD	5	3,59–3,91	3,97	3,59	2,89 / 4,95	5,11–7,79
биграммы	SVD	10	4,38–5,28	5,89	5,31	3,52 / 6,26	6,48–8,52
биграммы	SVD	15	4,80–5,88	7,21	6,20	3,38 / 7,01	8,26–10,70
биграммы	CBOW	5	5,03–6,15	4,97	6,61	4,74 / 5,57	3,82–6,79
биграммы	CBOW	10	5,94–8,96	7,50	8,48	4,67 / 7,47	4,85–9,43
биграммы	CBOW	15	6,34–10,41	9,27	8,41	4,33 / 8,11	5,73–10,51

n	векторы	d	Швайнхарт	TwoN N	Fisher S	Hidalgo	статья
биграмм ы	BERT→PC A	5	6,71–9,66	6,10	8,37	7,33 / 7,37	—
биграмм ы	BERT→PC A	10	8,88–15,40	8,24	12,67	9,93 / 10,03	—
биграмм ы	BERT→PC A	15	9,72–16,81	9,37	14,10	10,84 / 11,00	—
биграмм ы	BERT-768	768	14,50–18,20	13,90	17,56	14,21 / 14,95	—

¹ допустимые α есть у 2 из 3 лестниц; ² у 1 из 3.

Столбец «статья» — оценка Швайнхарта из Табл. 4 (SVD) и Табл. 5 (CBOW); TwoNN, FisherS и Hidalgo в статье не считались.




Рис. 4. Оценки всех методов при d = 15 и для полного BERT-768. Для SVD-слов Hidalgo находит почти одномерную часть (0,24) — «лучи» редких слов.

8. Выводы

- **Метод работает.** Реализация Швайнхарта точна и на фигурах ошибается не больше, чем в работах авторов метода; все четыре метода согласуются на кубах, сфере и фрактале.
- **SVD по главам занижает размерность.** 46,5% лемм встречаются в одной главе; их векторы совпадают или лежат на общем луче. Hidalgo выделяет эту часть (13–32% слов, размерность 0,2–0,6); без неё размерность SVD-слов 5,0 / 6,9 / 7,7 — заметно ближе к значениям статьи (4,65–5,52 / 7,14–8,20 / 9,81–12,78).
- **С векторами CBOW результаты согласуются со статьёй.** Биграммы CBOW внутри диапазонов Табл. 5 при всех d и у всех методов; слова CBOW при d = 10–15 выше значений статьи (там корпус из 6 429 текстов, здесь один роман, и CBOW обучен только на его тексте).

- **BERT даёт более высокие размерности**, и они сильнее зависят от масштаба: TwoNN для слов BERT-768 растёт с 13,7 до 26 при прореживании. Биграммы BERT-768 — самый согласованный результат между методами (≈ 14 –15, FisherS 17,6).
- **Пост с n.** Для SVD, CBOW и BERT→PCA размерность растёт от слов к биграммам и триграммам, как и в статье; у полного BERT порядок «слова > триграммы > биграммы».
- **FisherS** систематически расходится с остальными (ниже на словах SVD/CBOW, выше на биграммах BERT) и завышал изогнутые фигуры — его числа наименее надёжны. Hidalgo полезен как диагностика неоднородности облака.

9. Ограничения и что дальше

- Один роман вместо корпуса: ожидать точного совпадения с числами статьи для SVD не приходится. Следующий шаг — корпус из сотен русских текстов; код масштабируется (150 тыс. точек в 30 измерениях — ~ 10 мин на 16 ядрах).
- В статье выборки от 10^5 точек; у нас лестница от N/16 (для слов это ~ 1 100 точек), что ослабляет оценки для слов.
- Оценка Брито (BQY) из статьи не считалась; для BERT-768 по триграммам — одна лестница вместо трёх.
- Диапазон min-max по допустимым α зависит от порога 10%; для BERT при широком наборе α диапазоны широкие — ориентир медиана по α .

Приложение. Воспроизводимость

Шаг	Где	Файл / задача
Предобработка, SVD	ноутбук	wap_preprocess.py, 1_preprocess_on_laptop.bat → wap_embeddings.npz
ruBERT	ноутбук (+ проверка на HSE)	wap_embed_alt.py → wap_embeddings_alt.npz
CBOW, триграммы	HSE	wap_cbow_hse.py, wap_add_trigrams.py; задачи 4364103, 4364182
Швайнхарт	HSE	schweinhart_mst.py, wap_schweinhart.py; 4363712 (SVD), 4364206 (BERT→PCA), 4364265, 4365040 (BERT-768)
TwoNN, FisherS, Hidalgo	HSE	id_methods.py, id_run.py; 4365900 (8 ядер)
Фигуры	HSE	validate_synthetic.py, id_run.py --only-synthetic

Все скрипты — в папке LANC\hpc_wap; на HSE — ~/wap_run (JSON по каждой конфигурации, оценки по всем α , логи). Литература: «A Language and Its Dimensions: Intrinsic Dimensions of Language Fractal Structures» (Complexity, 2024); Schweinhart 2021; Facco et al. 2017; Albergante et al. 2019; Allegra et al. 2020.